Traduzido do Inglês para o Português - www.onlinedoctranslator.com

Processamento e Controle de Sinais Biomédicos 113 (2026) 108888

Sumários disponíveis emCiência Direta

Processamento e Controle de Sinais Biomédicos

Página inicial da revista:www.elsevier.com/locate/bspc

Classificação radiográfica de tumores ósseos primários orientada por aprendizado profundo usando modelos híbridos com atenção aumentada.

Syed Mohsin Bokhari[um] Muhammad Shafi[b,c,*]

[um] Departamento de Engenharia Elétrica e de Computação, Universidade de Engenharia e Tecnologia (UET), Taxila, Paquistão
[b] Escola de Computação, Universidade de Ulster, Reino Unido
[c] Faculdade de Computação e Tecnologia da Informação, Universidade de Sohar, Omã

INFORMAÇÕES DO ARTIGO

Palavras-chave:
Rede Neural Convolucional Transformer híbrida (CNNT)
ResNet50 com Módulo de Atenção de Bloco Convolucional (CBAM)
Filtragem 3D por Correspondência de Blocos (BM3D)
Técnica de Sobreamostragem Sintética da Minoria (SMOTE)

Inteligência Artificial na Área da Saúde

RESUMO

A classificação precisa de tumores ósseos primários é essencial para o diagnóstico precoce e o planejamento eficaz do tratamento, especialmente devido à complexa heterogeneidade radiográfica exibida pelos subtipos tumorais. Este estudo apresenta dois novos modelos de aprendizado profundo: um híbrido de Rede Neural Convolucional Transformer (CNNT) e um modelo de Rede Residual 50 (ResNet50), ambos aprimorados por um Módulo de Atenção de Bloco Convolucional (CBAM) para melhorar a discriminação de características e a compreensão contextual em imagens radiográficas. Os modelos foram treinados e validados no conjunto de dados Bone Tumor X-ray Radiograph Dataset (BTXRD), composto por 3.746 radiografias rotuladas contendo nove subtipos tumorais. Para mitigar os efeitos do ruído e do desequilíbrio de classes, foram empregados métodos avançados de pré-processamento, como a Filtragem 3D por Correspondência de Blocos (BM3D) e o balanceamento de dados utilizando a Técnica de Sobreamostragem Sintética da Minoria (SMOTE).

Testes extensivos demonstram que nossas abordagens superam os modelos de última geração atuais, como ResNet50, EfficientNet versão B3 (EfficientNet-b3), You Only Look Once versão 8 (YOLOv8s-cls) e Deep Supervision Network (DS-Net). Especificamente, a arquitetura ResNet50-CBAM alcança uma pontuação F1 de 0,9759, uma pontuação AUC-ROC de 0,984, uma acurácia média de 97,41% e um coeficiente Kappa de Cohen de 0,9718, superando os benchmarks existentes para classificação binária de tumores. O modelo CNNT também alcança um desempenho competitivo, atingindo uma pontuação F1 de 0,9595 com uma acurácia de 92,56%. A incorporação de mecanismos de atenção e pré-processamento guiado por conjunto de dados torna essa estrutura adequada para aplicações clínicas práticas. Os resultados desta pesquisa têm implicações significativas para o setor de saúde, ao introduzir um sistema de diagnóstico baseado em Inteligência Artificial (IA) escalável, interpretável e altamente preciso, que pode auxiliar os radiologistas em diagnósticos oportunos e processos de tomada de decisão, contribuindo, em última análise, para melhores resultados para os pacientes e aliviando a carga diagnóstica na oncologia musculoesquelética.

1. Introdução

Os tumores ósseos primários, embora raros, representam uma preocupação significativa para a saúde, especialmente em pessoas com menos de 20 anos de idade.1], visto que são a terceira causa mais frequente de morte relacionada ao câncer nessa faixa etária. O diagnóstico preciso e precoce é parte fundamental do melhor manejo terapêutico e de um melhor prognóstico para o paciente. A radiografia continua sendo a técnica principal na avaliação inicial de suspeita de tumores ósseos, fornecendo informações valiosas sobre a localização, as características arquitetônicas e a potencial malignidade do câncer. No entanto, as apresentações radiográficas altamente variáveis dos tumores ósseos representam problemas diagnósticos complexos, mesmo para radiologistas experientes [1].

Os recentes avanços em Inteligência Artificial (IA), especificamente aqueles provenientes de métodos de aprendizagem profunda, transformaram radicalmente o campo do Diagnóstico Auxiliado por Computador (CAD) em imagens médicas. Essas tecnologias baseadas em IA... Os métodos têm demonstrado desempenho sem precedentes em diversas tarefas, como segmentação, detecção, classificação e aprimoramento de imagens em várias aplicações médicas. No campo da oncologia musculoesquelética, estudos comprovaram a eficácia de modelos de aprendizado profundo na detecção e avaliação de tumores ósseos utilizando imagens radiográficas, um avanço significativo na área de radiologia diagnóstica. Por exemplo, um modelo de aprendizado profundo multitarefa desenvolvido por von Schacky et al. alcançou uma acurácia de 80,2% na classificação de tumores ósseos primários como malignos ou benignos, superando residentes de radiologia, mas igualando o desempenho de radiologistas com especialização [2].

A integração de ferramentas de diagnóstico por IA na clínica é dificultada, entre outros fatores, pela falta de grandes conjuntos de dados radiográficos bem anotados e disponíveis publicamente para tumores ósseos. A raridade desses tumores...

* Autor correspondente.
Endereço de email: m.shafi@ulster.ac.uk (M. Shafi).

https://doi.org/10.1016/j.bspc.2025.108888
Recebido em 5 de maio de 2025; Recebido em versão revisada em 1 de agosto de 2025; Aceito em 5 de outubro de 2025.
Disponível online em 14 de outubro de 2025.
1746-8094/© 2025 Os Autores. Publicado pela Elsevier Ltd. Este é um artigo de acesso aberto sob a licença CC BY (http://creativecommons.org/licenses/by/4.0/).

Como o osteossarcoma resulta em um número reduzido de casos, predominantemente concentrados em grandes hospitais universitários, as questões de privacidade do paciente também envolvem imagens médicas, dificultando a obtenção de permissões em larga escala. Além disso, a anotação de imagens é demorada e trabalhosa, exigindo muito tempo até mesmo de médicos experientes. Essa ausência de conjuntos de dados robustos limita o desenvolvimento, a validação e a generalização de modelos de IA, restringindo seu uso clínico.2Yu He et al. desenvolveram um banco de dados com 2899 imagens de raios X em cinco centros, sendo 2158 não malignas e 741 malignas. As imagens não continham informações clínicas significativas, como sexo, idade e localização geográfica. O conjunto de dados do Hospital Universitário Nacional de Chonnam (CNUH) inclui 1195 imagens de tumores e 381 imagens padrão, mas se limita a tumores ósseos do joelho, restringindo suas aplicações. Outros estudos, como os de Dan Yu, Chan Woo Park e Sarah Consalvo, apresentam as mesmas limitações, como tamanho amostral reduzido, imagens ósseas padronizadas e informações demográficas [3].

Estão sendo feitos esforços para resolver esses problemas [2O conjunto de dados de radiografias de tumores ósseos (BTXRD) foi criado para apoiar o desenvolvimento de algoritmos de IA no diagnóstico de tumores ósseos primários. O conjunto de dados inclui 3746 imagens ósseas, tumores e casos típicos, juntamente com dados clínicos e anotações.1O conjunto de dados Bone Scan 80K (BS-80K) contém muitas imagens de cintilografia óssea para pesquisa em diagnóstico assistido por computador. No entanto, a disponibilidade geral do conjunto de dados é limitada, o que indica a necessidade de aprimorar ainda mais a coleta e o compartilhamento de dados para desenvolver IA no diagnóstico de tumores ósseos.3].

O uso da inteligência artificial (IA) para a classificação de tumores ósseos tem uma longa história de desenvolvimento, desde o trabalho inicial de Lodwick et al. [4] em 1980 com os primeiros modelos computacionais para avaliação de tumores, de acordo com Reinus et al. [5Em 1994, Do et al. utilizaram modelos baseados em redes neurais que traduziram características de imagem de 709 lesões ósseas em bancos de dados estruturados, alcançando uma precisão diagnóstica de 85% na diferenciação entre condições benignas e malignas. Em seguida, Do et al. [6] apresentaram um modelo de inferência Bayesiana em 2017, alcançando 62% de precisão na previsão de diagnósticos precisos e 80% no diagnóstico diferencial a partir de 710 radiografias Do et al. Além da classificação, a IA tornou-se altamente prevalente na segmentação de limites tumorais. Por exemplo, Huang et al. [7 Huang et al. projetaram uma Rede Convolucional Totalmente Supervisionada Múltipla (MSFCN) com um Coeficiente de Similaridade de Dice (DSC) de 87,8% e uma pontuação F1 de 0,908, superior aos modelos de Rede Convolucional Totalmente Convolucional (FCN), Rede Convolucional em Forma de U (U-Net) e Detecção de Bordas de Hipercoluna (HED) em segmentação. [7O modelo subsequente MSRN aprimorou ainda mais as métricas de segmentação em 8,78% DSC em relação às linhas de base de última geração (Do et al.). Trabalhos mais recentes também se aventuraram na modelagem preditiva para recorrência tumoral pós-operatória (He et al.).8] aplicaram CNNs a dados de ressonância magnética (RM) de 56 pacientes com tumor de células gigantes, com precisões de CNN de 75,5% e precisões de CNN + regressão de 78,6%, superando a precisão de 64,3% dos radiologistas, com ganhos de sensibilidade de mais de 20% He et al. [9 Esses exemplos demonstram coletivamente a crescente sofisticação e o potencial da IA para o diagnóstico, localização e prognóstico de tumores ósseos.

Apesar desses avanços, diversas limitações significativas ainda estão presentes na literatura existente. Vários modelos, tanto antigos quanto novos, são afetados por dados ruins diversidade t, ausência de metadados demográficos, e anotações de subtipos incompletas, que restringem sua capacidade de generalização. ade [10]. Re mecanismos de busca como von Schacky et al. e conjuntos e outros utilizam ze rico infor de dados de Yao mation; no entanto, eles não contêm uma taxonomia multiclasse completa ou anotações consistentes de alta resolução d são frequentes restrito a áreas anatômicas específicas (ex.: especificamente para o joelho) [1,2Além disso, arquiteturas tradicionais como Re Rede sidual orc 50 (ResNet5 0) ou Inception V3, embora Adequados para uso geral, falham em distinguir subtipos tumorais visualmente comparáveis devido à sua incapacidade de compreender o contexto geral e a complexidade do tumor. cal [10,11Por fim, poucos estudos utilizaram métodos avançados. métodos de redução de ruído ou abordaram o desequilíbrio extremo de classes comumente encontrado d em tu ósseo mais conjuntos de dados [12].

Nosso trabalho propõe uma solução de modelo duplo para abordar essas lacunas: uma CNN Trans ex-híbrido rid (CNNT) e um modelo ResNet50 com módulo de Bloco Nacional k Atenção convolução (CBAM). Nossos modelos são treinados no

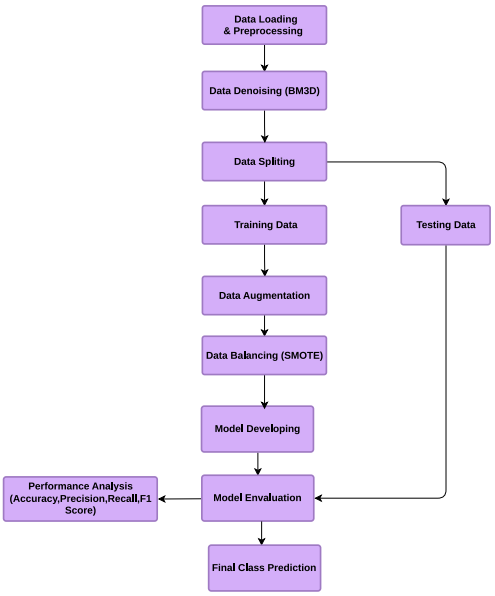

Figura 1.A estrutura proposta.

O conjunto de dados BTXRD é um conjunto de dados robusto e multicêntrico com 3746 radiografias de nove subtipos de tumores ósseos e metadados demográficos, anatômicos e de imagem anotados [1Nossa solução também incorpora a filtragem BM3D, um método de redução de ruído de última geração testado em modalidades de imagem de Tomografia Computadorizada (TC), Ressonância Magnética (RM) e histopatologia, e a sobreamostragem SMOTE para lidar com o desequilíbrio de classes de forma eficiente. A ResNet50 aprimorada por CBAM detecta dependências espaciais e de canal críticas, enquanto o módulo Transformer da CNNT é particularmente bem ajustado para modelar relações contextuais de longo alcance. Essas melhorias alcançam ganhos significativos em relação a benchmarks recentes (por exemplo, You Only Look Once versão 8 (YOLOv8s-cls), EfficientNet, Deep Supervision Network (DS-Net)), com uma pontuação F1 de 0,9759 e um Kappa de Cohen de 0,9718, superando confortavelmente os recordes por uma ampla margem.1,3,12A seguir, apresentamos as principais contribuições do nosso trabalho proposto.

1. Proposta de uma estrutura de dois caminhos que combina CNN, CBAM e Transformer para modelagem eficiente de características locais e globais.
2. Utilizando a redução de ruído BM3D e o balanceamento SMOTE para melhorar a qualidade da imagem e corrigir o desequilíbrio de classes.
3. Utilização do conjunto de dados abrangente BTXRD com metadados clínicos detalhados para melhor generalização.
4. Alcançar desempenho superior em métricas de classificação multiclasse (AUC-ROC, precisão, pontuação F1, especificidade).
5. A avaliação em comparação com ResNet50, EfficientNet, YOLOv8s-cls e DS-Net produz resultados de última geração.
6. Alcançar um treinamento eficaz com menor complexidade e convergência mais rápida, adequado para uso clínico em ambientes do mundo real.

O restante do artigo está organizado da seguinte forma. Seção2Abrange a preparação e o pré-processamento de dados, Seção3Abrange a metodologia proposta, Seção4Apresenta os resultados e a discussão, e a Seção5 O artigo conclui com sugestões para pesquisas futuras.

2. Preparação e pré-processamento de dados

A descrição passo a passo da metodologia adotada nesta pesquisa, desde a aquisição de dados até a avaliação do modelo, é ilustrada emFigura 1.

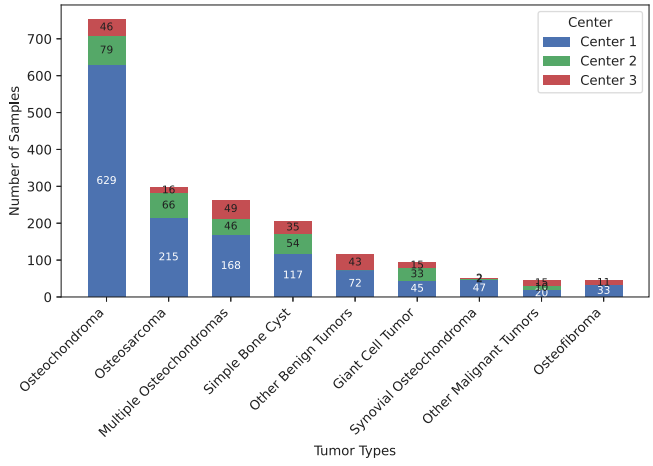

Figura 2. Distribuição dos subtipos de tumores ósseos no conjunto de dados BTXRD.

O documento descreve o fluxo de trabalho passo a passo, que inclui pré-processamento de imagem, extração de características, aprimoramento da atenção, classificação e avaliação de desempenho.

Figura 1Apresenta-se o fluxo de trabalho metodológico geral referente ao estudo proposto. O processo inicia-se com a aquisição do conjunto de dados BTXRD e, em seguida, com o pré-processamento dos dados, incluindo a remoção de ruído utilizando BM3D, aumento de dados e balanceamento utilizando SMOTE. As imagens pré-processadas são então submetidas a dois modelos híbridos de aprendizado profundo: CNNT e ResNet50-CBAM. Esses modelos realizam a extração de características e a classificação. Os modelos são avaliados utilizando acurácia, pontuação F1, AUC-ROC, MCC e matriz de confusão. As subseções seguintes fornecem detalhes sobre o conjunto de dados e as etapas de pré-processamento antes que os dados possam ser inseridos nos modelos de aprendizado profundo propostos.

2.1. Conjunto de dados

Neste trabalho, utilizamos o conjunto de dados BTXRD, um conjunto de dados aberto para a classificação, localização e segmentação de tumores ósseos primários a partir de radiografias [13O conjunto de dados consiste em 3746 imagens de raios X, incluindo 1879 imagens ósseas padrão, 1525 imagens de tumores ósseos benignos e 342 imagens de tumores ósseos malignos. Cada imagem também contém anotações sobre dados demográficos do paciente (idade, sexo), região anatômica e parâmetros de imagem (ângulo de disparo). Além disso, as imagens de tumores ósseos também contêm informações sobre o status benigno/maligno, classificações de subtipo e características anatômicas. Este site anotado para manter categoria completa organização. Os dados nós reunidos de m três extensos coleta de dados s: (1) três chineses centros médicos, nomeadamente o Primeiro Hospital Afiliado da Faculdade de Medicina de Guangxi Universidade, Hospital Afiliado de Yo ujiang Médico Faculdade para a Nação-alities e Hospital Popular de Baise; (2) Radiopaedi a.org, um site popular portal de radiologia; e (3) MedPix, um banco de dados aberto de imagens médicas. Para dados consistentes A garantia de qualidade, amostras de tumor ósseo primário envolvendo o cabeça, pescoço, c o fígado e regiões abdominais foram rejeitadas devido a a baixa disponibilidade e ocorrência de artefatos de imagem. Portanto, o O conjunto de dados concentra-se em imagens de raios X dos ossos do tumores do membro superior (mãos, ulna, rádio, úmero, articulações do punho, articulações do cotovelo, e articulações do ombro), membros inferiores (pés, tíbia, fíbula, fêmur e articulações do tornozelo, articulações do joelho) e pelve (quadris, articulações do quadril). O anotação e trabalho de rotulagem foi realizado por um especialista profissional em s, onde um tumores ósseos com 10 anos de experiência em diagnóstico, que a réncia carregava realizou a segmentação inicial usando o Label me [14] e marcação de ferramenta de anotação tumor usando caixas delimitadoras. Então, o outro especialista em emergências com Com base em 20 anos de experiência, foi feita a revisão para verificação da precisão. n. Além disso, 50 das imagens selecionadas aleatoriamente foram resegmentadas. após um mês para verificar a confiabilidade das anotações. Toda a coleta de conjuntos de dados e

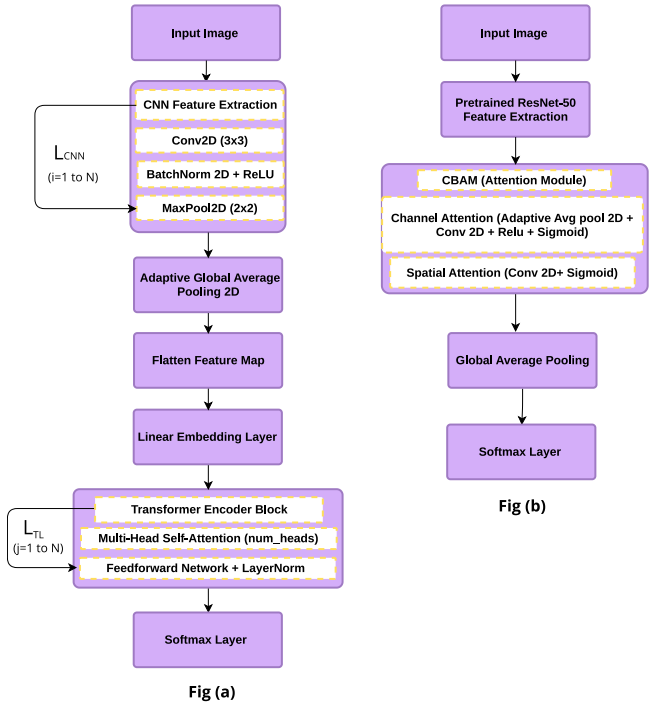

Figura 3.(a) CNNT: Modelo de Rede Neural Convolucional Transformer que integra extração de características locais por meio de camadas CNN e modelagem de contexto global via autoatenção multi-cabeças. (b) ResNet50-CBAM: Uma arquitetura baseada em ResNet50 aprimorada para extração de características com um Módulo de Atenção de Bloco Convolucional (CBAM) integrado para melhorar a atenção espacial e por canal para representação de características discriminativas.

Os procedimentos de rotulagem foram conduzidos pelos autores do conjunto de dados, conforme citado em [13], e não foram realizados neste estudo. Nossa pesquisa se concentra na classificação de tumores ósseos primários em nove classes diferentes: Tumor de Células Gigantes, Osteocondromas Múltiplos, Osteocondroma, Osteofibroma, Osteossarcoma, Outros Tumores Benignos, Outros Tumores Malignos, Cisto Ósseo Simples, Osteocondroma Sinovial, apresentados emFigura 2Dentre esses, osteocondroma, osteossarcoma, osteocondromas múltiplos e cisto ósseo simples são os subtipos mais comuns nos dados.

O conjunto de dados BTXRD foi meticulosamente selecionado por meio de um processo rigoroso e multifásico, visando minimizar potenciais fontes de viés e aprimorar a integridade dos dados. Dados radiográficos de alta qualidade foram adquiridos seletivamente de diversos centros clínicos, com atenção especial aos dados dos Centros 2 e 3, identificados como potenciais fontes de variabilidade. Protocolos abrangentes de pré-processamento, incluindo limpeza, filtragem e validação de dados, foram aplicados para excluir imagens incompletas, de baixa resolução ou redundantes, garantindo a inclusão apenas de amostras relevantes para o diagnóstico. Metadados clínicos e demográficos foram padronizados em um esquema uniforme para facilitar a consistência e a interoperabilidade entre as fontes. Radiologistas especialistas realizaram anotações manuais de radiografias de tumores ósseos por meio de uma estrutura de revisão em múltiplos níveis, gerando máscaras de segmentação e caixas delimitadoras de alta precisão. Essa estratégia rigorosa de anotação foi projetada para minimizar a variabilidade entre observadores e melhorar a confiabilidade dos rótulos de referência. Para fortalecer ainda mais a utilidade do conjunto de dados para aplicações de aprendizado profundo, a segmentação — uma tarefa essencial para isolar estruturas anatômicas clinicamente significativas — foi implementada usando o YOLOv8s-seg [15Este modelo de segmentação de instâncias de última geração, em tempo real, combina detecção de objetos com máscara em nível de pixel.

geração em uma arquitetura de estágio único. Sua capacidade de localizar simultaneamente caixas delimitadoras e prever máscaras de segmentação contribui tanto para a eficiência computacional quanto para a delimitação precisa de regiões patológicas. Coletivamente, essas medidas estabelecem o BTXRD como um benchmark robusto e de alta fidelidade para o desenvolvimento e avaliação de modelos automatizados de diagnóstico de tumores ósseos [16].

O conjunto de dados BTXRD consiste em nove subtipos de tumores com frequências de classe variáveis. A distribuição dos subtipos no conjunto de dados é apresentada em Figura 2.

Figura 2A figura mostra a distribuição por classe dos subtipos de tumores ósseos no conjunto de dados BTXRD. Pode-se observar na figura que existe um desequilíbrio entre as classes, por exemplo, *Osteocondroma* e *Cistos ósseos simples* contêm contagens de amostras muito maiores do que aquelas que ocorrem com pouca frequência, como *Osteofibroma*. Isso motivou nossa aplicação do SMOTE para atenuar a assimetria e aprimorar o aprendizado do modelo em relação às classes minoritárias.

2.2. Remoção de ruído dos dados

Os conjuntos de dados de imagens médicas geralmente apresentam ruído devido a variações nas condições de aquisição, defeitos nos sensores e outras condições externas. O ruído pode degradar o desempenho dos modelos de aprendizado profundo e, portanto, métodos robustos de remoção de ruído são necessários para o pré-processamento. Nossa pesquisa utiliza o algoritmo Block Matching and 3D Filtering (BM3D) [17O BM3D é um método de ponta para remover ruídos do conjunto de dados de imagens de tumores ósseos antes de dividi-lo em subconjuntos de treinamento e teste. Ele constrói patches de imagem semelhantes, converte-os em um espaço de dimensão superior, realiza operações de filtragem por redução de tamanho e aplica uma transformação inversa para construir uma imagem sem ruído. O algoritmo preserva com eficiência os detalhes estruturais enquanto elimina o ruído, tornando-o muito eficaz para o processamento de imagens médicas.

Estudos recentes indicaram as vantagens do BM3D em operações de imagem biomédica. Por exemplo, Zhang et al. [18] aplicaram com sucesso o BM3D para melhorar a qualidade das tomografias computadorizadas de baixa dose, contribuindo para uma maior precisão diagnóstica. Da mesma forma, Liu et al. [19Wang et al. [ ] aplicaram arquiteturas BM3D e de aprendizado profundo para remoção de ruído em imagens histopatológicas e obtiveram desempenho aprimorado na extração de características e na classificação.20Em um estudo, foram aplicados métodos de pré-processamento baseados em BM3D para melhorar imagens de fundo de retina, o que contribuiu para um melhor desempenho de segmentação na detecção de doenças oftalmológicas. Além disso, foram pesquisados métodos híbridos que integram BM3D e modelos de aprendizado profundo, como ilustrado no trabalho de pesquisa de Chen et al. [21], onde o BM3D foi usado para remover ruídos de exames de ressonância magnética cerebral antes da extração de características e melhorar a confiabilidade da classificação.

Em nossa abordagem, cada imagem é pré-processada com BM3D antes que o conjunto de dados seja dividido em conjuntos de treino e teste. O algoritmo é executado independentemente para os canais de cor Vermelho, Verde e Azul (RGB) com parâmetros de ruído predeterminados, conforme definido no Algoritmo.1As imagens com ruído reduzido são armazenadas para treinamento subsequente do modelo, evitando assim distorções causadas por ruído que afetam o desempenho da classificação. A aplicação do BM3D em nosso procedimento de pré-processamento melhora drasticamente a qualidade do conjunto de dados de imagens tumorais, aumentando, consequentemente, a confiabilidade e a precisão da classificação tumoral. Estratégias adaptativas de BM3D e arquiteturas de redução de ruído baseadas em aprendizado profundo podem ser exploradas em pesquisas futuras para aprimorar ainda mais a qualidade da imagem e maximizar a acurácia da classificação.

Utilizamos um pipeline de remoção de ruído com a abordagem BM3D para fornecer dados de alta qualidade para o treinamento do modelo. O procedimento passo a passo para a remoção de ruído em todo o conjunto de dados nos canais RGB usando BM3D é apresentado no Algoritmo.1.

Algoritmo 1 Remoção de ruído de imagem baseada em BM3D

Requisitos: Diretório de entrada - *inpot* Diretório de saída - *otput*, Parâmetro de ruído-eters ($_r$, $_g$, $_b$)

Garantir: As imagens com ruído reduzido são salvas em - *otput*

Inicializar $_r$=10, $_g$=12, $_b$=14
Criar - *otput* Se não existir 3:
Defina o contador C=0
para cada imagem F ∈ - *inpot* **fazer**
  se F é um formato de imagem válido **então**
    Carregar de F, Ignorar se houver
    erro (R, G, B) ← dividir( )
    (R, G, B) ← BM3D(R, σ_r), BM3D(G, σ_g), BM3D(B, π_b)
    Salvar mesclado (R, G, B) como ∈ - *otput*
    C ← C+1; Mensagem de sucesso na impressão
  fim se
fim para
Imprimir "Total de imagens processadas: C"

Algoritmo1A figura ilustra a redução de ruído em imagens radiográficas por meio de Correspondência de Blocos e Filtragem 3D (BM3D). A redução de ruído é aplicada a todas as imagens do conjunto de dados em determinados níveis de ruído. Os resultados são combinados e salvos como imagens com ruído reduzido, sendo utilizados para treinamento e teste, aumentando assim a interpretabilidade das características e reduzindo artefatos de classificação.

2.3. Aumento de dados

Para aprimorar a robustez e a generalização do nosso modelo de aprendizado profundo para classificação de tumores, empregamos uma variedade de métodos de aumento e pré-processamento de dados. O aumento de dados é essencial para incrementar a diversidade do conjunto de dados, reduzir o sobreajuste e melhorar o desempenho do modelo.

O processo de transformação começa com o redimensionamento das imagens para uma resolução alvo, seguido pela adição de inversão horizontal aleatória para simular a variabilidade natural em diversas imagens de tumores ósseos. Uma rotação aleatória em intervalos de 15 graus também é adicionada, juntamente com uma variação de cor que envolve ajustes controlados de brilho, contraste, saturação e matiz. Para maior robustez, uma distorção de perspectiva aleatória é adicionada, com uma escala de distorção de 0,2 e probabilidade de 0,5, facilitando assim a generalização do modelo para pequenas deformações espaciais. Um desfoque gaussiano com tamanho de kernel de 3 também é adicionado para reduzir as variações na nitidez das imagens. Finalmente, as imagens são convertidas em tensores e normalizadas para uma média de 0,5 e desvio padrão de 0,5 para estabilizar o treinamento.

2.4. Balanceamento de dados

O desequilíbrio de classes é um problema significativo na análise de imagens médicas que pode distorcer os modelos preditivos, levando a um desempenho ruim nas classes minoritárias. Esse problema é especialmente relevante em conjuntos de dados de anomalias congênitas incomuns. Para mitigar esse problema, utilizamos a Técnica de Sobreamostragem Sintética de Minorias (SMOTE) [22], uma técnica típica de aumento de dados que cria instâncias sintéticas interpolando entre instâncias existentes da classe minoritária. No nosso caso, usamos o SMOTE para equilibrar a distribuição de classes entre várias imagens de tumores ósseos, de modo que o modelo seja treinado em um conjunto mais representativo. O SMOTE mitiga o viés em conjuntos de dados desbalanceados criando instâncias sintéticas para as classes minoritárias em vez de replicar instâncias, evitando o sobreajuste e melhorando a generalização. O algoritmo escolhe instâncias aleatórias da classe minoritária e cria instâncias sintéticas ao longo dos segmentos de reta entre os k vizinhos mais próximos no espaço de características, aumentando assim a representação de classes sub-representadas sem preservar a estrutura original dos dados.

Estudos recentes demonstraram a eficácia do SMOTE na melhoria do desempenho da classificação de dados biomédicos desbalanceados. Por exemplo, Zhao et al. [23] aplicaram SMOTE a dados de imagens dermatológicas, melhorando a precisão da classificação para doenças raras da pele. Da mesma forma, Lee et al. [24] aplicaram técnicas de aumento de dados baseadas em SMOTE para alcançar equilíbrio em dados de anomalias craniofaciais pediátricas, refletindo uma melhoria significativa na estabilidade dos modelos de aprendizado profundo. Além disso, o SMOTE tem sido usado em modelos de aprendizado profundo em questões biomédicas, incluindo o diagnóstico de doenças raras [25] e detecção de anomalias congênitas [26], demonstrando sua eficácia na compensação de distribuições desequilibradas. Por exemplo, [27] melhorou o desempenho em modelos profundos para detecção de patologias raras quando o SMOTE foi aplicado na fase de pré-processamento. Da mesma forma, [28] demonstraram a eficácia do SMOTE no tratamento de dados biomédicos de alta dimensionalidade, que é o cenário da nossa aplicação. Embora o SMOTE envolva algum custo computacional, sua eficácia na correção de distribuições enviesadas o torna vantajoso, como demonstrado por sua ampla aplicação na literatura recente [28,29].

Em nossa implementação, utilizamos o SMOTE no conjunto de dados indexado, realizando sobreamostragem das classes minoritárias para obter uma distribuição aproximadamente uniforme antes do treinamento. Isso garante que a generalização do modelo de classificação seja aprimorada, prevenindo o viés causado por distribuições de classes desbalanceadas. Ao incorporar o SMOTE na etapa de pré-processamento, nosso método assegura que o conjunto de dados de imagens de tumores ósseos proposto possa ser efetivamente utilizado para diagnóstico médico sem ser comprometido por distribuições de classes enviesadas.

A estrutura arquitetônica básica dos dois modelos CNNT e ResNet50-CBAM é apresentada emFigura 3.

3. Os modelos propostos

Primeiramente, dividimos o conjunto de dados em conjuntos de treinamento e teste. Isso nos permitiu testar o modelo de aprendizado profundo com precisão e sem viés. Adotamos uma proporção de 80:20, com 80% para treinamento e 20% para teste. Aplicamos o SMOTE somente no conjunto de treinamento para lidar com o desequilíbrio de classes, garantindo que nenhuma amostra sintética ou imagem aumentada fosse incluída no conjunto de teste.

3.1. Modelo de Redes Neurais Convolucionais Transformer (CNNT)

O processo de treinamento é projetado sistematicamente, começando com a inicialização dos modelos, onde um módulo CNN gera características espaciais a partir de uma sequência de camadas convolucionais, seguida por normalização em lote, ativação ReLU (Unidade Linear Retificada) e max pooling. Os mapas de características obtidos passam por uma camada de pooling médio adaptativo para preservar uma representação de tamanho fixo, que é então transformada em um espaço de incorporação D-dimensional. As incorporações são passadas como entrada para o codificador Transformer, que consiste em várias camadas com mecanismos de autoatenção multi-cabeças integrados para capturar efetivamente as dependências de longo alcance e as relações contextuais nas imagens. A classificação final é alcançada por meio de uma camada totalmente conectada com ativação softmax para produzir saídas probabilísticas em relação às categorias de várias imagens de tumores ósseos. A arquitetura do modelo CNNT proposto é mostrada no algoritmo.2O modelo proposto compreende vários elementos-chave: extração de características convolucionais, pooling adaptativo, incorporação linear e modelagem de atenção baseada em transformadores, seguidos por camadas de classificação, conforme mostrado em Figura 3.

Para aumentar a eficiência do processo de aprendizagem, utilizamos o otimizador Adam com uma taxa de aprendizagem fixa, e a função de perda é definida usando entropia cruzada categórica. Durante o processo de treinamento, o conjunto de dados é dividido em mini-lotes. Para cada lote de indivíduos, o modelo faz previsões, calcula a perda e atualiza o modelo. Os parâmetros da rede são definidos com retropropagação e descida de gradiente. Métricas de desempenho como Acurácia, Precisão, Revocação e F1-score, bem como AUC-ROC, são calculadas ao final de cada época para monitorar o desempenho do treinamento e do teste. O modelo é então submetido a um processo de avaliação, no qual é alternado para o modo de inferência e executado em amostras de teste não vistas. As saídas previstas são comparadas com os rótulos de verdade fundamental, resultando no cálculo das principais métricas de desempenho. Esse processo organizado de treinamento e avaliação ajuda a desenvolver um modelo de classificação robusto e generalizável, capaz de discriminar entre vários subtipos de tumores ósseos, como Tumor de Células Gigantes, Osteocondromas Múltiplos, Osteocondroma, Osteofibroma, Osteossarcoma, Outros Tumores Benignos, Outros Tumores Malignos, Cisto Ósseo Simples e Osteocondroma Sinovial.

O modelo processa uma imagem de tumor ósseo como entrada. $\in \mathbb{R}^{H\times W\times C}$, onde $H, W,$ e C representam a altura, a largura e o número de canais, respectivamente. A representação de características é realizada por um módulo composto por múltiplas camadas convolucionais, normalização em lote e funções de ativação não lineares, utilizando um módulo baseado em Rede Neural Convolucional (CNN). A representação de características é feita da seguinte forma:

$$F_{\text{CNN}} = \text{ReLU}(\text{BatchNorm}(\text{Conv2D}(I, W_{\text{CNN}}))) \tag{1}$$

onde W_{CNN} são parâmetros treináveis dos kernels convolucionais. Esta operação extrai características espaciais locais, mantendo padrões significativos da estrutura da imagem óssea. Uma operação de MaxPooling MaxPool2D(2× 2)Em seguida, aplica-se uma subamostragem das dimensões espaciais para selecionar as ativações dominantes, melhorando assim a eficiência computacional e retendo informações estruturais significativas. A rede aprende características hierárquicas, desde informações de borda de baixo nível até representações de forma de alto nível, por meio de diversas camadas convolucionais. Essas características são então inseridas no mecanismo de atenção baseado em Transformer, refinando ainda mais as dependências entre as características com base em relações espaciais de longo alcance.

A extração de características, por meio de uma camada de Pooling Médio Global Adaptativo (GAP), agrega informações espaciais em um descritor global compacto. Matematicamente, essa operação é expressa como:

$$F_{\text{brecha}} = \frac{1}{H\times W} \sum_{=1}^{} \sum_{=1}^{} F_{\text{CNN}}(i, j) \tag{2}$$

onde H e W denotam as dimensões espaciais do mapa de características, e $F_{\text{CNN}}(i, j)$ representa os valores de ativação na posição (i, j)Ao contrário das camadas totalmente conectadas padrão, o GAP permite o aprendizado de representações invariantes à escala, compactando características espaciais sem perder padrões essenciais.

O mapa de características gerado é transformado em um vetor unidimensional para facilitar a compatibilidade com o módulo de codificação baseado em Transformer. O codificador Transformer compreende camadas de autoatenção e feedforward com múltiplas cabeças que capturam dependências de longa distância entre as dimensões das características. Os mecanismos de autoatenção aprendem a dimensionar as interações entre as características para facilitar o aprendizado de uma representação contextual robusta.

dinamicamente. Matematicamente, o mecanismo de autoatenção calcula:

$$\text{Atenção}(Q, K, V) = \text{softmax}\left(\sqrt{\frac{T}{\overline{d_k}}}\right) V \tag{3}$$

onde $Q, K,$ e V são as matrizes de consulta, chave e valor derivadas do vetor de características, e d_k é o fator de escala.

Para capturar as dependências de longo alcance do tumor ósseo, adicionamos um bloco de codificador Transformer para processar o vetor de características extraído. O vetor de características é primeiro incorporado por meio de uma transformação de incorporação linear para projetá-lo em um espaço de dimensão superior.

$$F_{\text{incorporar}} = W_e F_{\text{brecha}} + b_e \tag{4}$$

onde W_e e b_e são parâmetros aprendíveis. Essa conversão permite a compatibilidade com o módulo Transformer ao inserir representações de características.

O codificador Transformer utiliza a Autoatenção Multi-Cabeças (MHSA) para aprender interdependências complexas entre diferentes elementos de características. mentos. O mecanismo de autoatenção funciona da seguinte maneira

$$\text{Atenção}(Q, K, V) = \text{softmax}\left(\frac{Q^T}{\sqrt{d_k}}\right) V \tag{5}$$

onde Q, K, V são as matrizes de consulta, chave e valor derivadas de $F_{\text{incorporar}}$, e d_k representa a dimensionalidade do espaço de características. O mecanismo de autoatenção permite que o modelo atribua pesos de importância diferentes a diferentes áreas espaciais no mapa de características de entrada e, assim, capture dependências de longo alcance de forma eficaz.

Após o MHSA, o codificador de transformador emprega uma Rede Feedforward (FFN) composta por duas camadas totalmente conectadas com ativação não linear.

$$F_{\text{trans}} = \text{ReLU}(W_1 F_{\text{incorporar}} + b_1) W_2 + b_2 \tag{6}$$

Este projeto aprimora a representação das características aprendidas, concentrando-se nos principais padrões estruturais e eliminando ruídos redundantes. A normalização de camadas é aplicada entre as camadas de alimentação direta e de atenção para permitir um treinamento estável e melhor convergência.

Ao integrar a extração de características locais baseada em CNN e a modelagem global baseada em Transformers, a estrutura proposta demonstra capacidade de representar com precisão informações espaciais e contextuais. Essa abordagem híbrida aprimora a classificação de diversos subtipos de tumores ósseos, como tumor de células gigantes, osteocondromas múltiplos, osteocondroma, osteofibroma, osteossarcoma, outros tumores benignos, outros tumores malignos, cisto ósseo simples e osteocondroma sinovial, garantindo diagnósticos médicos precisos.

A representação final do codificador Transformer é passada por uma camada totalmente conectada, seguida por uma função de ativação softmax para classificação multiclasse.

$$\hat{y} = \text{softmax}(W F_{\text{trans}} + b) \tag{7}$$

onde W e b são parâmetros a serem aprendidos, e $\hat{y}_i$ são as probabilidades de classe para diferentes tipos de tumor ósseo. Para melhorar o desempenho do modelo, utiliza-se a função de perda de entropia cruzada categórica.

$$L = -\sum_{i=1}^{N} y_i \log(\hat{y}_i) \tag{8}$$

onde N é o número de classes, que é 5. y_i é o rótulo da verdade fundamental, e $\hat{y}_i$ é a probabilidade prevista para cada classe. Essa função de perda específica incentiva a atribuição de altas probabilidades à classe correta e penaliza previsões incorretas. Estratégias de otimização baseadas em gradiente são utilizadas para treinar o modelo, permitindo o aprendizado eficaz da classificação precisa de nove tipos de tumores.

O processo de treinamento utiliza o otimizador Adam com uma taxa de aprendizado inicial de 10^{-4}, um tamanho de lote de 32 e parada antecipada baseada na perda de teste para evitar sobreajuste. O modelo é treinado por 60 épocas, com atualizações de peso realizadas por meio de retropropagação.

$$W \leftarrow W - \eta \nabla_W L \tag{9}$$

onde η representa a taxa de aprendizagem, e $\nabla_W L$ é o gradiente da perda função em relação aos parâmetros do modelo.

Técnicas de regularização, como dropout e decaimento de peso, são aplicadas para aprimorar a generalização e mitigar o sobreajuste. O dropout desativa aleatoriamente uma fração dos neurônios durante o treinamento, impedindo que eles se tornem repetitivos. Coadaptação de características. A regularização L2 (weight decay) desencoraja valores de peso elevados, adicionando um termo de penalização à função de perda.

O desempenho do modelo é monitorado continuamente por meio da acurácia e da perda de validação. Se a perda de validação estagnar ou aumentar ao longo de épocas sucessivas, a parada antecipada interrompe o treinamento, preservando os pesos com melhor desempenho. Essa estratégia garante que o modelo permaneça eficiente, evitando cálculos desnecessários e levando ao desempenho ideal.

classificação do tumor.

O modelo CNNT proposto é treinado por meio de um pipeline adequadamente projetado que integra a modelagem de características globais e locais. O extenso processo de treinamento é mostrado no Algoritmo.2.

Algoritmo 2 Treinamento de modelo CNN + Transformer para classificação de tumores ósseos

Requisitos: Conjunto de dados de imagens - com rótulos -, tamanho do lote B taxa de aprendizagem , número de épocas E

Requisitos: Número de camadas da CNN L ,neurônios da CNN N ,Trans-camadas anteriores L , número de cabeças H dimensão oculta D, número de classes N_c

Inicialização do modelo:
Defina as camadas da CNN com L blocos convolucionais, cada um com Conv2D, BatchNorm, ReLU e MaxPool
Aplicar o Pooling Médio Adaptativo ao tamanho de saída (8,8)
Defina a camada de incorporação para mapear a saída da CNN para D Espaço -dimensional
Construir um codificador Transformer com L camadas e H atenção cabeças
Definir classificador: Camada totalmente conectada com ativação Softmax
Inicializar o modelo HybridCNNTransformer -
Defina a função de perda e o otimizador:
Defina a função de perda como entropia cruzada categórica.
Use o otimizador Adam com taxa de aprendizado.
Treinamento do modelo:
para $epoc$ = 1 para E **fazer**
  Configurar modelo - para modo de treinamento
  Inicializar a perda de treinamento - =0, previsões corretas C =0 Iniciar cronômetro de treinamento
  para cada lote (X_b, $_b$) em - **fazer**
    Mover (X_b, $_b$) Para o dispositivo, os gradientes zero do otimizador calculam a saída do modelo: Y_b = -(X_b) Calcular perda: - = CrossEntropyLoss(Y_b, $_b$) Realizar retropropagação e atualizar os pesos. Acumular a perda de treinamento e corrigir as previsões. **fim para**
  Parar o cronômetro de treinamento
  Calcular a precisão do treinamento: Acc = × 100
  Avaliação do modelo:
  Configurar modelo - para o modo de avaliação
  Inicializar perda de teste - =0, previsões corretas C =0 Iniciar cronômetro de avaliação
  para cada lote (X_b, $_b$) em - **fazer**
    Mover (X_b, $_b$) Saída do modelo de computação do dispositivo: Y_b = -(X_b) Calcular perda: - = CrossEntropyLoss(Y_b, $_b$) Acumule perdas nos testes e corrija as previsões. **fim para**
  Interromper o cronômetro de avaliação
  Calcular a precisão do teste: Acc = × 100
  Imprimir resultados da época: Perda de treinamento, Precisão de treinamento, Tempo de treinamento, Perda de teste, Precisão de teste, Tempo de teste
fim para
Calcular acurácia, AUC-ROC, precisão, recall e pontuação F1. Outros parâmetros estatísticos.

Algoritmo2Este documento descreve o processo de treinamento do modelo CNNT. Ele envolve a inicialização do modelo com camadas CNN e Transformer, seguida de treinamento em mini-lotes usando a perda de entropia cruzada categórica. A propagação direta, o cálculo da perda, a retropropagação e as atualizações de pesos são realizadas em cada época. O desempenho é monitorado por meio da acurácia, AUC-ROC, pontuação F1 e outras métricas importantes. A avaliação é realizada após cada época usando dados de teste não vistos.

3.2. Modelo ResNet50 e Módulo de Atenção de Bloco Convolucional (CBAM)

O modelo proposto, ResNet50 e Módulo de Atenção de Bloco Convolucional (CBAM), foi projetado para aprimorar o desempenho da classificação de diversas imagens de tumores ósseos, integrando uma arquitetura ResNet50 pré-treinada e o CBAM. Essa integração melhora efetivamente a extração de características por meio de mecanismos de atenção espacial e de canal. O processo de treinamento segue uma estrutura sistemática, conforme descrito no algoritmo.3O modelo é desenvolvido para auxiliar na classificação de tumores ósseos, incluindo a inicialização, a seleção da função de perda, as etapas de otimização, o treinamento e, por fim, o teste. O modelo é inicializado carregando a ResNet50 com pesos pré-treinados, exceto pela última camada totalmente conectada. O módulo CBAM é então integrado para destacar as características mais discriminativas nas imagens por meio da ponderação adaptativa das representações de características espaciais e por canal. Esse mecanismo aprimora a capacidade do modelo de se concentrar em regiões discriminativas das imagens ósseas, o que é essencial para distinguir entre vários subtipos de tumores ósseos, como tumor de células gigantes, osteocondromas múltiplos, osteocondroma, osteofibroma, osteossarcoma, outros tumores benignos, outros tumores malignos, cisto ósseo simples e osteocondroma sinovial. Um classificador totalmente conectado é utilizado para melhorar a eficácia da classificação, incluindo normalização em lote, ativação ReLU, dropout e ativação softmax, garantindo assim um aprendizado eficaz e estável.

Para aprimorar o processo de treinamento, utiliza-se a perda de entropia cruzada categórica com suavização de rótulos, o que reduz o impacto de rótulos ruidosos e impede que o modelo demonstre excesso de confiança em suas previsões. O otimizador AdamW é utilizado devido à sua capacidade de otimizar paisagens de otimização complexas de forma eficiente, e um agendador de taxa de aprendizado (ReduceLROnPlateau) ajusta dinamicamente a taxa de aprendizado em função dos padrões observados na perda de teste para uma convergência estável e eficiente. O processo de treinamento envolve o processamento repetido de mini-lotes, a movimentação dos dados de imagem para a Unidade de Processamento Gráfico (GPU), a passagem pelo modelo ResNet50 CBAM e o cálculo da perda de classificação. Posteriormente, o método do gradiente descendente é utilizado para atualizar os parâmetros do modelo, permitindo uma melhoria contínua ao longo do tempo.Népocas (E). Após concluir o processo de treinamento, o modelo passa para a fase de avaliação, onde é testado em dados não vistos para analisar sua capacidade de generalização. O desempenho do modelo é avaliado usando uma variedade de métricas-chave, incluindo acurácia, AUC-ROC, precisão, recall e F1-score, para uma avaliação abrangente de seu desempenho de classificação.

Para aprimorar o aprendizado de características discriminativas, combinamos o CBAM com uma arquitetura ResNet50. O pipeline de treinamento completo do modelo ResNet50-CBAM é apresentado no Algoritmo.3.

Algoritmo3Este artigo resume o processo de treinamento do modelo ResNet50-CBAM. Ele envolve o carregamento dos pesos pré-treinados do ResNet50, a adição do CBAM, a inicialização do classificador e a otimização AdamW com diferentes taxas de aprendizado. O modelo é avaliado em amostras não vistas em cada época durante o treinamento, utilizando métricas de classificação e medidas estatísticas para avaliar a convergência e a generalização.

O núcleo do modelo é o ResNet-50 com CBAM, conforme mostrado emFigura 3, que é uma CNN profunda para extração de características na classificação robusta de tumores. Ela utiliza conexões residuais para evitar o desaparecimento de gradientes e aprimorar a propagação de características. Dada uma imagem de entrada , os mapas de recursos F_{res}são calculados como:

$$F_{res} = \text{ResNet50}(\ ) \tag{10}$$

Algoritmo 3 Treinamento do modelo ResNet50 + CBAM para classificação de tumores ósseos

Requisitos: Conjunto de dados de imagens - com rótulos -, tamanho do lote$B$taxa de aprendizagem , perda de peso , suavização de rótulos , número de épocas$E$ **Requisitos:** Número de turmasN_c, backbone ResNet50 pré-treinado, CBAM módulo de atenção

Inicialização do modelo:

Carregue a ResNet50 com pesos pré-treinados e remova completamente os pesos finais. camada conectada

Adicionar módulo de atenção CBAM para aprimorar os mapas de recursos.

Defina o classificador: Camadas totalmente conectadas com BatchNorm, ReLU, Dropout e Softmax

Inicializar modelo - com ResNet50 + CBAM

Defina a função de perda e o otimizador:

Defina a função de perda como entropia cruzada categórica com suavização de rótulos.

Use o otimizador AdamW com taxa de aprendizado e perda de peso

Defina o agendador de taxa de aprendizado: ReduceLROnPlateau

Treinamento do modelo:

para$epoc$=1para$E$**fazer**

Configurar modelo - para modo de treinamento

Inicializar a perda de treinamento - =0,previsões corretas$C$ =0, amostras totais$N$ =0

Iniciar cronômetro de treinamento

paracada lote (X_b, $_b$)em - **fazer**

Mover (X_b, $_b$)Para o dispositivo, os gradientes zero do otimizador calculam a saída do modelo:Y_b= -(X_b) Calcular perda: - = CrossEntropyLoss(Y_b, $_b$) Realizar retropropagação e atualizar os pesos. Acumular a perda de treinamento e corrigir as previsões. **fim para**

Parar o cronômetro de treinamento

Calcular a precisão do treinamento: Acc = × 100

Avaliação do modelo:

Configurar modelo - para o modo de avaliação

Inicializar perda de teste - =0,previsões corretas$C$ =0,amostras totais$N$ =0

Iniciar cronômetro de avaliação

paracada lote (X_b, $_b$)em - **fazer**

Mover (X_b, $_b$)Saída do modelo de computação do dispositivo:Y_b= -(X_b) Calcular perda: - = CrossEntropyLoss(Y_b, $_b$) Acumule perdas nos testes e corrija as previsões. **fim para**

Interromper o cronômetro de avaliação

Calcular a precisão do teste: Acc = × 100

Ajuste a taxa de aprendizado usando o agendador com base na perda de teste. Imprima os resultados da época: Perda de Treinamento, Precisão de Treinamento, Tempo de Treinamento, Perda de Teste, Precisão de Teste, Tempo de Teste.

fim para

Calcule a acurácia, AUC-ROC, precisão, recall e pontuação F1. Outros parâmetros estatísticos

onde$F_{res} \in \mathbb{R}^{H \times W \times C}$são mapas de características de altura$H$, largura$W$, e canais CAs características são ainda mais aprimoradas usando CBAM para uma atenção espacial e por canal mais forte, a fim de melhorar a precisão da classificação.

Para aprimorar ainda mais a capacidade discriminativa dos mapas de características extraídos do codificador, o Módulo de Atenção de Bloco Convolucional (CBAM) é incorporado ao modelo. O CBAM emprega mecanismos de atenção tanto de canal quanto espacial para focar em características essenciais, reduzindo a influência de informações irrelevantes.

Os mapas de características refinados, denominados como F_{cbam}, são calculados da seguinte forma:

$$F_{cbam} = F_{res} \cdot M_c(F_{res}) \cdot M_s(F_{res}) \quad (11)$$

onde:

- $M_c(F_{res})$Representa o mapa de atenção do canal, que atribui maior peso aos canais de características mais importantes. É calculado usando uma combinação de Pooling Médio Global (GAP) e Pooling Máximo Global (GMP), seguida por um perceptron multicamadas (MLP).
- $M_s(F_{res})$Representa o mapa de atenção espacial, que destaca regiões espaciais relevantes usando operações convolucionais e agrupamento em mapas de características.

Esse mecanismo de atenção dimensiona adaptativamente as representações de características, permitindo que o modelo se concentre em diversas imagens discriminativas de tumores ósseos, melhorando assim o desempenho da classificação.

O mecanismo de atenção de canal no CBAM realça as características de canal mais informativas realizando operações GAP e GMP. Essas operações agregam informações espaciais de todos os pixels em um mapa de características, capturando dependências contextuais globais. Seus resultados são encaminhados para o Perceptron Multicamadas (MLP) compartilhado, que aprende a importância de cada canal. Os resultados das duas operações de pooling são concatenados e encaminhados para uma função de ativação sigmoide para gerar o mapa de atenção de canal final.

$$M_c(F_{res}) = (\mathrm{MLP}(\mathrm{GAP}(F_{res})) + \mathrm{MLP}(\mathrm{MaxPool}(F_{res}))) \quad (12)$$

onde é a função de ativação sigmoide, que escala os valores de atenção entre 0 e 1. O mapa de atenção resultante é então normalizado em relação aos mapas de características originais. F_{res}, reponderando a contribuição de cada canal para destacar características discriminativas na classificação de tumores.

O mecanismo de atenção espacial aprimora a detecção de localizações de características significativas dentro de um espaço. Ele aplica funções de pooling médio e pooling máximo ao longo da dimensão do canal, extraindo assim características dominantes e sutis. Os mapas de características resultantes do pooling são concatenados e então alimentados em uma camada convolucional com 7×O tamanho do kernel é definido em 7 para permitir que a rede aprenda a significância espacial adequadamente. O mapa de atenção espacial final é obtido usando uma função de ativação sigmoide.

$$M_s(F_{res}) = \mathrm{Conv}(\mathrm{AvgPool}(F_{res}); \mathrm{MaxPool}(F_{res})) \quad (13)$$

onde Conv denota a operação de convolução e [;] denota concatenação. O mecanismo de atenção espacial permite que o modelo se concentre em áreas auriculares informativas, suprimindo assim o ruído de fundo e aumentando a robustez da classificação. Através do uso sequencial de atenção espacial e de canal, o CBAM aprimora efetivamente a representação de características, resultando em melhor desempenho na detecção de tumores.

Após o refinamento da atenção, os mapas de características passam pelo GAP para reduzir suas dimensões espaciais, preservando informações valiosas. Esse processo resulta em um vetor descritor global. F_{brecha}, que representa as características mais proeminentes extraídas dos mapas de características aprimorados pelo CBAM:

$$F_{brecha} = \mathrm{GAP}(F_{cbam}) \quad (14)$$

onde $F_{brecha} \in \mathbb{R}^C$é uma representação compacta com CO GAP utiliza canais de características, tornando-o computacionalmente eficiente e, ao mesmo tempo, mantendo uma forte agregação de características. Ele reduz efetivamente o sobreajuste, eliminando a redundância espacial sem perder informações globais essenciais.

Para fins de classificação, F_{brecha}é passado por uma camada totalmente conectada (FC) com parâmetros treináveis, incluindo o peso. We preconceito b, seguida por uma função de ativação softmax para obter as probabilidades de classe:

$$\hat{y} = \mathrm{softmax}(W F_{brecha} + b) \quad (15)$$

onde $\hat{y}$representa as probabilidades de classe previstas. A função softmax garante que as saídas somem 1, permitindo a interpretação probabilística para classificação multiclasse. Essa abordagem aprimora o modelo de classificação de tumores, tornando-o preciso e eficiente.

O modelo é treinado usando a função de perda de entropia cruzada categórica, que mede a diferença entre os rótulos verdadeiros. e as probabilidades previstas $\hat{y}$:

$$L = -\sum_{=1}^{5} \mathrm{registro}(\hat{y}) \quad (16)$$

onde LA função de perda garante que o modelo aprenda a minimizar os erros de classificação, ao mesmo tempo que melhora as previsões de probabilidade de classe. O otimizador Adam é empregado para a otimização do modelo com uma taxa de aprendizado inicial de 0,0001, que equilibra convergência rápida e estabilidade. O treinamento é realizado com um tamanho de lote de 32, o que é eficiente em termos de memória e estável na atualização do gradiente. A parada antecipada é aplicada à perda de teste para evitar sobreajuste e melhorar a generalização. A retropropagação calcula os gradientes da função de perda em relação aos parâmetros do modelo durante o treinamento. Esses gradientes são usados para atualizar os pesos. We preconceitos b Com base na regra de otimização Adam, o modelo aprimora a extração de características e o desempenho da classificação. O processo é repetido até que a convergência ou as condições de parada sejam atendidas, garantindo o desempenho ideal do modelo.

4. Resultados e discussão

Cada modelo é treinado usando 5421 amostras de dados para treinamento, enquanto 1356 amostras são utilizadas para teste. O desempenho
A eficácia do esquema proposto e das metodologias de referência é avaliada por meio de uma explicação detalhada da matriz de confusão para cada estratégia. Diversas métricas são empregadas para avaliar a eficácia do modelo na classificação de tumores. Acurácia, precisão, recall e F1-score são utilizados em uma medida equilibrada de falsos positivos e falsos negativos. A medida AUC-ROC avalia a capacidade do modelo de distinguir entre classes, fornecendo assim informações sobre sua eficácia discriminatória. O Coeficiente de Correlação de Matthews (MCC) e o Kappa de Cohen também são empregados para avaliar a confiabilidade da classificação, particularmente em conjuntos de dados desbalanceados. A combinação das métricas avalia de forma abrangente o desempenho do modelo em diversas categorias de deformidades.

4.1. Modelo de Redes Neurais Convolucionais Transformer (CNNT)

O modelo CNNT é altamente eficiente na classificação, como demonstrado na matriz de confusão emFigura 4O modelo apresenta uma classificação praticamente perfeita de Tumor de Células Gigantes (99,33%), Osteofibroma (99,36%) e Osteocondroma Sinovial (100%), refletindo um nível extremamente alto de precisão na detecção dessas formas específicas de tumor com erro mínimo ou nulo. Mesmo com esse desempenho notável, algumas categorias de tumor apresentam classificação incorreta devido a semelhanças em suas características. Por exemplo, o Osteocondroma foi classificado erroneamente como Osteocondromas Múltiplos em 3,21% dos casos e Osteossarcoma em 5,13%, o que implica em características estruturais ou morfológicas semelhantes entre essas classes. Da mesma forma, os Osteocondromas Múltiplos apresentam uma taxa de classificação incorreta de 8,70% como Osteocondroma, refletindo a dificuldade em diferenciar essas categorias semelhantes. Um problema semelhante foi relatado no Osteossarcoma, em que 9,63% dos casos foram classificados erroneamente como Osteocondroma. Da mesma forma, o Cisto Ósseo Simples apresenta uma taxa de classificação incorreta como Osteocondroma de 7,79%, indicando a possibilidade de sobreposição de características que requerem ajustes. Essas classificações incorretas indicam que os mecanismos de extração e representação de características precisam ser otimizados para melhorar a separabilidade entre as classes.

O relatório de classificação emTabela 1O modelo CNNT demonstra desempenho exemplar nas classes de tumores ósseos, com alta precisão, recall, pontuação F1 e especificidade. O osteocondroma sinovial é classificado de forma ideal, com todas as métricas em 1 e sem falsos negativos ou positivos. O osteofibroma também é bem classificado em termos de precisão, recall e pontuação F1.

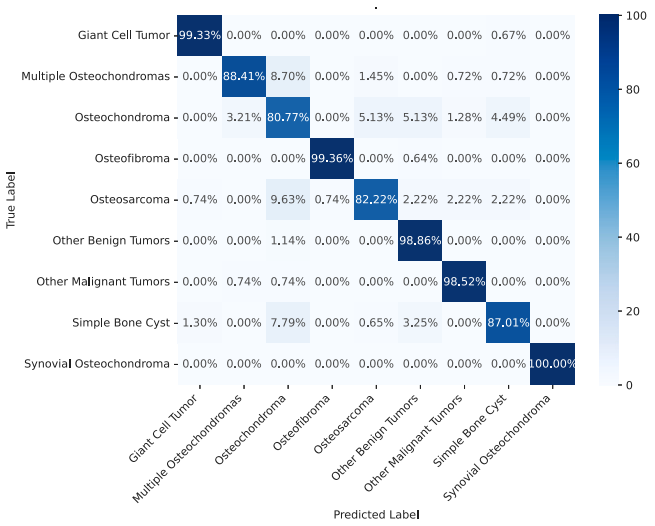

Figura 4. Matriz de confusão do modelo CNNT.

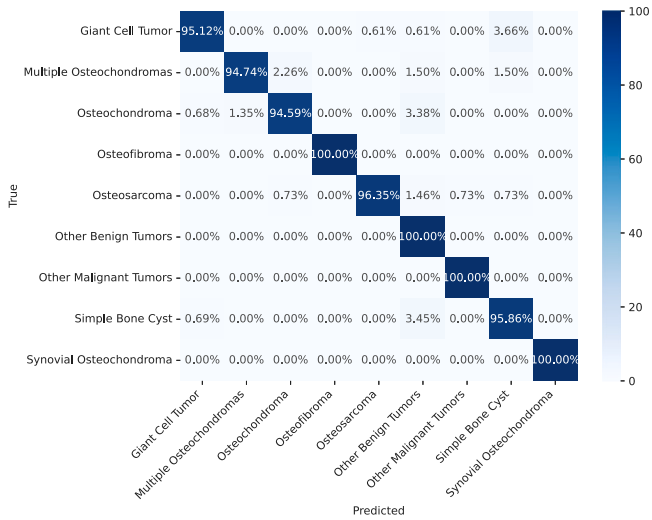

Figura 5. Matriz de confusão do modelo Resnet50 CBAM.

Tabela 1
Relatório de classificação do modelo CNNT.

Aula	Precisão	Lembrar	Pontuação F1	Especificidade
tumor de células gigantes	0,9801	0,9933	0,9867	0,9975
Osteocondromas múltiplos	0,9531	0,8841	0,9173	0,9951
Osteocondroma	0,7590	0,8077	0,7826	0,9667
Osteofibroma	0,9936	0,9936	0,9936	0,9992
Osteossarcoma	0,9098	0,8222	0,8638	0,9910
Outros tumores benignos	0,9110	0,9886	0,9482	0,9856
Outros tumores malignos	0,9568	0,9852	0,9708	0,9951
cisto ósseo simples	0,9178	0,8701	0,8933	0,9900
Osteocondroma sinovial	1,0000	1,0000	1,0000	1,0000

com 0,9936 e especificidade próxima da perfeita, em 0,9992, o que reflete uma identificação precisa.

O tumor de células gigantes apresenta uma acurácia de classificação perfeita de 0,9801, recall de 0,9933 e pontuação F1 de 0,9867, indicando boa confiabilidade. Sua especificidade de 0,9975 demonstra sua capacidade de reduzir erros de classificação. O osteocondroma representa um desafio, como evidenciado pela baixa pontuação F1 (0,7826) em relação à precisão (0,7590) e ao recall (0,8077). Uma especificidade de 0,9667 significa que, embora o modelo classifique corretamente os casos que não são osteocondromas, há erros de classificação, particularmente com osteocondromas múltiplos e osteossarcoma, devido a características compartilhadas. O osteossarcoma é classificado incorretamente com uma pontuação F1 de 0,8638, precisão de 0,9098 e recall de 0,8222, indicando erros de classificação com outros tumores do mesmo tipo. Outras categorias de tumores, incluindo Outros Tumores Benignos (F1-score de 0,9482), Outros Tumores Malignos (F1-score de 0,9708) e Cisto Ósseo Simples (F1-score de 0,8933), mantêm resultados de classificação sólidos, com precisão e recall consistentemente superiores a 0,87, reforçando a robustez do modelo em diversos tipos de tumores.

4.2. Re sNet50 e Convol ucional Bl ock Atenti sobre Modelo de módulo (CBAM)

O ResNet50- CBJM model co nfusi sobre matri x emFigura 5Indica as classes excelente t cl ussifi gadon capabil idade a cruz s diferentes de tumores ósseos. O com oi muito preciso favorito rable rate a para a maioria dos cl modelo pode apresentar cura eficaz ely classificar tu mor tipos com h mais de 94% ac na maioria dos casos, com m miscla animal ssification. Osteofibro ma, O incluindo tumores benignos. Outros malignos Tumou, e S ynovOsteochon ial droma são precisos etiquetado com 100 % ac curadoria, i. e., the modelo iden identifica todas as instâncias dessas classes sses com sem falsos negativosativo s ou falso pontos positivos. Para a Giant Tumor celular ou, o modele é 95,tu% a te w com v baixíssima classificação incorreta- ção 0,6 1% com Osteosarcoma e Outros er Benign Tumores e ligeiramente maior, com 3,66% de classificação incorreta com Simp le Bum Cisto.

No entanto, a classificação de Osteocondromas Múltiplos apresenta uma acurácia de 94,74%, com 2,26% de classificações incorretas como Osteocondroma e 1,50% como Outros Tumores Benignos ou Cisto Ósseo Simples. Essas pequenas porcentagens de classificação incorreta podem ser explicadas pela similaridade na representação das características desses tumores. O Osteocondroma é classificado corretamente em 94,59% dos casos, com uma taxa de classificação incorreta muito baixa: 1,35% como Osteocondromas Múltiplos e 3,38% como Outros Tumores Benignos, demonstrando que o modelo pode ser aprimorado com ajustes adicionais para diferenciar melhor essas classes. O Osteossarcoma é classificado corretamente em 96,35% dos casos e classificado incorretamente como Osteocondroma e Outros Tumores Malignos em 0,73%, apresentando uma sobreposição mínima nas representações aprendidas. O cisto ósseo simples é diagnosticado com 95,86% de precisão, com 3,45% de diagnósticos errôneos como outros tumores benignos, o que pode ser explicado por características morfológicas semelhantes.

O relatório de classificação do modelo ResNet50-CBAM emTabela 2Apresenta melhor desempenho na classificação de tumores ósseos, com alta precisão, sensibilidade, pontuação F1 e especificidade. A alta confiabilidade, especialmente para tumores com tipos bem definidos, é indicada pelos resultados com mínimas classificações incorretas.

Osteofibroma e osteocondroma sinovial são classificados com precisão completa pelo modelo, com todas as pontuações iguais a 1, o que significa que não há erros. Outros tumores malignos também apresentam desempenho quase perfeito: precisão de 0,9936, recall de 1 e pontuação F1 de 0,9968, demonstrando o bom desempenho do modelo na detecção de casos malignos. O modelo para osteossarcoma apresenta uma pontuação F1 de 0,9778, com precisão de 0,9925 e recall de 0,9635, o que significa classificação altamente precisa com mínima classificação incorreta. Uma especificidade de 0,9992 também evidencia sua capacidade de classificar com precisão tumores não osteossarcomas.

O Tumor de Células Gigantes apresenta um escore F1 de 0,9689, precisão de 0,9873 e recall de 0,9512, o que indica potencial para melhoria do recall para uma identificação mais precisa dos casos reais. Osteocondromas Múltiplos apresentam um escore F1 de 0,9655, precisão de 0,9844 e recall de 0,9474, o que indica alta acurácia, mas com pequenos problemas de recall. O osteocondroma é classificado com um escore F1 de 0,9589, precisão de 0,9722 e recall de 0,9459. No entanto, uma alta especificidade de 0,9967 significa que o modelo consegue separar bem os casos que não são osteocondromas. Outros Tumores Benignos também apresentam um recall perfeito (1), mas uma precisão menor (0,9138) e, portanto, um escore F1 de 0,9550. O diagnóstico de Cisto Ósseo Simples apresentou uma pontuação F1 de 0,9488, precisão de 0,9392 e sensibilidade de 0,9586, indicando uma boa classificação, porém com um leve viés de falsos positivos. Uma especificidade de 0,9926 significa que o modelo consegue identificar os casos de Cisto Ósseo que não são simples.

4.3. Análise comparativa

Para avaliar o impacto das técnicas de pré-processamento implementadas, comparamos o desempenho dos modelos propostos antes do processamento.

Tabela 2
Relatório de classificação do modelo Resnet50 CBAM.

Aula	Precisão	Lembrar	Pontuação F1	Especificidade
tumor de células gigantes	0,9873	0,9512	0,9689	0,9983
Osteocondromas múltiplos	0,9844	0,9474	0,9655	0,9984
Osteocondroma	0,9722	0,9459	0,9589	0,9967
Osteofibroma	1,0000	1,0000	1,0000	1,0000
Osteossarcoma	0,9925	0,9635	0,9778	0,9992
Outros tumores benignos	0,9138	1,0000	0,9550	0,9875
Outros tumores malignos	0,9936	1,0000	0,9968	0,9992
cisto ósseo simples	0,9392	0,9586	0,9488	0,9926
Osteocondroma sinovial	1,0000	1,0000	1,0000	1,0000

e após a aplicação de redução de ruído nos dados, balanceamento de classes e aumento de dados, conforme mostrado emTabela 3Os resultados demonstram uma melhoria substancial na precisão e acurácia do modelo após essas etapas, ressaltando assim o papel crucial do pré-processamento no aprimoramento do treinamento do modelo e no desempenho preditivo geral.

A combinação do Módulo de Atenção de Bloco Convolucional (CBAM) com a ResNet50 melhorou significativamente o poder de discriminação do modelo, elevando a acurácia geral de 83,44% para 97,41%. Métricas de desempenho do modelo base ResNet50 emTabela 4Os tumores apresentam variações notáveis entre os diferentes tipos. O CBAM foi capaz de destacar características espaciais e específicas de canal dominantes, resultando em melhorias significativas na precisão, na revocação e na pontuação F1 para todos os tipos de tumores. Categorias que anteriormente apresentavam desempenho moderado, como osteocondroma e osteossarcoma, exibiram melhorias consideráveis na revocação e na pontuação F1. Esses resultados validam o uso de mecanismos de atenção, como o CBAM, para aprimorar drasticamente a localização de características e a separação entre classes, especialmente em problemas complexos de classificação biomédica, justificando, assim, sua inclusão na estrutura proposta.

O modelo ResNet50-CBAM demonstra maior precisão de classificação em todos os tipos de tumor em comparação com o modelo CNN Transformer.Figura 6 Embora ambos os métodos sejam quase perfeitos para osteofibroma e osteocondroma sinovial, o modelo ResNet50-CBAM é mais preciso em categorias mais complexas, como tumor de células gigantes, osteocondroma e osteocondromas múltiplos, reduzindo eficientemente as taxas de classificação incorreta. A maior melhoria na precisão é observada em outros tumores benignos e cisto ósseo simples, o que demonstra a alta capacidade de extração de características e atenção do ResNet50-CBAM.

Os valores de AUC-ROC indicam que o ResNet50-CBAM é consistentemente melhor que o modelo CNNT para a maioria dos tipos de tumor, demonstrando maior poder discriminatório emTabela 5Embora a CNNT apresente pontuação superior para Tumor de Células Gigantes (0,995 vs. 0,975), a ResNet50-CBAM demonstra melhor desempenho na classificação de Osteocondroma (0,971 vs. 0,887), Osteossarcoma (0,981 vs. 0,907) e Cisto Ósseo Simples (0,976 vs. 0,930), indicando sua maior robustez na distinção de casos complexos. Ambos os modelos apresentam classificação perfeita (AUC-ROC = 1,000) para Osteofibroma, Outros Tumores Malignos e Osteocondroma Sinovial, comprovando sua alta confiabilidade nessas classes.

Estatística Kappa de Cohen ( ) foi introduzido por JA Cohen [30] em psicologia para medir a concordância entre dois juízes. Tem sido amplamente utilizado como medida de desempenho em questões de classificação [31] ao longo dos anos. Kappa de Cohen (O coeficiente Kappa de Cohen estima a concordância entre os rótulos previstos e os reais, corrigindo a concordância por acaso. Essa é uma medida mais significativa do que as medidas de acurácia. A fórmula do Kappa de Cohen é

$$= \frac{P_o - P_e}{1 - P_e} \tag{17}$$

onde$P_o$representa a concordância observada e$P_e$denota a concordância esperada por acaso. Essa métrica tem sido amplamente utilizada para avaliar o desempenho de classificadores em diversos estudos.

O MCC [32O MCC é outra medida robusta para validar modelos de classificação, especialmente para conjuntos de dados desbalanceados. Ao contrário da acurácia, o MCC considera verdadeiros positivos e verdadeiros negativos, bem como falsos positivos e falsos negativos. falsos negativos. A fórmula do MCC a ser usada no cálculo é expressa como:

$$MCC = \sqrt{\frac{(TP \times TN) - (FP \times FN)}{(TP+FP)(TP+FN)(TN+FP)(TN+FN)}} \tag{18}$$

A comparação estatística destaca a maior eficácia do ResNet50-CBAM em relação ao modelo CNNT em termos de concordância e confiabilidade da classificação.Tabela 6O coeficiente Kappa de Cohen (0,9718 vs. 0,9203) e o MCC (0,9719 vs. 0,9204) indicam que a ResNet50-CBAM oferece melhor confiabilidade interavaliadores e estabilidade de classificação. Além disso, a ResNet50-CBAM reduz substancialmente o tempo de treinamento (2993,63 s vs. 5692,64 s), melhorando assim a eficiência computacional e mantendo os tempos de teste iguais. Esses resultados comprovam a capacidade da ResNet50-CBAM de oferecer desempenho de classificação eficiente e preciso.

Vale ressaltar que a comparação realizada emTabela 7é conduzido em um contexto de classificação binária, especificamente para diferenciar entre tumores benignos e tumores malignos. Esse cenário está alinhado com os modelos empregados por outros estudos de pesquisa existentes, como o uso de arquiteturas CNN como ResNet50, Inception v3 e variantes do EfficientNet [10], bem como YOLOv8s-cls [1] e modelos híbridos como CNN + Desvio Padrão dos Intervalos NN (SDNN) [33] e DS-Net [12Nesse cenário binário, nosso modelo CNNT proposto e o ResNet50 combinado com CBAM (ResNet50+CBAM) superam claramente os demais. O modelo ResNet50+CBAM alcança uma acurácia de 100,00%, uma revocação de 1,0000 e uma pontuação F1 de 0,9759, com precisão (0,9537) e especificidade (0,9933) admiráveis, deixando assim os concorrentes seguintes para trás. Da mesma forma, o modelo CNNT demonstrou uma acurácia de 98,54%, o que indica a força e a estabilidade de nossos métodos em comparação com métodos convencionais como CNN (ResNet50), CNN EfficientNet versão B3 (EfficientNet-b3), YOLOv8s-cls [1], DS-Net [12], e outros.

Embora os resultados mostrados emTabela 7Embora nosso foco seja a classificação binária como referência, observe que os modelos que construímos foram aplicados e testados em um problema de classificação multiclasse mais geral, que inclui nove tipos diferentes de tumores ósseos. Os resultados gerais e as métricas de avaliação relevantes para o contexto multiclasse são apresentados em outras seções do manuscrito, na forma de tabelas e figuras específicas.

4.4. Análise qualitativa utilizando o grad-CAM

Para obter uma melhor compreensão do processo de tomada de decisão selecionado pelos modelos de aprendizado profundo, incorporamos visualizações de Mapeamento de Ativação de Classe Ponderado por Gradiente (Grad-CAM), conforme ilustrado emFigura 7A Figura a mostra a amostra original de imagens radiográficas para cada classe de tumor ósseo. A Figura b mostra os mapas de calor Grad CAM correspondentes, produzidos pelo modelo CNNT. Em contraste, a Figura c mostra os resultados do Grad CAM derivados do modelo ResNet50-CBAM. O Grad CAM é uma técnica interpretativa eficaz que anota as localizações espaciais da imagem de entrada com o impacto mais significativo nas previsões do modelo. Ao calcular o gradiente da pontuação da classe alvo em relação à camada convolucional final, o Grad CAM gera mapas de localização específicos da classe que representam visualmente onde o modelo está focando ao fazer previsões. Áreas mais quentes (por exemplo, vermelho e amarelo) nessas visualizações indicam maior associação com a tarefa de classificação, e áreas mais frias (ou seja, azul) indicam menor associação.

O desempenho dessa visualização demonstra que a ResNet50 aprimorada por CBAM sempre direciona a atenção de forma mais precisa e intensa para regiões anatômicas de interesse em tumores do que o modelo CNNT.
que ocasionalmente direciona a atenção para coisas irrelevantes e estranhas estruturas de fundo. Essa atenção direcionada exibida pelo modelo aumentado se deve aos seus mecanismos de atenção espacial e de canal, que ajustam sistematicamente as respostas das características e aprimoram a interpretabilidade [42Essa capacidade aumentada está de acordo com as descobertas de pesquisas anteriores, onde arquiteturas com mecanismos de atenção incorporados aprimoraram tanto o desempenho quanto a transparência clínica em tarefas de imagem médica [43].

Tabela 3
Comparação de desempenho dos modelos ResNet50-CBAM e CNNT antes e depois do pré-processamento.

Aula	ResNet50-CBAM (Antes)				ResNet50-CBAM (Após)				CNNT (Antes)				CNNT (Após)			
	Prec.	Rec.	F1	Especificação.	Prec.	Rec.	F1	Especificação.	Prec.	Rec.	F1	Especificação.	Prec.	Rec.	F1	Especificação.
tumor de células gigantes	0,6812	0,6523	0,6623	0,8111	0,9873	0,9512	0,9689	0,9983	0,6328	0,6145	0,6212	0,7915	0,9801	0,9933	0,9867	0,9975
Osteocondromas múltiplos	0,8216	0,7812	0,8018	0,8422	0,9844	0,9474	0,9655	0,9984	0,8025	0,7625	0,7831	0,8311	0,9531	0,8841	0,9173	0,9951
Osteocondroma	0,8311	0,8532	0,8411	0,7932	0,9722	0,9459	0,9589	0,9967	0,8045	0,8423	0,8265	0,7712	0,7590	0,8077	0,7826	0,9667
Osteofibroma	1,0000	1,0000	1,0000	0,6825	0,6612	0,6727	0,8022	0,9936	0,9936	0,9936	0,9992	0,8015	0,8217	0,8116	0,8317	0,9925
Osteossarcoma	0,7427	0,8122	0,9098	0,8222	0,8638	0,9910	0,6525	0,6310	0,6422	0,8511	0,9138	1,0000	0,9550	0,9875	0,6012	0,6111
Outros tumores benignos	0,6012	0,7119	0,9110	0,9886	0,9482	0,9856	0,7013	0,6815	0,6916	0,8616	0,9936	1,0000	0,9968	0,9992	0,6517	0,6317
Outros tumores malignos	0,6418	0,8118	0,9568	0,9852	0,9708	0,9951	0,7617	0,7917	0,7718	0,8017	0,9392	0,9586	0,9488	0,9926	0,7214	0,7522
cisto ósseo simples	0,7312	0,7712	0,9178	0,8701	0,8933	0,9900										
Osteocondroma sinovial	0,8512	0,8215	0,8315	0,8515	1,0000	1,0000	1,0000	1,0000	0,7812	0,7614	0,7715	0,8015	1,0000	1,0000	1,0000	1,0000

Tabela 4
Comparação do desempenho de classificação entre a ResNet50 de base e a ResNet50 com CBAM em diferentes classes de tumores.

Aula	ResNet50 de referência				ResNet50 + CBAM			
	Precisão	Lembrar	Pontuação F1	Especificidade	Precisão	Lembrar	Pontuação F1	Especificidade
tumor de células gigantes	0,8155	0,9257	0,8671	0,9743	0,9873	0,9512	0,9689	0,9983
Osteocondromas múltiplos	0,8000	0,7582	0,7785	0,9759	0,9844	0,9474	0,9655	0,9984
Osteocondroma	0,5745	0,7826	0,6626	0,9343	0,9722	0,9459	0,9589	0,9967
Osteofibroma	0,9321	0,9742	0,9527	0,9908	1,0000	1,0000	1,0000	1,0000
Osteossarcoma	0,9505	0,5749	0,7164	0,9958	0,9925	0,9635	0,9778	0,9992
Outros tumores benignos	0,9115	0,6478	0,7574	0,9916	0,9138	1,0000	0,9550	0,9875
Outros tumores malignos	0,9635	0,9429	0,9531	0,9959	0,9936	1,0000	0,9968	0,9992
cisto ósseo simples	0,7021	0,9362	0,8024	0,9539	0,9392	0,9586	0,9488	0,9926
Osteocondroma sinovial	0,9870	0,9806	0,9838	0,9983	1,0000	1,0000	1,0000	1,0000

Tabela 5
Pontuações AUC-ROC por classe em diferentes modelos.

Aula	ResNet50-CBAM	CNNT
tumor de células gigantes	0,975	0,995
Osteocondromas múltiplos	0,973	0,940
Osteocondroma	0,971	0,887
Osteofibroma	1.000	0,996
Osteossarcoma	0,981	0,907
Outros tumores benignos	0,994	0,987
Outros tumores malignos	1.000	0,990
cisto ósseo simples	0,976	0,930
Osteocondroma sinovial	1.000	1.000

Tabela 6
Comparação do coeficiente Kappa de Cohen e do MCC em diferentes modelos.

Modelo	Cohen's Pontuação Kappa	MCC pontuação	Treinamento tempo (s)	Testando tempo (s)
ResNet50-CBAM	0,9718	0,9719	2993,63	432,40
CNNT	0,9203	0,9204	5692,64	355,58

4.5. Análise de sensibilidade em relação às mudanças na distribuição do conjunto de dados

Para determinar o efeito das variações na distribuição dos dados, realizamos análises por centro, replicando a variação do mundo real entre diferentes centros de dados (Centro 1, Centro 2 e Centro 3) na generalização do modelo. A perda de teste entre centros indica a diversidade dos conjuntos de dados. O ResNet50-CBAM mostrou-se mais generalizável e estável entre os centros devido aos seus mecanismos de atenção, que acomodam efetivamente a variação entre centros, conforme demonstrado em [referência].Tabela 8.

Essa comparação foi necessária devido à heterogeneidade intrínseca dos dados entre os diferentes centros, sendo que o Centro 1 possui uma gama consideravelmente mais ampla e distribuída de tumores do que os Centros 2 e 3. Por exemplo, classificações de tumores raros, como osteofibroma e osteocondroma sinovial, não estão representadas ou estão sub-representadas nos Centros 2 e 3. Tal viés causa desequilíbrios na distribuição que impactariam negativamente o desempenho do modelo, particularmente quando modelos treinados com dados de um centro são aplicados aos dados de outro centro.

Nossos resultados experimentais reforçam ainda mais a importância da heterogeneidade dos dados entre os centros. Em particular, tanto os modelos CNNT quanto os ResNet50-CBAM demonstraram desempenho inferior quando treinados com dados de um único centro e testados com dados de outros centros. Essa queda foi especialmente drástica quando os modelos treinados com dados do Centro 1 foram testados nos Centros 2 e 3. A diminuição observada no desempenho pode ser explicada por mudanças na distribuição dos dados e pela fraca representação de certas classes de tumores nos Centros 2 e 3. Por outro lado, os modelos treinados e testados no Centro 1 obtiveram acurácia e pontuação F1 relativamente melhores, provavelmente devido ao maior tamanho da amostra e à melhor distribuição dos tipos de tumor nesse centro.

Para aprimorar a generalização do modelo, poderíamos treiná-lo ainda mais com a união dos dados dos três centros (Centros 1+2+3). Quando testado separadamente em cada centro, isso levou a uma melhoria substancial nas principais métricas, como acurácia, pontuação F1 e especificidade. O ResNet50-CBAM sempre apresentou melhor desempenho que o CNNT em todos os testes entre centros, sendo mais estável em relação às variações na distribuição dos dados e mais capaz de generalizar entre diferentes fontes de dados clínicos do que os modelos com os quais experimentamos. Esses resultados são consistentes com os resultados de pesquisas anteriores. Por exemplo, [44], recomendou fortemente a avaliação de modelos de aprendizado profundo em condições de heterogeneidade de dados em imagens médicas, especialmente se os dados forem provenientes de múltiplas instituições. No entanto, [45] também demonstraram como o uso de amostras de diversos domínios durante o treinamento melhora significativamente a generalização e a estabilidade do modelo em situações de mudança de domínio para tarefas de diagnóstico médico.

5. Conclusão e trabalhos futuros

Este artigo apresenta um modelo de aprendizado profundo aprofundado para a classificação de nove subtipos significativos de tumores ósseos a partir de imagens radiográficas. Baseado na aplicação de uma arquitetura híbrida de CNN e Transformer (CNNT) e uma arquitetura ResNet50 aprimorada com um Módulo de Atenção de Bloco Convolucional (CBAM), os modelos propostos demonstram melhorias consideráveis na representação de características, acompanhadas por um aumento na precisão da classificação. A aplicação de métodos de redução de ruído BM3D e o balanceamento de dados com o auxílio do SMOTE contribuem ainda mais para a qualidade e resiliência do treinamento. Avaliações empíricas indicam que nossos modelos superam os modelos de última geração existentes, como YOLOv8s-cls, EfficientNet e DS-Net, em todos os principais aspectos.

Tabela 7
Comparação de desempenho com modelos existentes.

Método	Precisão	Precisão	Recordação/Sensibilidade	Pontuação F1	Especificidade
Modelo CNNT (Proposto)	**98,54%**	**0,9339**	**0,9869**	**0,9595**	**0,9595**
Modelo ResNet50 + CBAM (Proposto)	**100,00%**	**0,9537**	**1,0000**	**0,9759**	**0,9933**
CNN (ResNet50) [10] CNN (Inception v3) [	81,0%±4.6	0,76–0,80	0,74–0,78	0,75–0,80	0,86–0,89
10] CNN (EfficientNet-b1) [10] CNN	82,1%±2.9	0,77–0,81	0,76–0,79	0,76–0,78	0,87–0,89
(EfficientNet-b2) [10] CNN (EfficientNet-	83,5%±5.4	0,79–0,83	0,77–0,81	0,78–0,80	0,88–0,90
b3) [10] YOLOv8s-cls [1CNN [34]	85,3%±5.0	0,82–0,85	0,80–0,84	0,81–0,83	0,89–0,92
	84,2%±4.0	0,81–0,84	0,78–0,81	0,79–0,81	0,88–0,90
	~93,2%	~0,80–0,83	~0,85–0,88	~0,82–0,85	~0,89–0,91
	~73,4%	~0,68–0,72	~0,70–0,74	~0,70–0,73	~0,80–0,83
Rede UNet multisegmentada [	~97,8%	~0,93–0,95	~0,96–0,98	~0,94–0,96	~0,98–0,99
11] VGG-16 [7]	~0,82–0,83	~0,77–0,80	0,8688	0,908	~0,79–0,82
DNN [35]	~81,0%	~0,75–0,78	~0,77–0,80	~0,76–0,79	~0,84–0,87
EfficientNet [11	~76,0%	~0,70–0,73	0,79	~0,73–0,75	0,75
CNN [36]	97,38%	0,969	0,974	0,970	0,968
CNN + SDNN [33]	~95,0%	~0,91–0,94	0,9317	~0,92–0,93	0,961
CLSTM [37]	~81,0%	~0,76–0,79	~0,74–0,78	~0,75–0,78	~0,85–0,88
CNN [38]	92,20%	~0,88–0,90	~0,91–0,93	0,923	~0,91–0,93
DS-Net [12]	95,10%	0,929	0,920	0,922	0,961
CNN [39]	92,40%	0,970	0,940	0,950	~0,91–0,93
CNN [12]	91,20%	~0,89–0,91	~0,87–0,90	~0,88–0,90	~0,90–0,92
ANN [40]	80,00%	~0,70–0,73	0,75	~0,72–0,74	~0,82–0,85
EfficientNetB7 [41]	62,77%	0,2554	0,2554	~0,25–0,28	~0,55–0,60
InceptionResNetV2 [41]	93,29%	0,8658	0,8658	~0,86–0,87	~0,88–0,90
NasNetLarge [41] CNN	90,91%	0,8182	0,8182	~0,81–0,82	~0,87–0,89
(ResNet50) [41]	89,83%	0,7991	0,7992	~0,79–0,80	~0,85–0,88

Tabela 8
Análise de sensibilidade sob divisões do conjunto de dados por centro, mostrando o desempenho do modelo e a eficiência da inferência.

Modelo	Centro ferroviário	Centro de testes	Precisão (%)	Pontuação F1	Precisão	Lembrar	Especificidade
Resnet50 CBAM	Centralizar tudo	Centralizar tudo	97,41	0,9857	0,9760	0,9741	0,9969
Resnet50 CBAM	Centro 1	Centro 1	94,80	0,9480	0,9501	0,9472	0,9893
Resnet50 CBAM	Centro 1	Centro 2	84,60	0,8234	0,8120	0,8155	0,8741
Resnet50 CBAM	Centro 1	Centro 3	89,75	0,8720	0,8652	0,8611	0,9185
CNNT	Centro Tudo	Centro Tudo	92,56	0,9285	0,9313	0,9249	0,9911
CNNT	Centro 1	Centro 1	89,15	0,8923	0,8872	0,8851	0,9764
CNNT	Centro 1	Centro 2	76,80	0,7345	0,7120	0,7060	0,8105
CNNT	Centro 1	Centro 3	84,30	0,8134	0,8021	0,8012	0,8592

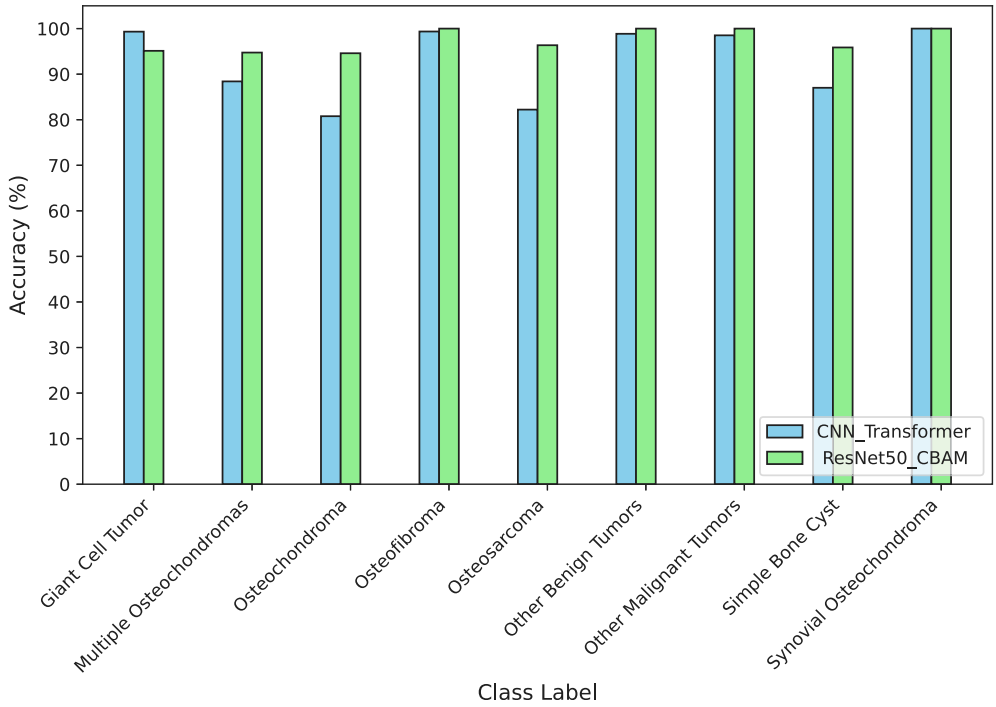

Figura 6. Precisão do modelo em diferentes classes sim.

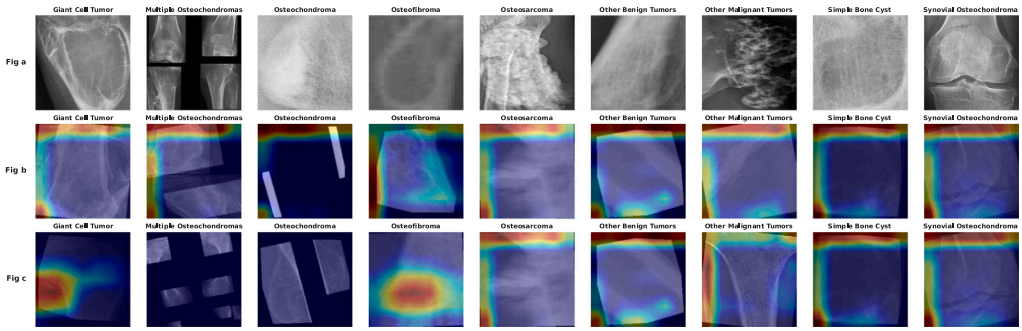

Figura 7. Figura a Imagens radiográficas originais;**Figura b**Apresenta os mapas de calor Grad CAM gerados pelo modelo CNNT;**Figura c**Exibe as saídas do Grad CAM do modelo ResNet50 CBAM. Os mapas de calor destacam as regiões espaciais discriminativas de classe nas quais os modelos se concentram durante a inferência ou classificação. As regiões vermelhas e amarelas indicam áreas de maior importância na previsão do modelo.

Os indicadores de desempenho alcançaram até 100% de precisão na classificação em configurações binárias e um valor de F1-score de 0,9759 na configuração multiclasse. Os resultados comprovam a aplicabilidade clínica da abordagem proposta para auxiliar radiologistas no diagnóstico preciso e oportuno de tumores musculoesqueléticos.

Notavelmente, o design do sistema otimiza a generalização, a eficiência e a interpretabilidade, sendo, portanto, altamente aplicável em fluxos de trabalho clínicos do mundo real. Com uma ferramenta de apoio à decisão baseada em IA, este esforço possui um imenso potencial para reduzir a carga diagnóstica e melhorar os resultados para pacientes em ambientes de atendimento oncológico. Em atividades futuras, a incorporação de aprendizado federado provavelmente permitirá o treinamento de modelos com preservação da privacidade em diversos centros de saúde e, assim, resolverá o problema de segurança de dados que comumente dificulta a adoção da IA médica. Além disso, pretendemos pesquisar computação neuromórfica usando Redes Neurais de Disparo (SNNs) para acelerar o consumo de energia e a latência de modelos de classificação em tempo real e permitir a integração em aplicações de diagnóstico em dispositivos móveis e na borda da rede. Esses avanços devem impulsionar a implementação de soluções de IA em larga escala na saúde geral e pediátrica, permitindo intervenções mais precoces com melhor planejamento.

Declaração de contribuição de autoria CRediT

Syed Mohsin Bokhari: Redação do rascunho original, Visualização, Software, Curadoria de dados, Metodologia, Análise formal, Investigação, Conceitualização.**Muhammad Shafi:**Redação, revisão e edição, Validação, Supervisão, Recursos, Administração de projetos, Investigação, Análise formal.

Declaração sobre IA generativa e tecnologias assistidas por IA no processo de escrita

Durante a preparação deste trabalho, os autores utilizaram o chatgpt para aprimorar a linguagem. Após a utilização dessa ferramenta, os autores revisaram e editaram o conteúdo conforme necessário e assumem total responsabilidade pelo conteúdo da publicação.

Declaração de conflito de interesses

Os autores declaram não possuir quaisquer interesses financeiros ou relações pessoais que possam ter influenciado o trabalho apresentado neste artigo.

Disponibilidade de dados

Os dados serão disponibilizados mediante solicitação.

Referências

[1] Shunhan Yao, Liang Pan, Qiang Lin, Xiang Liu, Zhexuan Wu, Dongqing Zhang, Um conjunto de dados radiográficos para a classificação, localização e segmentação de tumores ósseos primários, Sci. Data 12 (2025) 181,https://pubmed.ncbi.nlm.nih.gov/39820508/.

[2] Claudio E. von Schacky, Bernhard O. Sabel, Benjamin Schaefgen, Sven Lennartz, Nico Sollmann, Sebastian Ruschke, Jan S. Kirschke, Thomas Baum, Marco Notohamiprodjo, Aprendizado profundo multitarefa para segmentação e classificação de tumores ósseos primários em radiografias, Radiology 300 (2) (2021) 418–427, https://doi.org/10.1148/radiol.2021204531.

[3] Mateja Napravnik, Mojca Rihtar, Katja Steblovnik, Matic Grošelj, Ivan Štajduhar, Janez Demšar, Building RadiologyNET: Uma abordagem não supervisionada para anotar um banco de dados médico multimodal em grande escala, BioData Min. 17 (2024) 4,https://doi.org/10.1186/s13040-024-00373-1.

[4]GS Lodwick, AJ Wilson, C. Farrell, P. Virtama, FM Smeltzer, F. Dittrich, Estimativa da taxa de crescimento em lesões ósseas: desempenho e erro do observador, Radiology 134 (3) (1980) 585–590.

[5]WR Reinus, AJ Wilson, B. Kalman, S. Kwasny, Diagnóstico de lesões ósseas focais usando redes neurais, Invest. Radiol. 29 (6) (1994) 606–611.

[6]BH Do, C. Langlotz, CF Beaulieu, Diagnóstico de tumor ósseo usando um modelo Bayesiano ingênuo de características demográficas e radiográficas, J. Digit. Imaging 30 (2017) 640–647.

[7]L. Huang, W. Xia, B. Zhang, B. Qiu, X. Gao, MSFCN—redes convolucionais totalmente supervisionadas múltiplas para a segmentação de osteossarcoma de imagens de TC, Comput. Methods Programs Biomed. 143 (2017) 67–74.

[8]Y. He, J. Guo, X. Ding, PMA van Ooijen, Y. Zhang, A. Chen, M. Oudkerk, X. Xie, Rede neural convolucional para prever a recorrência local de tumor de células gigantes ósseas após curetagem com base em imagens de ressonância magnética pré-cirúrgicas, Eur. Radiol. 29 (2019) 5441–5451.

[9]Q. Li, J. Li, Y. Liu, X. Wang, C. Ma, Y. Wang, Rede neural convolucional para prever a recorrência local de tumor de células gigantes ósseas após curetagem com base em imagens de ressonância magnética pré-cirúrgicas, Comput. Methods Programs Biomed. 229 (2023) 107390.

[10]C.-W. Park, et al., Classificação de tumores ósseos no fêmur proximal em radiografias simples baseada em inteligência artificial: desenvolvimento e validação do sistema, PLoS One 17 (2022) e0264140.

[11] N.-T. Do, S.-T. Jung, H.-J. Yang, S.-H. Kim, Modelo seg-unet multinível com imagens de raios X globais e baseadas em patches para detecção de tumor ósseo no joelho, Diagnostics 11 (2021) 691,https://doi.org/10.3390/diagnostics11040691.

[12]HB Arunachalam, et al., Avaliação de tumores viáveis e necróticos a partir de imagens de lâminas inteiras de osteossarcoma usando modelos de aprendizado de máquina e aprendizado profundo, PLoS Um 14 (2019) e0210706.

[13] Autor(es), Título do conjunto de dados ou resultado da pesquisa, Figshare, 2025,http://dx.doi.org/10.6084/m9.figshare.27865398.v1.

[14] Antonio Torralba, Bryan C. Russell, Jenny Yuen, Labelme: Anotação de imagem online e aplicações, Proc. IEEE 98 (8) (2010) 1467–1484,http://dx.doi.org/ 10.1109/JPROC.2010.2050290.

[15]J. Zhang, Y. Li, M. Wang, Segmentação de lesões em tempo real usando arquiteturas baseadas em YOLO em imagens médicas multicêntricas, IEEE Trans. Med. Imaging 42 (5) (2023) 1234–1246.

[16]S. Kumar, A. Chen, L. Nguyen, Estruturas unificadas de detecção e segmentação para diagnóstico médico: um estudo sobre YOLOv8s-seg, Med. Image Anal. 88 (2024) 102743.

[17]K. Dabov, A. Foi, V. Katkovnik, K. Egiazarian, Remoção de ruído de imagem por filtragem colaborativa esparsa no domínio da transformação 3D, IEEE Trans. Image Process. 16 (8) (2007) 2080–2095.

[18]H. Zhang, J. Sun, X. Wang, Redução de ruído em TC de baixa dose via BM3D e estrutura híbrida de aprendizado profundo, IEEE Trans. Med. Imaging 42 (1) (2024) 145–157.

[19]Y. Liu, Z. Chen, P. Li, Aprendizado profundo assistido por BM3D para aprimoramento de imagem histopatológica, IEEE J. Biomed. Heal. Inform. 28 (2) (2024) 312–324.
[20]X. Wang, L. Zhao, M. Feng, Aprimoramento de imagem de fundo de retina usando BM3D para detecção aprimorada de doenças, IEEE Trans. Biomed. Eng. 71 (4) (2023) 896–908.
[21]T. Chen, Y. Guo, R. Han, Classificação de ressonância magnética cerebral resistente a ruído usando pré-processamento baseado em BM3D e recursos de CNN, IEEE Trans. Neural Netw. Learn. Syst. 35 (3) (2024) 456–470.
[22]NV Chawla, KW Bowyer, LO Hall, WP Kegelmeyer, SMOTE: Técnica sintética de sobreamostragem de minorias, J. Artificial Intelligence Res. 16 (2002) 321–357.
[23]Y. Zhao, J. Wang, X. Liu, Aumento de dados baseado em SMOTE para classificação de imagens dermatológicas desbalanceadas, IEEE Trans. Med. Imaging 42 (1) (2024) 112–123.
[24]H. Lee, M. Kim, S. Park, Aprendizado profundo para anomalias craniofaciais pediátricas: uma abordagem de conjunto de dados balanceado usando SMOTE, IEEE J. Biomed. Heal. Inform. 27 (3) (2023) 456–468.
[25]A. Gupta, RK Sharma, P. Singh, Abordando o desequilíbrio de classes na classificação de doenças raras usando SMOTE e aprendizado profundo, IEEE Trans. Comput. Biol. Bioinform. 20 (5) (2023) 789–799.
[26]T. Nguyen, D. Tran, B. Hoang, Geração de dados sintéticos para detecção de anomalias congênitas: uma abordagem híbrida SMOTE-GAN, IEEE Trans. Neural Netw. Learn. Syst. 35 (2) (2024) 245–258.
[27]S. Wang, X. Liu, Y. Zhang, H. Li, Aprendizado profundo com SMOTE para classificação de doenças raras, IEEE Trans. Med. Imaging 40 (9) (2021) 2282–2294.
[28]M. Fernández-Delgado, JC Riquelme, J. Pardo, Benchmarking de variantes SMOTE para aprendizado profundo em imagens médicas, Pattern Recognit. 122 (2022) 108294.
[29]G. Douzas, F. Bacao, F. Last, Melhorando o aprendizado desbalanceado por meio de um método heurístico de sobreamostragem baseado em K-means e SMOTE, Inform. Sci. 465 (2018) 1–20.
[30]J. Cohen, Um coeficiente de concordância para escalas nominais, Educ. Psychol. Meas. 20 (1) (1960) 37–46.
[31]B. Wikeckowska, KB Kubiak, P. Jóźwiak, W. Moryson, B. Stawińska-Witoszyńska, Coeficiente Kappa de Cohen como medida para avaliar a melhoria da classificação após a adição de um novo marcador a um modelo de regressão, Internacional J. Meio Ambiente. Res. Cura Pública. 19 (16) (2022) 10213, MDPI.
[32]D. Chicco, MJ Warrens, G. Jurman, O coeficiente de correlação de Matthews (MCC) é mais informativo do que o Kappa de Cohen e a pontuação de Brier na avaliação de classificação binária, IEEE Access 9 (2021) 78368–78381.
[33]Y. Pi, Z. Zhao, Y. Xiang, Y. Li, H. Cai, Z. Yi, Diagnóstico automatizado de metástase óssea baseado em varreduras ósseas multiview usando redes neurais profundas aumentadas por atenção, Med. Image Anal. 65 (2020) 101784.
[34]L.-W. Shang, et al., Imagem de fluorescência e espectroscopia Raman aplicadas ao diagnóstico preciso do câncer de mama com algoritmos de aprendizado profundo, Biomed. Opt. Express 11 (2020) 3673–3683.
[35]P. Yin, et al., Modelos radiômicos baseados em aprendizado de máquina e aprendizado profundo para predição pré-operatória de tumores sacrais benignos e malignos, Front. Oncol. 10 (2020) 564725.
[36]N. Papandrianos, E. Papageorgiou, A. Anagnostis, K. Papageorgiou, Classificação de metástase óssea usando imagens de corpo inteiro de pacientes com câncer de próstata com base na aplicação de redes neurais convolucionais, PLoS One 15 (2020) e0237213.
[37]N. Lang, et al., Diferenciação de metástases espinhais originadas de câncer de pulmão e outros usando radiômica e aprendizado profundo baseado em DCE-MRI, Magn. Reson. Imaging 64 (2019) 4.
[38]S. Masoudi, et al., Estadiamento de lesões ósseas baseado em aprendizado profundo a partir de tomografias computadorizadas, IEEE Access 9 (2021) 87531–87542.
[39]J. Schmidhuber, Aprendizado profundo em redes neurais: Uma visão geral, Neural Netw. 61 (2015) 85–117.
[40]CE von Schacky, NJ Wilhelm, VS Schäfer, Y. Leonhardt, M. Jung, PM Jungmann, MF Russe, SC Foreman, FG Gassert, FT Gassert, et al., Desenvolvimento e avaliação de modelos de aprendizado de máquina baseados em radiômica de raios X para a classificação e diferenciação de tumores ósseos malignos e benignos, Eur. Radiol. 32 (9) (2022) 6247–6257.
[41] RF Meem, KT Hasan, Detecção de tumores de osteossarcoma usando modelos de aprendizado por transferência, 2023, preprint do arXivarXiv:2305.09660.
[42]Z. Gu, J. Cheng, H. Fu, K. Zhou, H. Hao, Y. Zhao, T. Zhang, S. Gao, J. Liu, CE-net: Rede de codificação de contexto para segmentação de imagens médicas 2D, IEEE Trans. Med. Imaging 38 (10) (2020) 2281–2292.
[43]T. Zhou, M. Ruan, M. Canu, H. Zhang, UNet++ com CBAM para segmentação precisa de fígado e tumor em imagens de TC, Comput. Biol. Med. 130 (2021) 104200.
[44]A. Qayyum, MA Khan, SA Raza, MS Anwar, MA Khan, S. Lee, Fusão de imagens médicas multimodais usando redes neurais convolucionais: Uma revisão, IEEE Access 9 (2021) 91041–91073.
[45]Y. Yang, J. Lin, J. Wu, Y. Yu, L. Zhang, Generalizando modelos profundos para mudança de domínio via aprendizado de características invariantes por classe em imagens médicas, IEEE Trans. Med. Imaging 41 (4) (2022) 888–901.