Assine o DeepL Pro para traduzir arquivos maiores.
Mais informações em www.DeepL.com/pro.

Computerized Medical Imaging and Graphics 127 (2026) 102668

Índices disponíveis no ScienceDirect

Imagens Médicas Computadorizadas e Gráficos

Página inicial da revista : www.elsevier.com/locate/compmedimag

BoneVisionNet: Uma abordagem de aprendizado profundo para a classificação de tumores ósseos a partir de radiografias utilizando uma rede de atenção de fusão tripla de transformadores e CNNs com visualizações XAI

Armaano Ajay [a], Karthik R [b,*], Akshaj Singh Bisht [a], Pranav Uppuluri [a]

[a] Escola de Ciência da Computação e Engenharia, Instituto de Tecnologia de Vellore, Chennai, Índia
[b] Centro de Sistemas Ciberfísicos, Instituto de Tecnologia de Vellore, Chennai, Índia

I N FORMAÇÕESSO
BREO A R T I G O

Palavras-chave:
Tumor ósseo
Classificação de imagens
Classificação de raios-X Aprendizado profundo
Transformers Imagens médicas Radiografias
XAI

R E S U MO

O diagnóstico de tumores ósseos apresenta inúmeros desafios devido à complexidade da patologia e às diversas morfologias desses tumores. Os métodos atuais dependem de técnicas manuais que são demoradas e propensas a erros. Por isso, há uma necessidade de métodos mais precisos e automatizados para auxiliar os profissionais da área médica. O trabalho proposto visa resolver esse desafio através do desenvolvimento de uma arquitetura baseada em aprendizado profundo para a classificação de tumores ósseos a partir de radiografias. O BoneVisionNet proposto é desenvolvido utilizando uma combinação de três redes de DL especializadas. A abordagem proposta utiliza o Convolution-Enhanced Image Transformer para a extração de características globais, que é posteriormente refinada por meio de um Global Context Block (GCB). Paralelamente, a Attention Boosted Mid-Level Feature Extraction Network (ABMLFE-Net) tem como alvo características de nível médio, enquanto a DenseNet-169 se concentra na extração de características locais. Os mapas de características da ABMLFE-Net e da DenseNet-169 são fundidos por meio de multiplicação elemento a elemento, seguido por uma camada de Atenção de Canal Eficiente (ECA) para o refinamento das características. As características globais refinadas pelo GCB são concatenadas com os mapas de características aprimorados da camada ECA, resultando em um mapa de características multiescala refinado. A BoneVisionNet atingiu uma precisão de 84,35% quando testada no conjunto de dados BTXRD, superando as redes baseadas em CNN e transformadores na classificação de tumores ósseos a partir de radiografias. Até onde sabemos, este estudo representa a primeira aplicação de uma arquitetura de trilha tripla para a classificação de tumores ósseos a partir de imagens de raios-X. Visualizações XAI usando Grad-CAM, LIME e SHAP ajudam a validar ainda mais o desempenho do modelo, garantindo transparência no processo de tomada de decisão.

1. Introdução

Os tumores ósseos são crescimentos anormais que podem ser benignos ou malignos, afetando e ceifando a vida de milhares de pessoas em todo o mundo a cada ano (Hakim et al., 2015). Cânceres ósseos, como o osteossarcoma, o sarcoma de Ewing e o condrossarcoma, progridem rapidamente e representam risco de vida se não forem diagnosticados precocemente (Xu et al., 2023). Pacientes que sofrem de tumores ósseos geralmente apresentam dor persistente, acompanhada de inchaço, mobilidade reduzida, fraqueza e alto risco de fraturas patológicas. Dados recentes indicam que cerca de 0,2% de todos os casos de câncer são casos de câncer ósseo; no entanto, ele afeta os pacientes de forma bastante grave devido à rapidez com que se espalha (Sarcomas ósseos, 2014).

Embora o diagnóstico precoce e preciso seja essencial para um tratamento eficaz, identificar o câncer ósseo é particularmente difícil devido à diferenças sutis nas estruturas tumorais (Singh et al., 2024). No diagnóstico tradicional, o primeiro passo consiste na análise de raios-X, tomografias computadorizadas e ressonâncias magnéticas, seguidas da avaliação especializada de radiologistas e patologistas (K, 2025). Além disso, a análise manual de imagens médicas introduz variabilidade e subjetividade, além de acarretar o risco de diagnósticos errôneos. Isso se torna ainda mais grave quando há escassez de especialistas experientes disponíveis para realizar um diagnóstico bem fundamentado (Dalai et al., 2024). Essas questões ressaltam a necessidade de ferramentas de diagnóstico automatizadas que possam ajudar os profissionais da área médica a tomar decisões informadas e precisas.

Nos últimos tempos, o aprendizado de máquina tem sido amplamente utilizado em ferramentas de diagnóstico automatizadas (Ahsan et al., 2022). O uso de ferramentas baseadas em aprendizado de máquina permite processar e analisar grandes quantidades de dados mais rapidamente em comparação com os métodos tradicionais.

* Autor correspondente.
Endereços de e-mail: armaano.ajay2021@vitstudent.ac.in (A. Ajay), r.karthik@vit.ac.in (K. R), akshajsingh.bisht2021@vitstudent.ac.in (A.S. Bisht), pranav.uppuluri2021@vitstudent.ac.in (P. Uppuluri).

https://doi.org/10.1016/j.compmedimag.2025.102668
Recebido em 12 de maio de 2025; Recebido na versão revisada em 27 de outubro de 2025; Aceito em 13 de novembro de 2025
Disponível online em 19 de novembro de 2025
0895-6111/© 2025 Elsevier Ltd. Todos os direitos reservados, incluindo os relativos à mineração de texto e dados, ao treinamento de IA e a tecnologias similares.

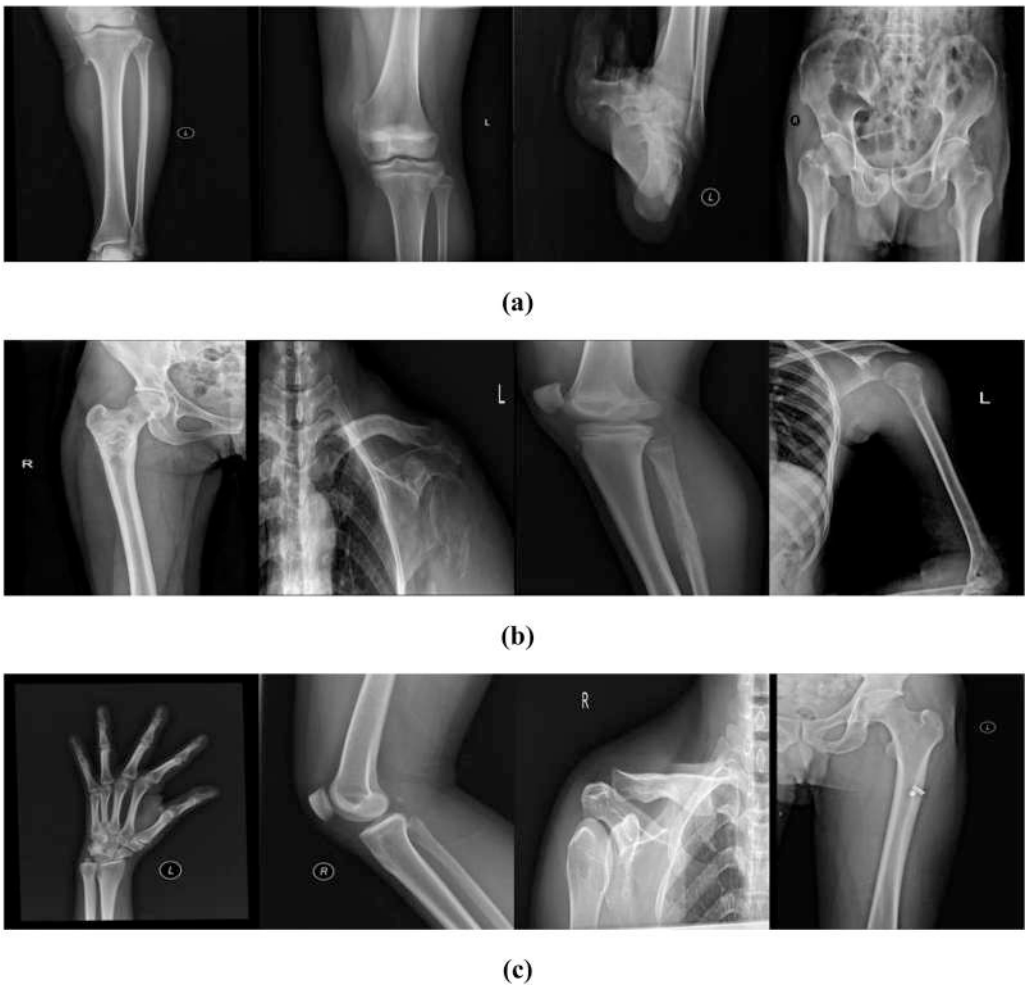

Fig. 1. Imagens de amostra do conjunto de dados BTXRD (a) Tumor benigno, (b) Tumor maligno e (c) Normal.

No entanto, os métodos baseados em aprendizado de máquina geralmente exigem a seleção manual de características, o que pode reduzir sua eficácia e capacidade de generalização (Ahmed et al., 2023). O Aprendizado Profundo (DL) surge como uma alternativa promissora, superando as limitações do Aprendizado de Máquina. Ao contrário do Aprendizado de Máquina, as técnicas de DL podem capturar automaticamente hierarquias de características diretamente dos dados, o que resulta em melhor desempenho diagnóstico (Rayed et al., 2024). Embora os modelos de Aprendizado de Máquina possam ser treinados mais rapidamente, as estruturas de DL tendem a superá-los durante a fase de teste, tornando-as mais eficazes para aplicações no mundo real (Taye, 2023).

Portanto, há uma necessidade crescente de soluções automatizadas para a detecção de tumores ósseos, capazes de auxiliar os profissionais da área médica a realizar um diagnóstico mais rápido e preciso. O trabalho proposto desenvolve um sistema baseado em aprendizagem profunda (DL) para a classificação de tumores ósseos a partir de radiografias. As principais contribuições incluem:

- Uma arquitetura de três vias para capturar características de tumores ósseos em múltiplas escalas, utilizando uma fusão de redes transformadoras e CNN. A primeira via utiliza o Convolutional Enhanced Image Transformer (CeiT) e o Global Context Block (GCB) para extração aprimorada de características globais a partir de raios-X.
- A segunda trilha utiliza uma CNN personalizada para capturar características entre os níveis global e local. A segunda trilha é complementada pela DenseNet-169, que se concentra na extração de características locais. As características da CNN personalizada e da DenseNet-169 são concatenadas e passadas pela Efficient Channel Attention (ECA) para refinamento das características.
- As características globais aprimoradas do GCB são combinadas com os mapas de características refinados da camada ECA, resultando em um mapa de características informativo que captura informações completas sobre o tumor em múltiplas escalas. Além disso, foram utilizadas técnicas de Inteligência Artificial Explicável (XAI) para aumentar a transparência e visualizar o processo de tomada de decisão do sistema proposto.

2. Revisão da literatura

Esta subseção discute os estudos existentes que empregaram a aprendizagem profunda (DL) para a detecção e classificação de tumores ósseos. A imagemologia óssea tem se beneficiado enormemente dos avanços na DL devido à sua capacidade de extrair automaticamente características das imagens e fornecer um diagnóstico mais preciso em comparação com os métodos tradicionais. Vijayaraj et al. desenvolveram um modelo de DL para a classificação do câncer ósseo utilizando uma CNN personalizada para melhorar a representação das características (Vijayaraj et al., 2023). A abordagem inclui etapas de pré-processamento, como remoção de ruído e normalização de imagens, juntamente com a extração de ROI para isolar regiões cancerosas. A classificação foi realizada utilizando CNN para extração de características espaciais e LSTM bidirecional para análise temporal. O método demonstra o potencial do DL na automatização do diagnóstico de câncer ósseo, reduzindo o erro humano e melhorando a precisão. Da mesma forma, Pan et al. trabalharam no desenvolvimento de um sistema baseado em IA para classificar tumores ósseos no fêmur proximal utilizando radiografias anteroposteriores padrão (Pan et al., 2023). O sistema utilizou um modelo DenseNet e Grad-CAM para destacar a região de interesse na imagem do tumor. O sistema mostra como a IA pode complementar o julgamento clínico e ajudar a lidar com o problema do diagnóstico incorreto

Tabela 1
Divisão do conjunto de dados antes e depois do aumento.

Classe	Antes do aumento			Após o aumento		
	Treinamento	Validação	Teste	Treinamento	Válido	Teste
Tumor benigno	1067	305	153	1067	305	153
Tumor maligno	239	68	35	1195	340	35
Normal	1315	375	189	1315	375	189
Total	**2621**	**748**	**377**	**3577**	**1020**	**377**

de tumores ósseos.

Natha et al. propuseram o modelo Stack Ensemble Transfer Learning (SETL_BMRI) para a classificação de tumores cerebrais a partir de imagens de ressonância magnética. O modelo SETL_BMRI utilizou redes pré-treinadas AlexNet e VGG19 e empilhou suas saídas para melhorar o desempenho da classificação (Natha et al., 2024). Li et al. utilizaram radiografias de campo total para criar um modelo com a estrutura YOLO que detecta e classifica lesões ósseas (Li et al., 2022). O conjunto de dados utilizado neste estudo continha imagens radiográficas de casos normais, benignos, intermediários e malignos. O modelo alcançou alta precisão na detecção e classificação de tumores ósseos, superando os radiologistas na classificação de tumores intermediários. Em uma tentativa semelhante, Hinterwimmer et al. propuseram um algoritmo que combina DL e um sistema de recomendação k-Nearest Neighbour baseado em hash para classificar tumores ósseos e associar pacientes não diagnosticados a casos anteriores (Hinterwimmer et al., 2024). O método agrupa imagens com semelhanças e as classifica utilizando modelos ResNet e Transformer por meio de votação por maioria.

Song et al. desenvolveram um sistema para classificar tumores ósseos primários como benignos, de natureza indeterminada ou malignos a partir de imagens multimodais incompletas, por meio do modelo de fusão PBTC-TransNet (Song et al., 2024). O modelo apresentou alto desempenho de classificação em conjuntos de dados internos e externos, especialmente nos casos que utilizaram dados de raios-X e tomografia computadorizada. Breden et al. utilizaram um modelo transformer para a classificação de radiografias ósseas do joelho, abordando o problema da detecção precoce de tumores ósseos em crianças (Breden et al., 2023). O modelo, treinado com TL e aumento de dados, alcançou alta precisão, sensibilidade e especificidade. O emprego do Grad-CAM na validação das previsões mostrou que o modelo poderia auxiliar os clínicos gerais no diagnóstico preciso. O conjunto completo de trabalhos de pesquisa demonstra o potencial da DL na identificação e classificação de tumores ósseos com maior precisão, menor tempo de resposta e melhores resultados gerais. Apesar dos avanços promissores na DL para a classificação de raios-X de tumores ósseos, existe uma limitação notável na acessibilidade dos conjuntos de dados. A maioria dos estudos analisados baseou-se em conjuntos de dados privados, o que restringe a capacidade de replicar os resultados ou realizar comparações diretas entre diferentes métodos. Isso destaca a necessidade de pesquisas em conjuntos de dados abertamente acessíveis para garantir a padronização

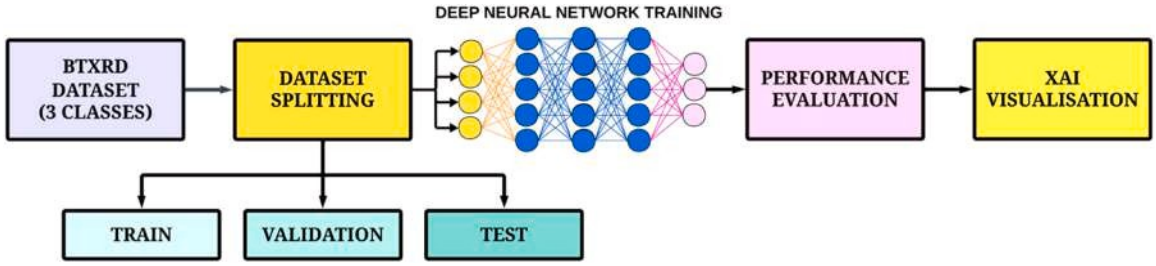

Fig. 2. Fluxo de trabalho do sistema proposto.

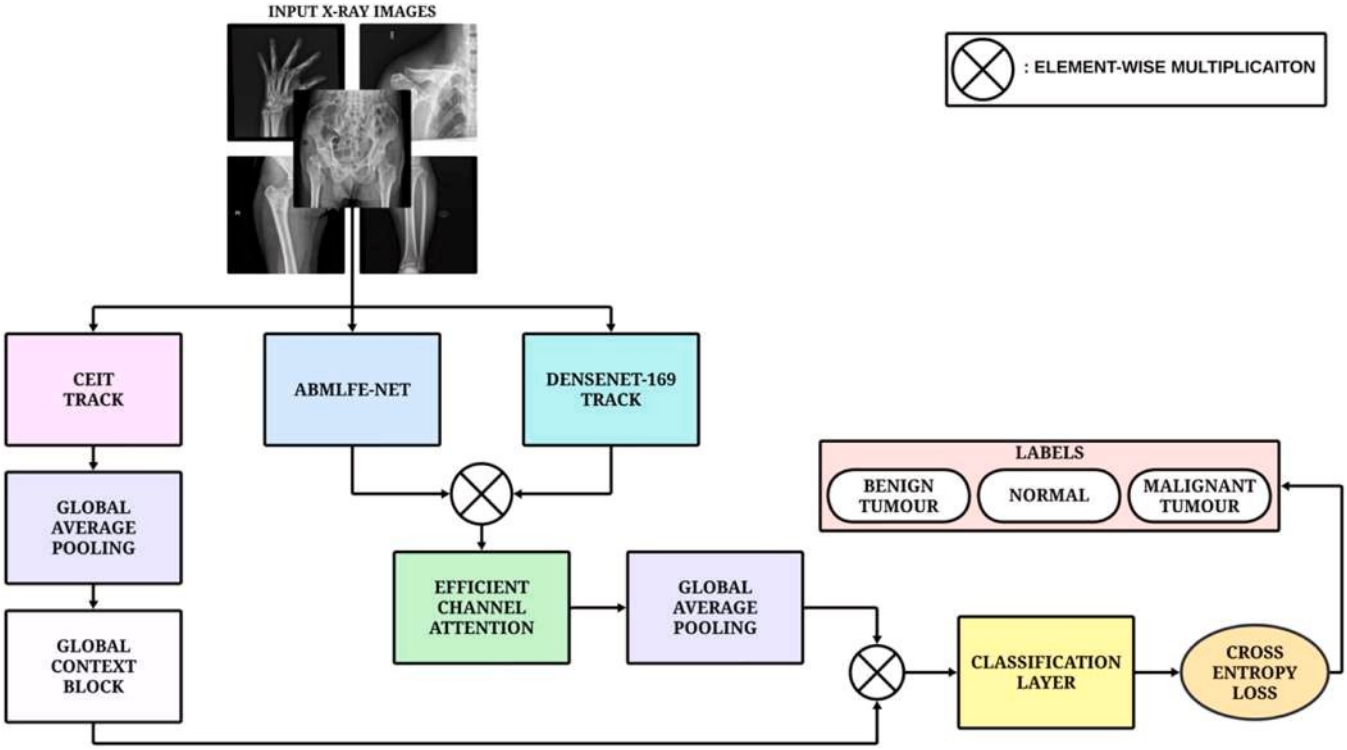

Fig. 3. Arquitetura do BoneVisionNet.

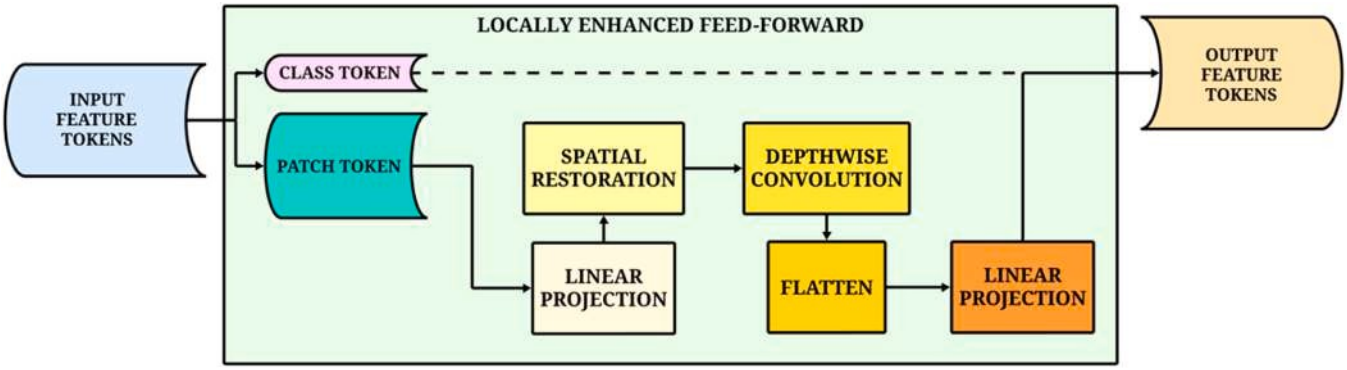

Fig. 4. Estrutura do módulo FeedForward com aprimoramento local.

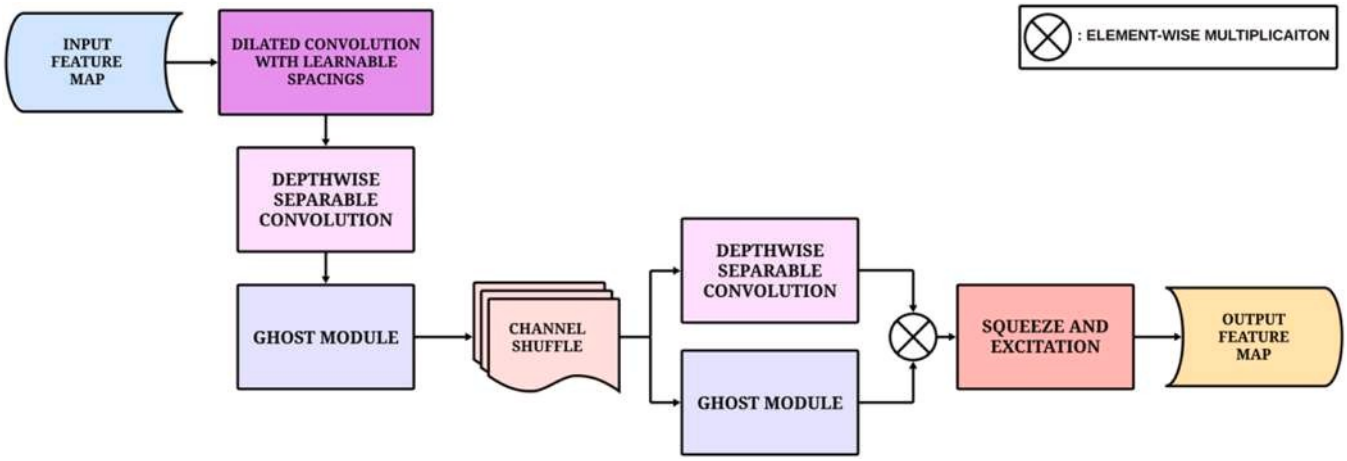

Fig. 5. Diagrama esquemático do bloco MCFE da rede ABMLFE-Net.

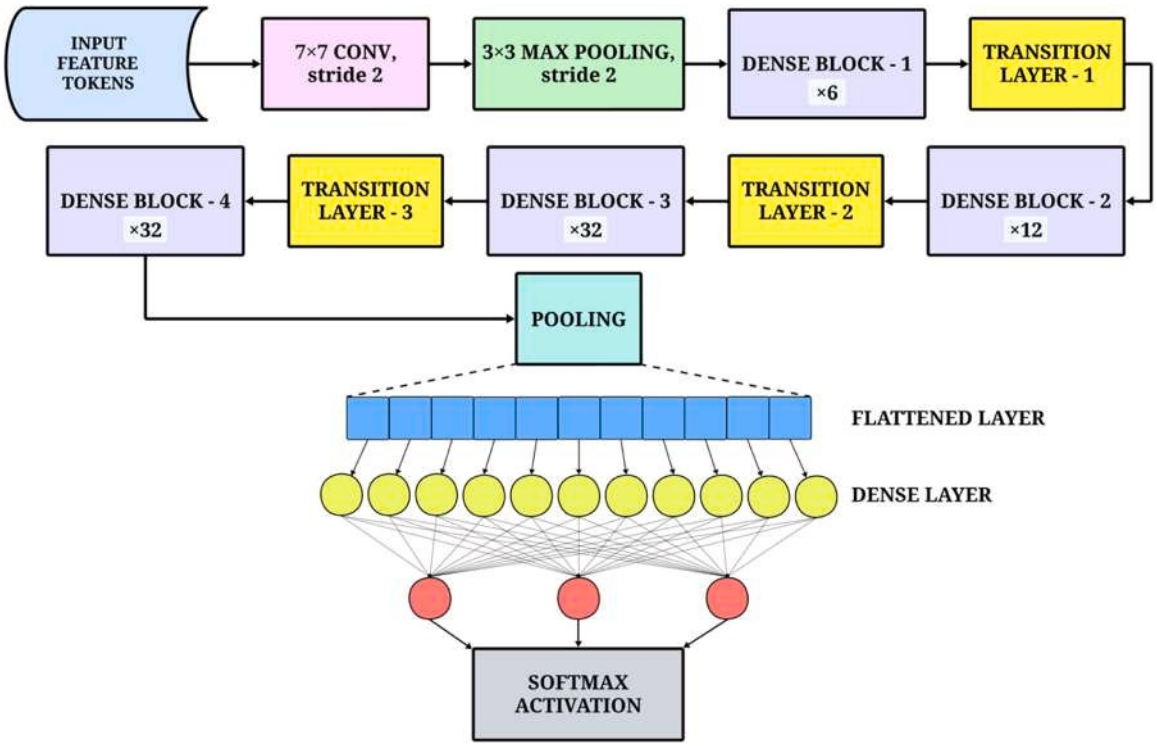

Fig. 6. Diagrama esquemático da arquitetura DenseNet.

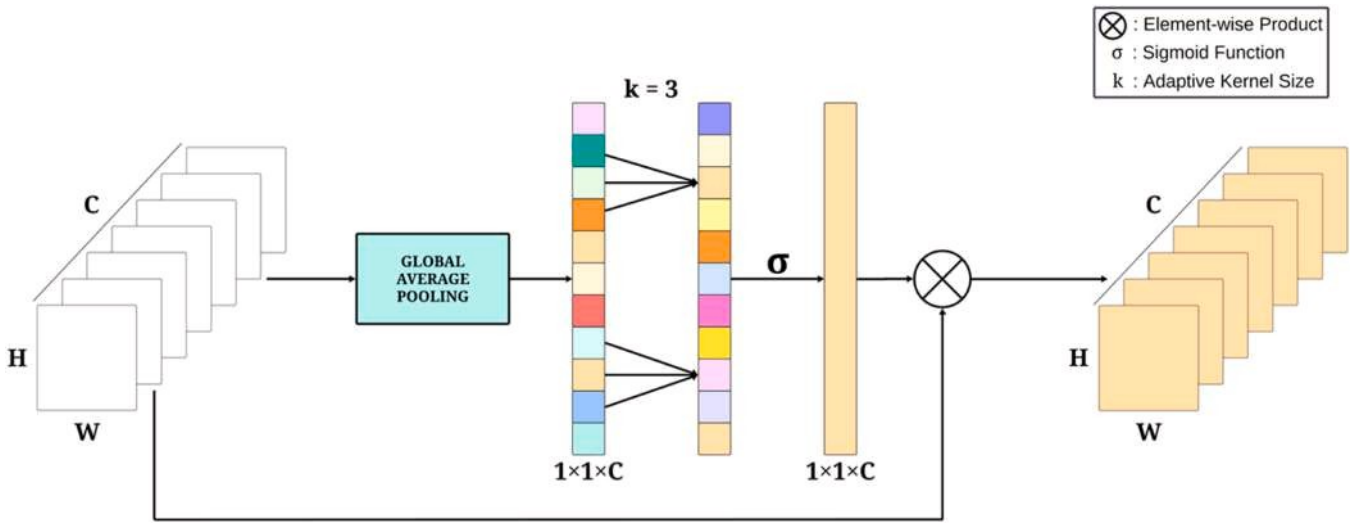

Fig. 7. Estrutura do módulo ECA.

Tabela 2
Resultados do ajuste de hiperparâmetros.

Hiperparâmetro	Intervalo de valores	Valor final
Tamanho do lote	[16,32,64]	32
Taxa de aprendizagem	$[10^{-1}, 10^{-7}]$	10^{-4}
Decaimento de peso	$[10^{-1}, 10^{-7}]$	10^{-4}
Tamanho do passo (Agendador)	[5,10,15,20,25,30]	25
Função de perda	[Entropia cruzada, Perda focal]	Entropia cruzada
Otimizador	[ADAM, SGD]	ADAM

Tabela 3
Métricas de desempenho por classe para a faixa CeiT.

Classe	Precisão (em %)	Precisão (em %)	Recuperação (em %)	F1-Score (em %)
Tumor benigno	62,09	71,97	62,09	66,67
Maligno Tumor	60,00	36,84	60,00	45,65
Normal	76,72	77,13	76,72	76,92
Total	**69,23**	**61,98**	**66,27**	**63,08**

avaliações e contribuições de pesquisa mais amplas neste domínio.

3. Metodologia

Esta seção detalha o conjunto de dados utilizado no estudo proposto e apresenta a arquitetura da rede BoneVisionNet proposta. As seções subsequentes descrevem a funcionalidade dos subcomponentes da rede proposta e explicam como seu projeto aprimora a classificação de tumores ósseos a partir de radiografias.

3.1. Descrição do conjunto de dados

A pesquisa proposta utiliza o Conjunto de Dados de Radiografias de Tumores Ósseos (BTXRD) (Yao et al., 2025). O conjunto de dados conta com 3.746 imagens de raios-X, divididas em três classes: osso normal, tumores ósseos benignos e malignos. As imagens utilizadas no conjunto de dados BTXRD provêm de três fontes, incluindo hospitais na China, o site Radiopaedia.org e o banco de dados de acesso aberto MedPix. O conjunto de dados contém imagens da mesma lesão capturadas de diferentes ângulos, como vista frontal, lateral e oblíqua. Além disso, partes anatômicas específicas, como membros superiores, membros inferiores e pelve, são mantidas em foco. O conjunto de dados foi dividido em três subconjuntos, com 70% dos dados utilizados para treinamento, 20% para validação e os restantes imagens para teste. Para equilibrar o conjunto de dados e melhorar a generalização, as amostras de treinamento e validação da classe Maligna foram aumentadas por meio de inversões aleatórias na horizontal e na vertical, juntamente com rotações aleatórias de 90, 180 e 270 ˚ . A Fig. 1 mostra amostras representativas do conjunto de dados, e a divisão do conjunto de dados antes e depois do aumento é apresentada na Tabela 1.

3.2. Sistema proposto

Esta subseção apresenta uma visão geral do fluxo técnico do sistema proposto. Inicialmente, o conjunto de dados de radiografias de tumores ósseos (BTXRD) é dividido em conjuntos de treinamento, validação e teste. Posteriormente, a classe com menor número de imagens passa por um processo de aumento de dados para equilibrar o conjunto de treinamento. Na etapa seguinte, a rede proposta é treinada no conjunto de dados BTXRD. O desempenho do BoneVisionNet é então avaliado utilizando uma série de métricas no conjunto de teste. Por fim, o processo de tomada de decisão do modelo é validado utilizando técnicas de XAI para melhorar a transparência na classificação de radiografias de tumores ósseos. Todo o fluxo de trabalho está resumido na Fig. 2.

3.2.1. Rede proposta

A rede BoneVisionNet proposta utiliza uma arquitetura de três vias projetada especificamente para melhorar a precisão da classificação de tumores ósseos, capturando características em múltiplas escalas. O CeiT é utilizado como a primeira trilha de extração de características, com foco em características globais. As características extraídas pelo CeiT são agrupadas e passadas pelo GCB, que captura o contexto global com baixo custo computacional. Esse método garante uma extração aprimorada de características globais, essencial para os detalhes de longo alcance das radiografias de tumores ósseos. A segunda trilha consiste na ABMLFE-Net, uma CNN personalizada para a extração eficiente de características de nível médio. A ABMLFE-Net utiliza o bloco Multi-Conv Feature Extraction (MCFE) para capturar dependências informativas de médio alcance, de modo que o modelo possa diferenciar facilmente entre tumores benignos e malignos. O bloco MCFE emprega técnicas convolucionais avançadas com tamanhos de kernel dinâmicos, mecanismo de atenção e operação de embaralhamento de canais para melhorar a extração de características. O DenseNet-169 é empregado para a extração de características locais na terceira faixa, garantindo que características detalhadas das radiografias sejam efetivamente capturadas.

Posteriormente, os mapas de características do ABMLFE-Net e do DenseNet-169 são concatenados por meio de multiplicação elemento a elemento e encaminhados para a camada ECA. A camada ECA permite que a rede se concentre nas informações específicas de canal mais importantes. Essas características são então agrupadas por meio do Global Average Pooling (GAP) para compactar as informações espaciais. As características refinadas do GCB e da ECA são então concatenadas. Esta

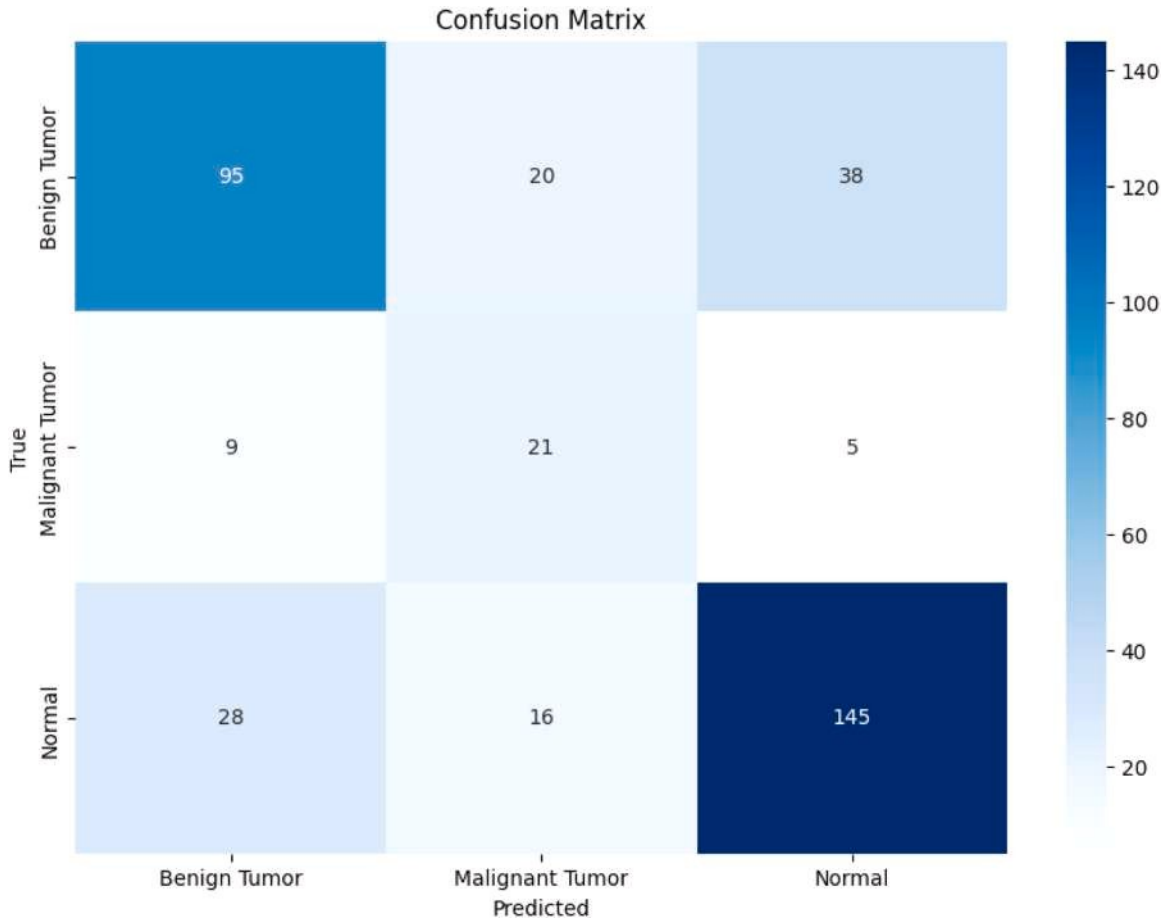

Fig. 8. Matriz de confusão para a faixa CeiT.

permite que a rede analise características informativas em múltiplas escalas a partir das radiografias. Os mapas de características fundidos passam por uma camada de achatamento e são encaminhados para a camada de classificação ativada. Além disso, a perda de entropia cruzada foi utilizada para garantir que o modelo atingisse a convergência máxima. A Fig. 3 mostra a arquitetura completa da rede da abordagem proposta.

3.2.1.1. Categoria "Image Transformer com aprimoramento convolucional". Esta subseção discute a arquitetura da categoria CeiT, que combina os pontos fortes das arquiteturas de CNN e de transformadores (Yuan et al., 2021). Enquanto as CNNs se especializam em capturar características detalhadas e manter o campo receptivo local, os transformadores se destacam na modelagem de dependências de longo alcance. O CeiT tenta combinar essas abordagens adicionando melhorias convolucionais à arquitetura do Vision Transformer (ViT). A arquitetura do CeiT começa com o módulo Image-to-Tokens (I2T), que utiliza um núcleo convolucional leve para aprimorar o processo padrão de tokenização do ViT. O núcleo consiste em uma camada convolucional seguida por BatchNorm e max-pooling. Em vez de achatar as imagens de entrada brutas em patches, o I2T utiliza os mapas de características intermediários para realizar uma extração de características aprimorada. Essa estratégia melhora a tokenização de patches grandes do ViT ao capturar detalhes locais da imagem, como bordas e texturas. Quando a tokenização é realizada, o módulo Locally-enhanced FeedForward (LeFF) aumenta a força da conectividade local entre os tokens. O LeFF substitui as redes feed-forward típicas do ViT, adicionando convoluções em profundidade às redes feed-forward para melhorar as relações espaciais entre os tokens e capturar detalhes mais refinados na imagem. Uma visão geral do módulo LeFF é apresentada na Fig. 4.

Uma melhoria fundamental no CeiT é o seu módulo de atenção por camadas ao token de classe (LCA). O módulo LCA refina continuamente o token de classe, que é um resumo de toda a imagem com base em informações hierárquicas em todas as suas camadas. O LCA garante que haja uma contribuição de características locais e globais na construção da representação final das características, de modo que o CeiT possa capturar contextos ricos a partir das imagens. A fim de aprimorar as características extraídas pelo CeiT, o GCB é integrado à sua estrutura (Cao et al., 2023). O GCB tem como objetivo destacar dependências globais por meio da geração de pesos de atenção, que detectam regiões críticas nos mapas de características. O módulo captura relações inter-regionais dentro do mapa de características de entrada, de modo que as características extraídas retenham detalhes finos juntamente com um contexto global. O GCB refina a característica extraída do CeiT calculando uma máscara de atenção global, que é então imposta aos mapas de características para realçar regiões críticas e ignorar aquelas menos informativas.

3.2.1.2. Rede de extração de características de nível intermediário com reforço de atenção. Esta seção explica a arquitetura da ABMLFE-Net, empregada como o segundo extrator de características no BoneVisionNet. A ABMLFE-Net concentra-se na extração de características de nível intermediário, captando os detalhes entre as características locais e globais. Isso é especialmente importante em tarefas como a análise de tumores ósseos, nas quais os padrões espaciais e estruturais dos tumores precisam ser analisados para se chegar a um diagnóstico adequado. A ABMLFE-Net é uma arquitetura CNN personalizada utilizada sem pesos pré-treinados, garantindo que a rede aprenda representações específicas do domínio, adaptadas para radiografias de tumores ósseos. Ao contrário de extratores de características convencionais, como ResNet e MobileNet, que se concentram principalmente em características genéricas de baixo nível, a ABMLFE-Net incorpora recursos especializados de extração de características de nível médio utilizando o bloco MCFE. O bloco MCFE é o principal módulo de extração de características na ABMLFE-Net e foi projetado para impulsionar a extração de características de nível médio, sendo repetido iterativamente cinco vezes de maneira sequencial. Cada bloco começa com uma Convolução Dilatada

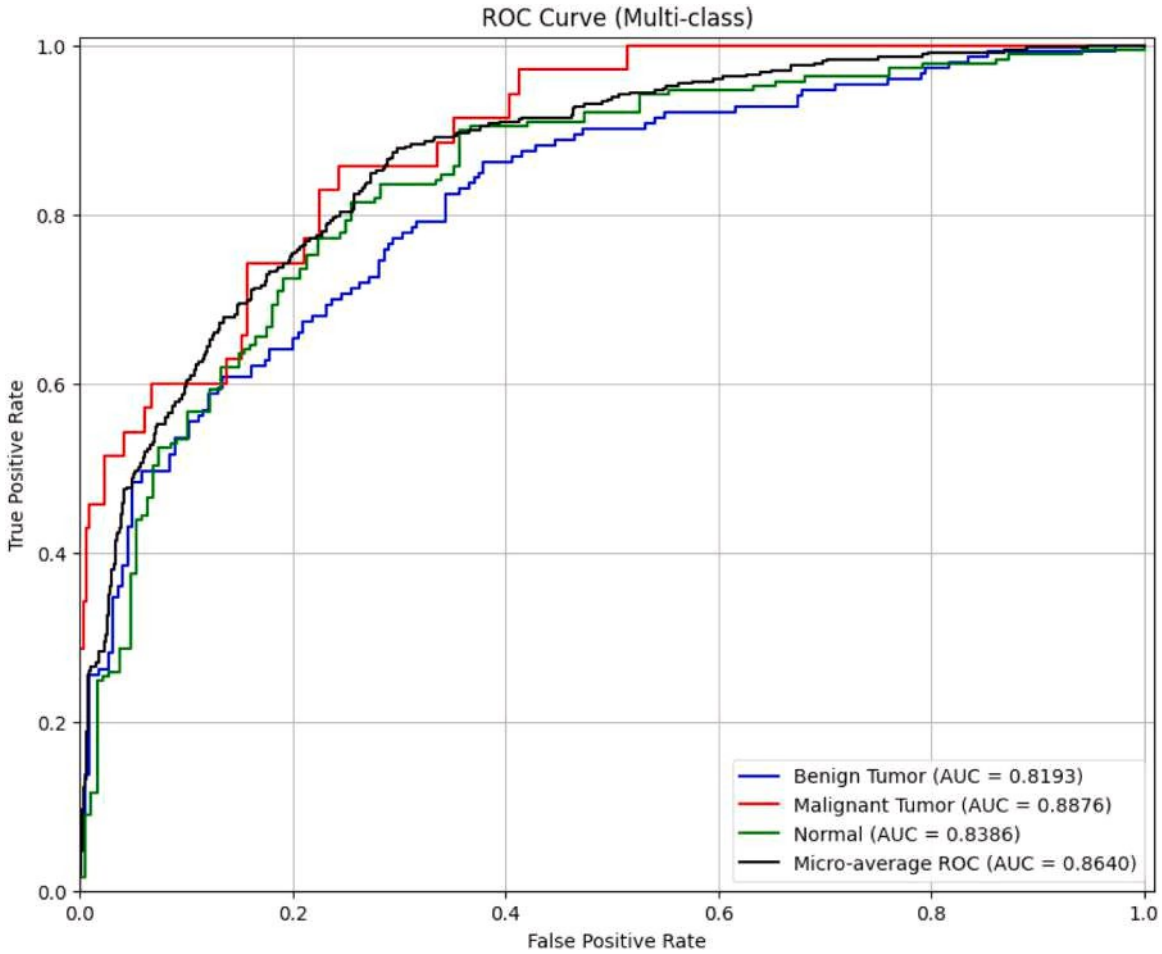

Fig. 9. Curvas ROC para a categoria CeiT.

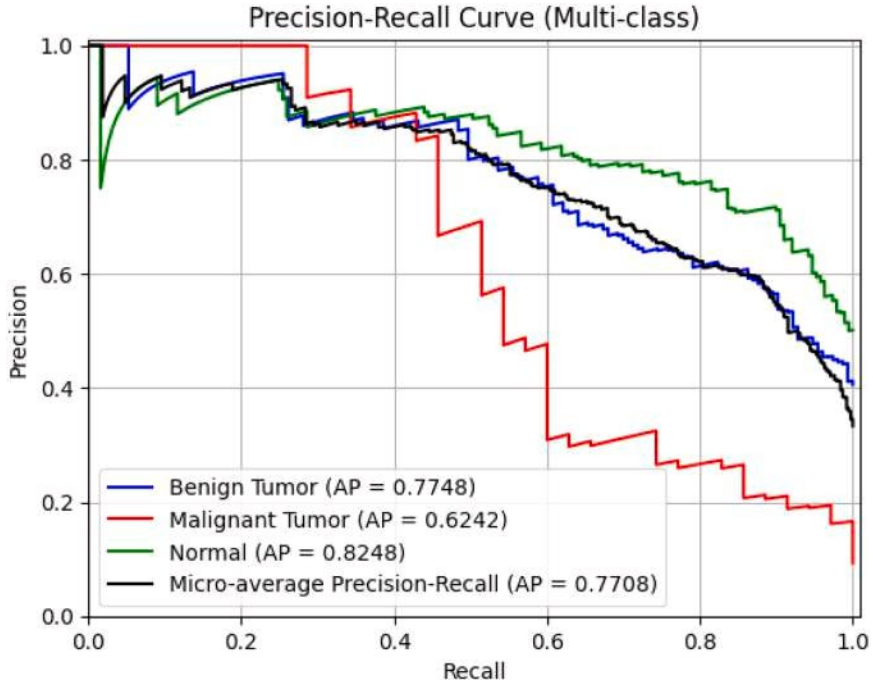

Fig. 10. Curvas de precisão-recall para a faixa CeiT.

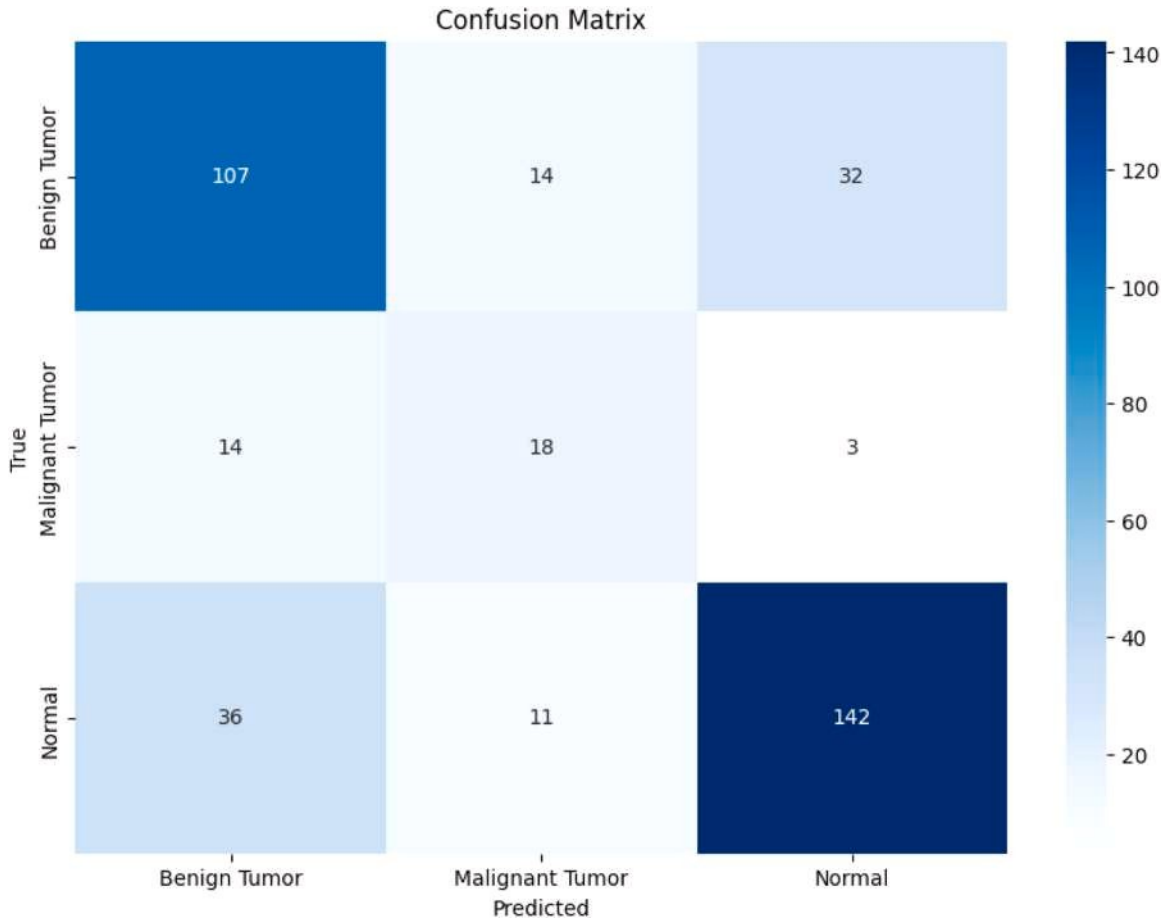

Fig. 11. Matriz de confusão para a rede ABMLFE-Net.

Camada com espaçamentos aprendíveis (DCLS), na qual o tamanho do kernel é cinco para aumentar o campo receptivo (Khalfaoui-Hassani et al., 2021). Durante a fase de treinamento, o DCLS permite que a rede controle dinamicamente as distâncias entre os elementos do kernel. Isso permite que a rede possua um campo receptivo flexível, capaz de capturar dependências de longo alcance sem aumentar o número de parâmetros. Isso é essencial para a classificação de radiografias de tumores ósseos, uma vez que os tecidos circundantes com alterações sutis podem ser muito úteis no diagnóstico.

O resultado da camada DCLS é encaminhado para um módulo de Convolução Separável em Profundidade com tamanho de kernel igual a 3 (Chollet, 2017). A Convolução Separável em Profundidade divide as convoluções em duas: uma é a convolução espacial e a outra é a convolução por canal. Isso diminui a complexidade computacional do modelo e mantém a precisão simultaneamente. As características refinadas são então processadas pelo Módulo Ghost com um tamanho de kernel de 1 (Han et al., 2020). Em vez de depender de convoluções regulares, o Módulo Ghost enriquece os mapas de características por meio de operações lineares simples, o que reduz a duplicação desnecessária e, ao mesmo tempo, aumenta a representação das características. Após o Módulo Ghost, os mapas de características são embaralhados para melhorar a comunicação entre unidades usando o Channel Shuffle (Zhang et al., 2018). As características embaralhadas são então alimentadas em duas camadas paralelas: uma consiste na Convolução Separável em Profundidade com um tamanho de filtro de 3 e a segunda possui um Módulo Ghost com um tamanho de filtro de 5. Os resultados dessas duas camadas são mesclados e processados por um módulo de compressão e excitação que realça características específicas do canal e, ao mesmo tempo, diminui características sem importância (Hu et al., 2018). Isso leva a um mapa de características aprimorado com foco em características de nível médio usando tamanhos de kernel dinâmicos. A estrutura geral do bloco MCFE é apresentada na Fig. 5.

3.2.1.3. Faixa DenseNet-169. O DenseNet-169 é utilizado como a terceira característica extração de pistas na rede BoneVisionNet para melhorar a extração de características locais, como bordas, texturas e padrões complexos (Huang et al., 2017). Essas características tornam-se essenciais na análise de tumores ósseos, pois suas alterações morfológicas costumam ser sutis, como margens irregulares, calcificações e alterações na estrutura do tecido. O DenseNet-169 utiliza uma arquitetura distinta, na qual cada camada dentro de um bloco denso está conectada a todas as camadas precedentes. Esse arranjo permite a reutilização de características, elimina cálculos desnecessários e garante que os detalhes de todos os níveis sejam preservados em toda a rede. Essas características tornam o DenseNet-169 eficaz na retenção e no aprimoramento de características que são fundamentais para diferenciar entre tumores ósseos benignos e malignos. Isso permite a extração de características locais complexas. O modelo demonstra melhor desempenho e precisão no diagnóstico ao empregar o DenseNet-169 na arquitetura, o que permite uma representação mais detalhada e holística das imagens de tumores ósseos. Uma visão geral estrutural da arquitetura do DenseNet-169 é apresentada na Fig. 6.

3.2.1.4. Atenção de canal eficiente. O módulo ECA desempenha um papel importante na rede BoneVisionNet proposta (Wang et al., 2020). A camada ECA refina os mapas de características fundidos obtidos a partir da rede ABMLFE-Net e da cadeia DenseNet-169. Ao enfatizar seletivamente os canais mais informativos, o módulo ECA garante que a rede se concentre nas características críticas essenciais para distinguir com precisão entre tumores ósseos benignos e malignos. O ECA utiliza a atenção de canal sem depender de camadas totalmente conectadas, que são computacionalmente onerosas e normalmente utilizadas em mecanismos de atenção tradicionais. Em vez disso, ele utiliza uma convolução 1D leve com um tamanho de kernel determinado dinamicamente com base no número de canais. Esse tamanho de kernel adaptativo equilibra expressividade e eficiência, garantindo que o mecanismo de atenção seja adaptado para

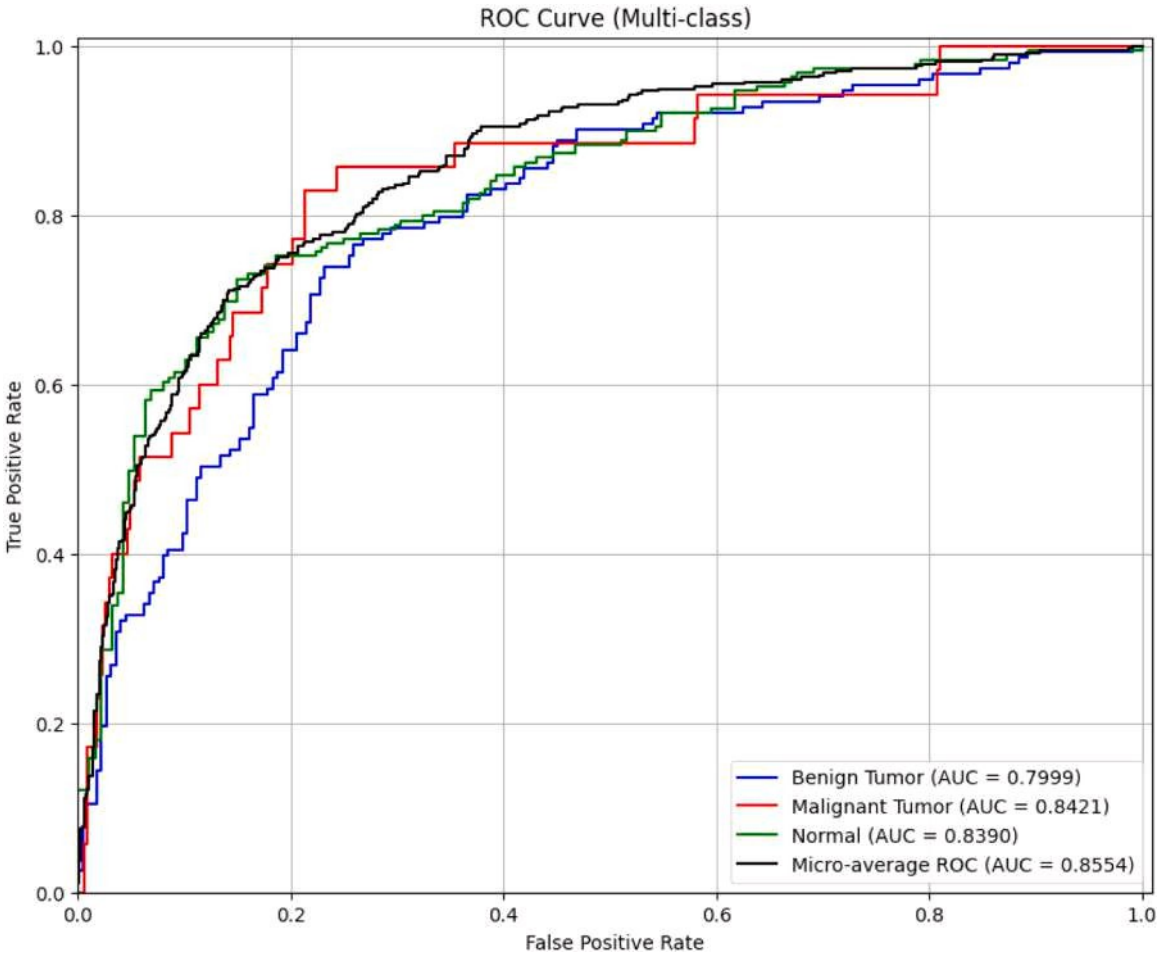

Fig. 12. Curvas ROC para a ABMLFE-Net.

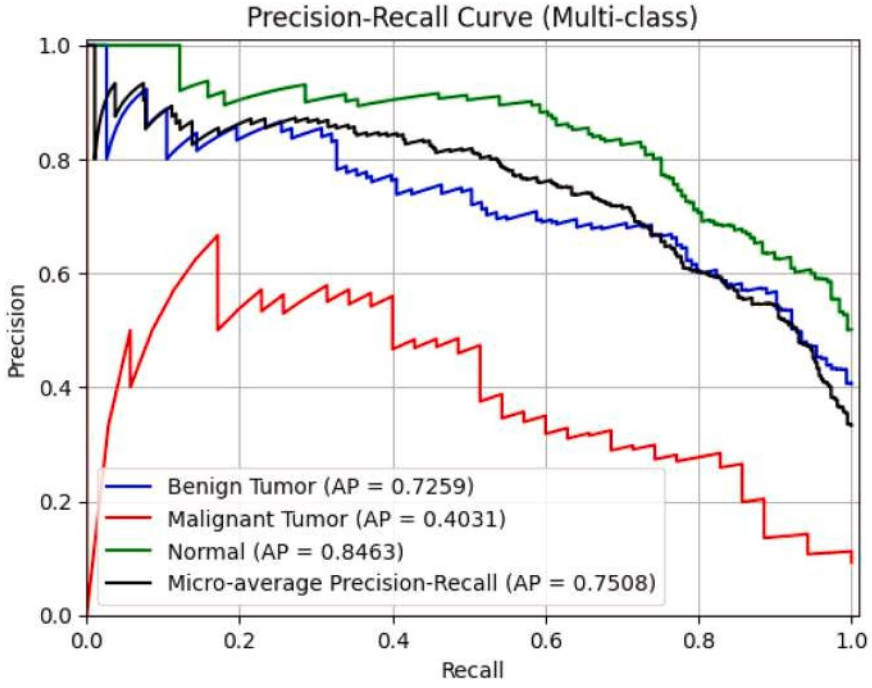

Fig. 13. Curvas de precisão-recall para a rede ABMLFE-Net.

Tabela 4
Métricas de desempenho por classe para o ABMLFE-Net.

Classe	Precisão (em %)	Precisão (em %)	Recuperação (em %)	F1-Score (em %)
Tumor benigno	69,94	68,15	69,94	69,03
Maligno Tumor	51,43	41,86	51,43	46,15
Normal	75,13	80,23	75,13	77,60
Total	**70,82**	**63,41**	**65,50**	**64,26**

Tabela 5
Métricas de desempenho por classe para a faixa DenseNet-169.

Classe	Precisão (em %)	Precisão (em %)	Recuperação (em %)	F1-Score (em %)
Tumor benigno	68,63	71,43	68,63	70,00
Maligno Tumor	71,43	49,02	71,43	58,14
Normal	76,19	80,45	76,19	78,26
Total	**72,68**	**66,97**	**72,08**	**68,80**

a dimensionalidade do mapa de características.

O processo de atenção começa com o GAP, que calcula um vetor descritor que resume as informações espaciais para cada canal no mapa de características. Esse descritor é então submetido à convolução 1D adaptativa, que produz pesos específicos para cada canal por meio de uma função de ativação sigmoide. Esses pesos de atenção são aplicados para dimensionar cada canal no mapa de características, refinando-o para priorizar as características mais relevantes enquanto suprime informações redundantes ou irrelevantes. As características refinadas permitem que o modelo se concentre em regiões críticas associadas com características tumorais, melhorando sua capacidade de classificar tumores com alta precisão. Além disso, o design leve do ECA minimiza a sobrecarga computacional, tornando-o uma opção eficiente e eficaz para aprimorar a representação de características na classificação de radiografias de tumores ósseos. O diagrama esquemático do módulo ECA é apresentado na Fig. 7.

3.2.1.5. Camada de classificação. Os mapas de características aprimorados da camada ECA são agrupados usando GAP para redução da dimensão espacial. Posteriormente, as características agrupadas das camadas GCB e ECA são concatenadas por meio de multiplicação elemento a elemento. Essas características são então encaminhadas para uma camada de achatamento para converter o tensor 4D em um tensor 2D. Posteriormente, as características achatadas são passadas por uma camada de classificação final ativada por ReLU. A fim de otimizar o processo de treinamento do modelo, a entropia cruzada é empregada como função de perda. A perda por entropia cruzada mede a divergência entre a probabilidade prevista e os rótulos verdadeiros. Ela penaliza as previsões incorretas feitas pelo modelo com alta confiança. Isso garante que o modelo atribua probabilidades mais altas à classe correta, levando a um melhor desempenho de classificação.

3.2.2. Explicabilidade

Para garantir a interpretabilidade e validar a confiabilidade clínica do BoneVisionNet proposto, foram empregadas três técnicas de XAI: Mapeamento de Ativação de Classe Ponderado por Gradiente (Grad-CAM), Explicações Locais Interpretáveis e Independentes do Modelo (LIME) e Explicações Aditivas de Shapley (SHAP). Essas técnicas foram aplicadas após o treinamento para visualizar o processo de tomada de decisão, confirmar o foco da rede em estruturas anatômicas relevantes e verificar se as previsões se baseiam em regiões clinicamente significativas das radiografias de tumores ósseos.

O Grad-CAM foi utilizado para produzir mapas de ativação específicos por classe, aproveitando as informações de gradiente que fluem para a convolucional final

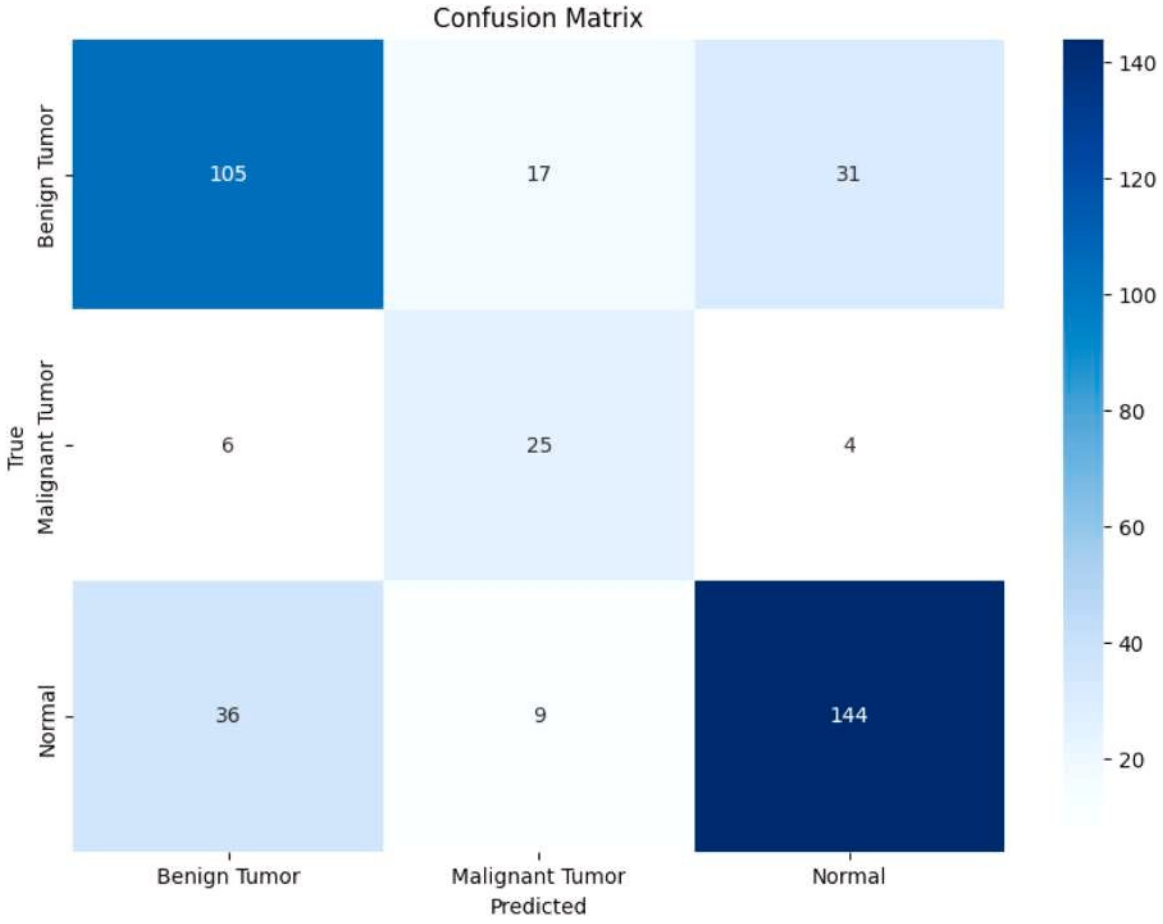

Fig. 14. Matriz de confusão para a faixa DenseNet-169.

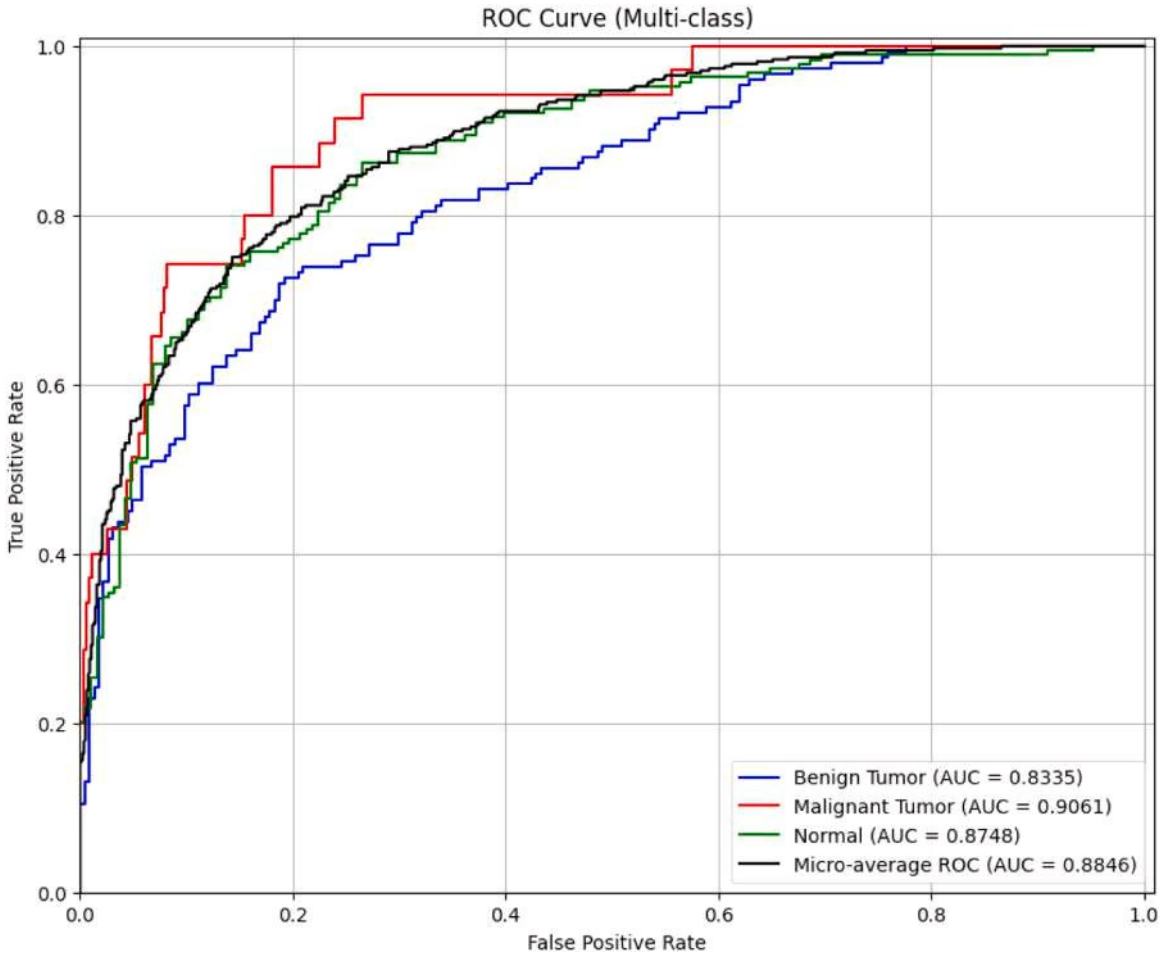

Fig. 15. Curva ROC para a faixa DenseNet-169.

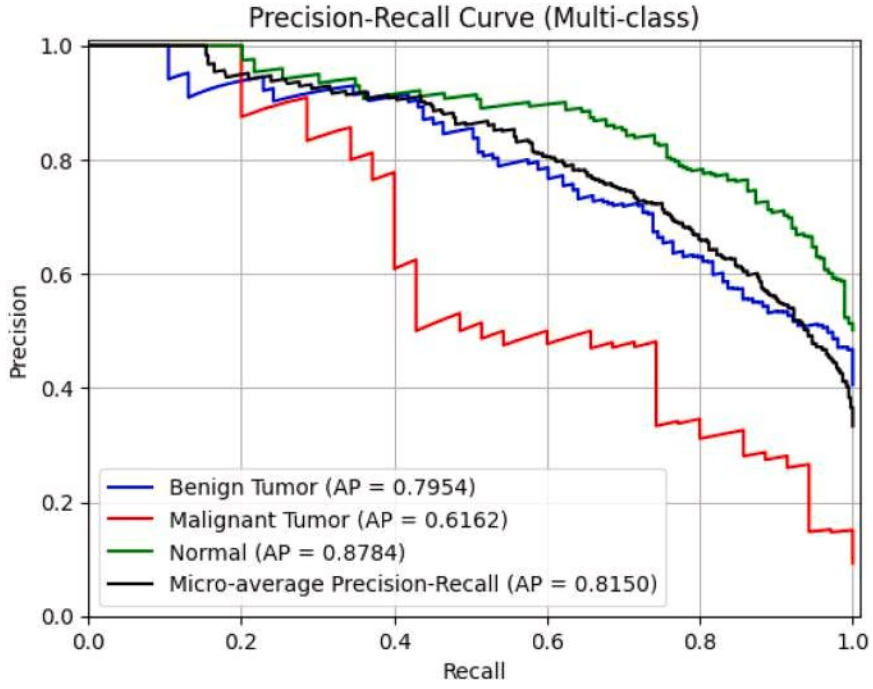

Fig. 16. Curva de precisão-recall para a faixa DenseNet-169.

Tabela 6
Métricas de desempenho por classe para as faixas ABMLFE-Net e CeiT.

Classe	Precisão (em %)	Precisão (em %)	Recuperação (em %)	F1-Score (em %)
Tumor benigno	64,05	69,01	64,05	66,44
Maligno Tumor	80,00	54,90	80,00	65,12
Normal	76,72	78,80	76,72	77,75
Total	**71,88**	**67,57**	**73,59**	**69,77**

camadas da rede (Selvaraju et al., 2017). Para o sistema proposto, o Grad-CAM foi aplicado à representação combinada de características após a etapa de fusão de três trilhas, garantindo que a visualização refletisse as contribuições das trilhas CeiT, ABMLFE-Net e DenseNet-169. O processo envolveu o cálculo dos gradientes da pontuação da classe-alvo em relação aos mapas de características e a ponderação das ativações de acordo com isso. Os mapas de calor resultantes foram normalizados e sobrepostos às radiografias originais para destacar as regiões mais influentes. Para radiografias de tumores ósseos, essas visualizações demonstram que o modelo se concentrou principalmente nas regiões tumorais e nas estruturas críticas para um diagnóstico preciso.

Além disso, o LIME foi implementado para fornecer explicações localizadas e interpretáveis no nível da região da imagem (Ribeiro et al., 2016). As radiografias foram primeiro segmentadas em superpixels, e o explicador perturbou essas regiões mascarando subconjuntos com um valor constante. Para cada versão perturbada, as previsões foram obtidas por meio da função de classificação do modelo e o efeito sobre a probabilidade de saída foi analisado. O LIME então atribuiu pontuações de importância a cada superpixel com base em seu impacto na previsão, destacando as regiões mais influentes. Essas explicações confirmam se o modelo se concentra em zonas clinicamente relevantes, em vez de fundo irrelevante ou artefatos. Foram geradas visualizações para o rótulo principal, ilustrando a progressão da granularidade da interpretabilidade.

Por fim, o SHAP foi implementado utilizando a estrutura Deep SHAP para fornecer uma análise de atribuição da importância das características ao nível do pixel (Lundberg e Lee, 2017). Este método utiliza valores de Shapley, provenientes da teoria dos jogos cooperativos, para distribuir de forma justa as contribuições dos pixels de entrada para a saída do modelo. Para esta implementação, foi utilizado um máscara de desfoque para a perturbação, com uma avaliação de conjunto máximo e um tamanho de lote de 32 para um cálculo eficiente. Os valores de saída do SHAP foram visualizados como mapas de calor, nos quais cores quentes (vermelho) representam contribuições positivas para a previsão de uma classe e cores frias (azul) indicam contribuições negativas. Para a classificação de tumores ósseos, o SHAP fornece uma visão detalhada e minuciosa do comportamento do modelo, verificando se as características mais discriminatórias do tumor estão impulsionando as previsões, em vez de ruído de fundo irrelevante.

4. Resultados

Nesta seção, é discutida a configuração do ambiente utilizada para o treinamento e a avaliação do modelo. A seção seguinte aborda o processo de ajuste de hiperparâmetros, seguido por um resumo dos estudos de ablação e da visualização XAI. Na seção final, a rede proposta é testada em conjuntos de dados externos para uma avaliação mais abrangente.

4.1. Configuração do ambiente

Esta seção descreve a configuração do ambiente utilizada para o treinamento e a avaliação do modelo. O sistema proposto foi implementado e avaliado utilizando a estrutura PyTorch na versão 2.6.0, garantindo compatibilidade com técnicas e ferramentas modernas de DL. Todos os experimentos

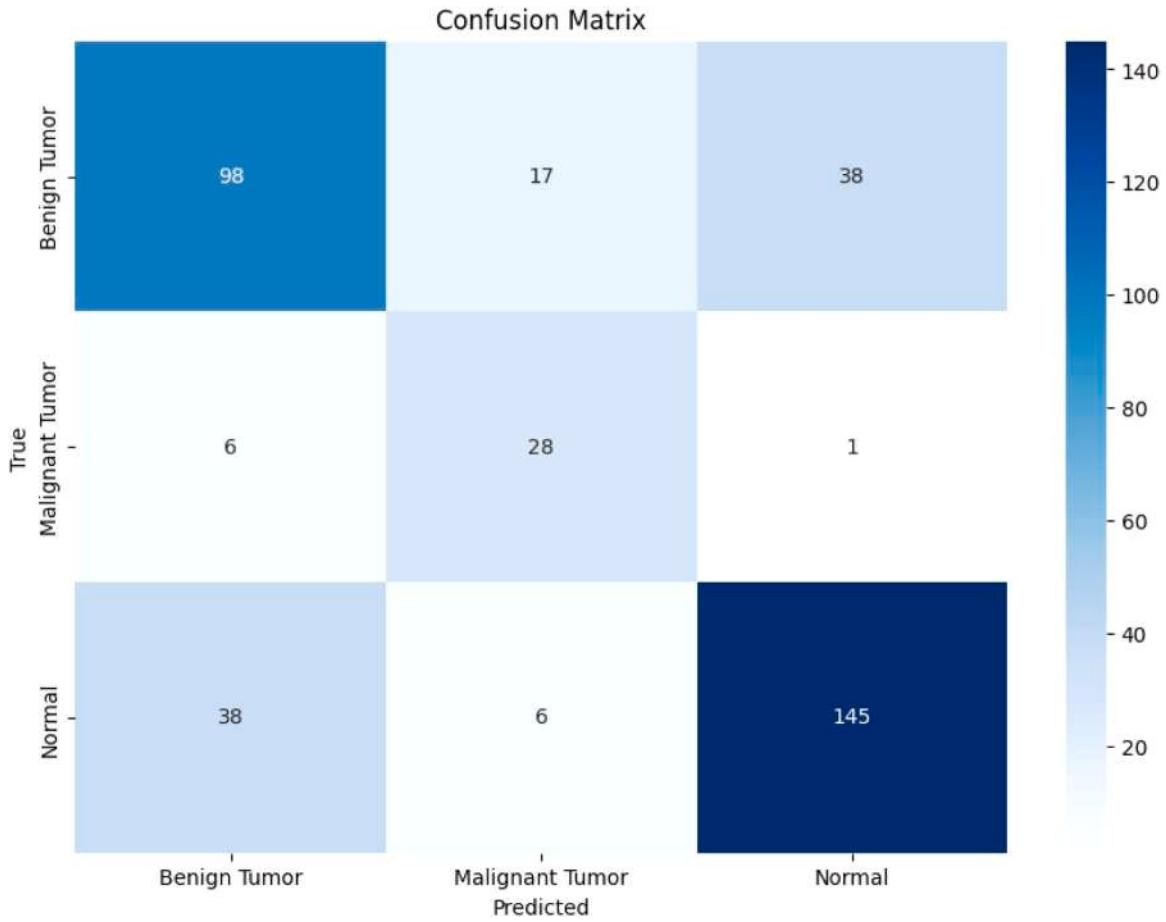

Fig. 17. Matriz de confusão para as faixas ABMLFE-Net e CeiT.

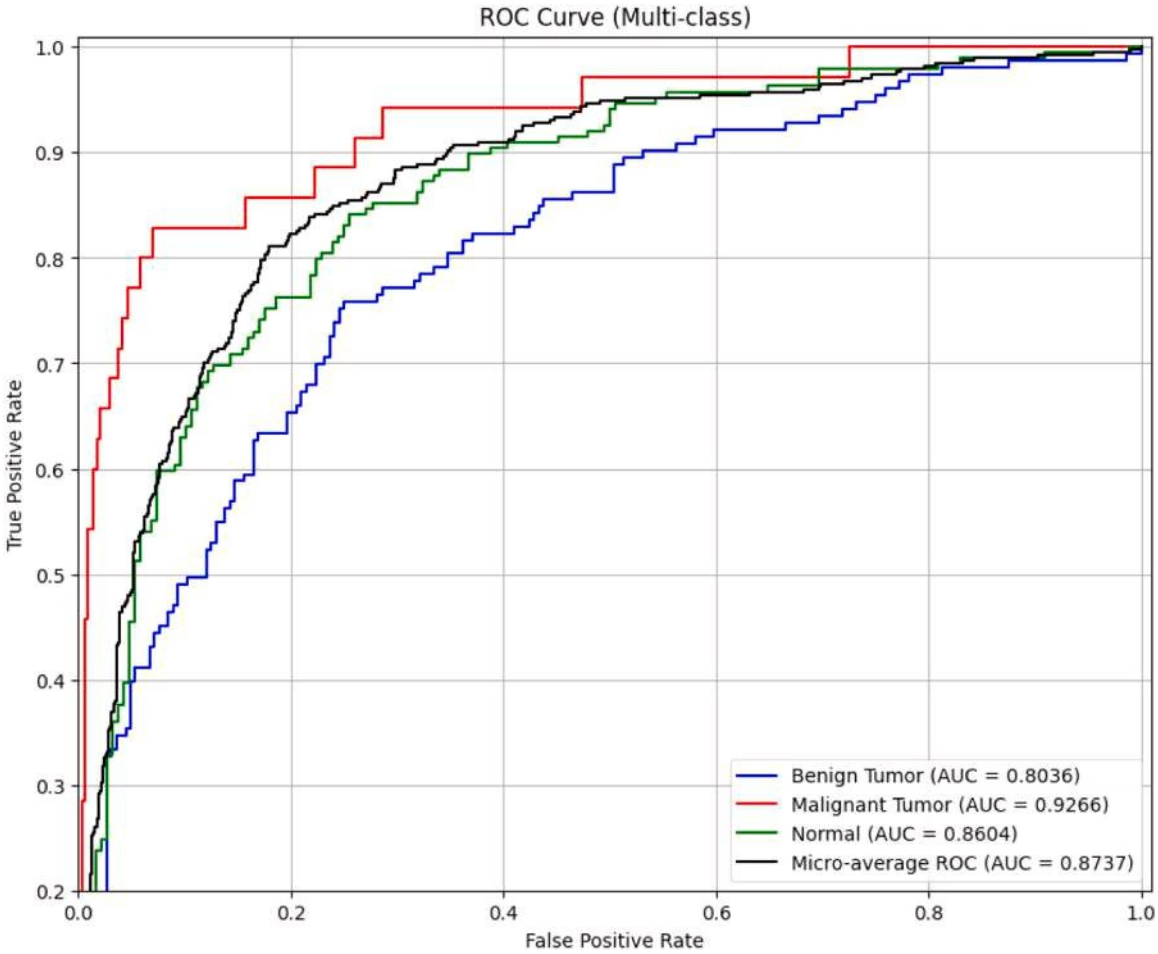

Fig. 18. Curva ROC para as faixas ABMLFE-Net e CeiT.

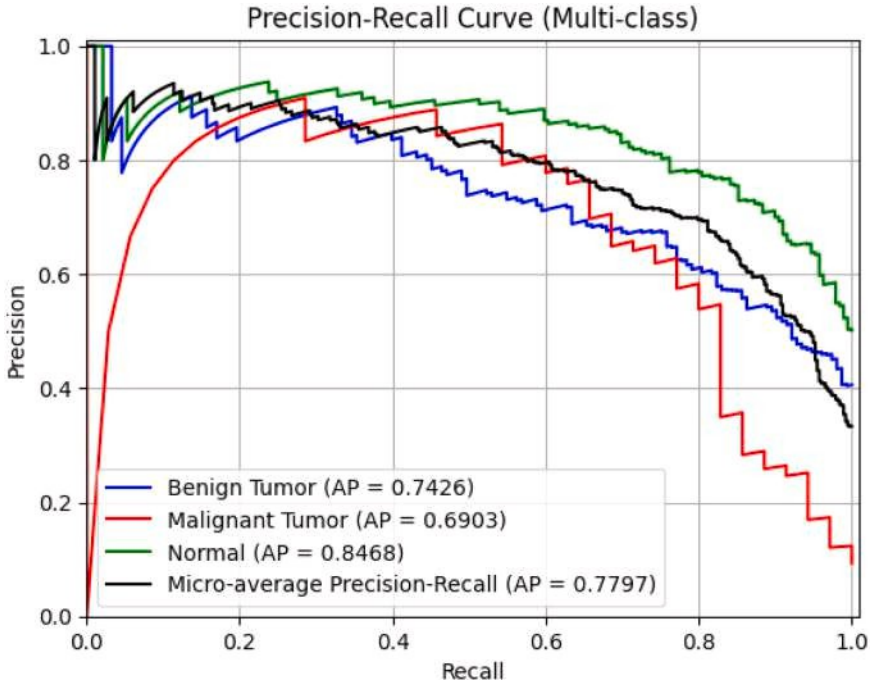

Fig. 19. Curva de precisão-recall para as faixas ABMLFE-Net e CeiT.

Tabela 7
Métricas de desempenho por classe para as faixas ABMLFE-Net e DenseNet-169.

Classe	Precisão (em %)	Precisão (em %)	Recuperação (em %)	F1-Score (em %)
Tumor benigno	79,74	72,19	79,74	75,78
Tumor maligno	88,57	50,82	88,57	64,58
Normal	70,37	90,48	70,37	79,17
Total	**75,86**	**71,16**	**79,56**	**73,18**

foram realizadas no Google Colab, aproveitando seus recursos baseados em nuvem para garantir eficiência computacional e escalabilidade. A configuração de hardware incluiu uma CPU Intel Xeon e uma GPU NVIDIA Tesla K80 com 12 GB de VRAM, permitindo o tratamento eficaz de grandes conjuntos de dados e arquiteturas de DL.

4.2. Ajuste de hiperparâmetros

Esta seção descreve a importância do ajuste de hiperparâmetros, especialmente no que diz respeito ao desempenho e à estabilidade do modelo durante o treinamento, o que é alcançado através do equilíbrio entre a aceleração da convergência, a precisão e a generalização do modelo. Os parâmetros ajustados nesta investigação incluem o tamanho do lote, a taxa de aprendizagem, a decaimento dos pesos, o tamanho do passo do programador de taxa de aprendizagem, a função de perda e o otimizador. Para encontrar a melhor combinação desses parâmetros, foi empregado o algoritmo de busca em grade. Esse método permite uma avaliação sistemática de muitas combinações de parâmetros, garantindo que os valores que mais melhoram o desempenho do modelo tenham sido selecionados. Um resumo detalhado dos resultados do ajuste de hiperparâmetros é apresentado, incluindo os valores ótimos selecionados para o modelo final na Tabela 2.

4.3. Estudos de ablação

Nesta seção, são realizados estudos de ablação para avaliar a contribuição de vários subcomponentes na arquitetura proposta.

Estudos de ablação ajudam a garantir que todos os componentes essenciais utilizados em
o BoneVisionNet proposto melhora o desempenho na classificação de radiografias de tumores ósseos.

4.3.1. Avaliação da categoria CeiT

Esta seção avalia o desempenho da trilha CeiT para
classificação de tumores por raios X. Na rede BoneVisionNet proposta, o CeiT foi utilizado como o primeiro track para extrair características globais de forma eficiente. O track CeiT foi treinado no conjunto de dados BTXRD por 100 épocas, utilizando o otimizador ADAM. Quando testado no conjunto de dados BTXRD, o modelo CeiT atingiu uma precisão de 69,23 %, com precisão, recall e pontuação F1 de
61,98%, 66,27% e 63,08%, respectivamente. As métricas por classe para a trilha CeiT são apresentadas na Tabela 3. Além disso, a matriz de confusão, a curva ROC e as curvas de precisão-recall são apresentadas nas Figuras 8–10.

4.3.2. Avaliação da ABMLFE-Net

Nesta seção, é avaliado o desempenho da rede ABMLFE-Net na classificação de radiografias de tumores ósseos. A rede ABMLFE-Net é utilizada como o segundo módulo de extração de características na rede proposta, aproveitando sua capacidade de extrair características integrais de nível intermediário das imagens radiográficas. A rede ABMLFE-Net passou por um treinamento de 100 épocas e foi posteriormente avaliada no conjunto de dados BTXRD. O modelo atingiu uma precisão de 70,82 %, enquanto a precisão, o recall e os escores F1 foram de 63,41 %, 65,50 % e 64,26 %, respectivamente. A fim de avaliar exaustivamente o desempenho da ABMLFE-Net, a matriz de confusão, a curva ROC e as curvas de precisão-recall foram plotadas e visualizadas na

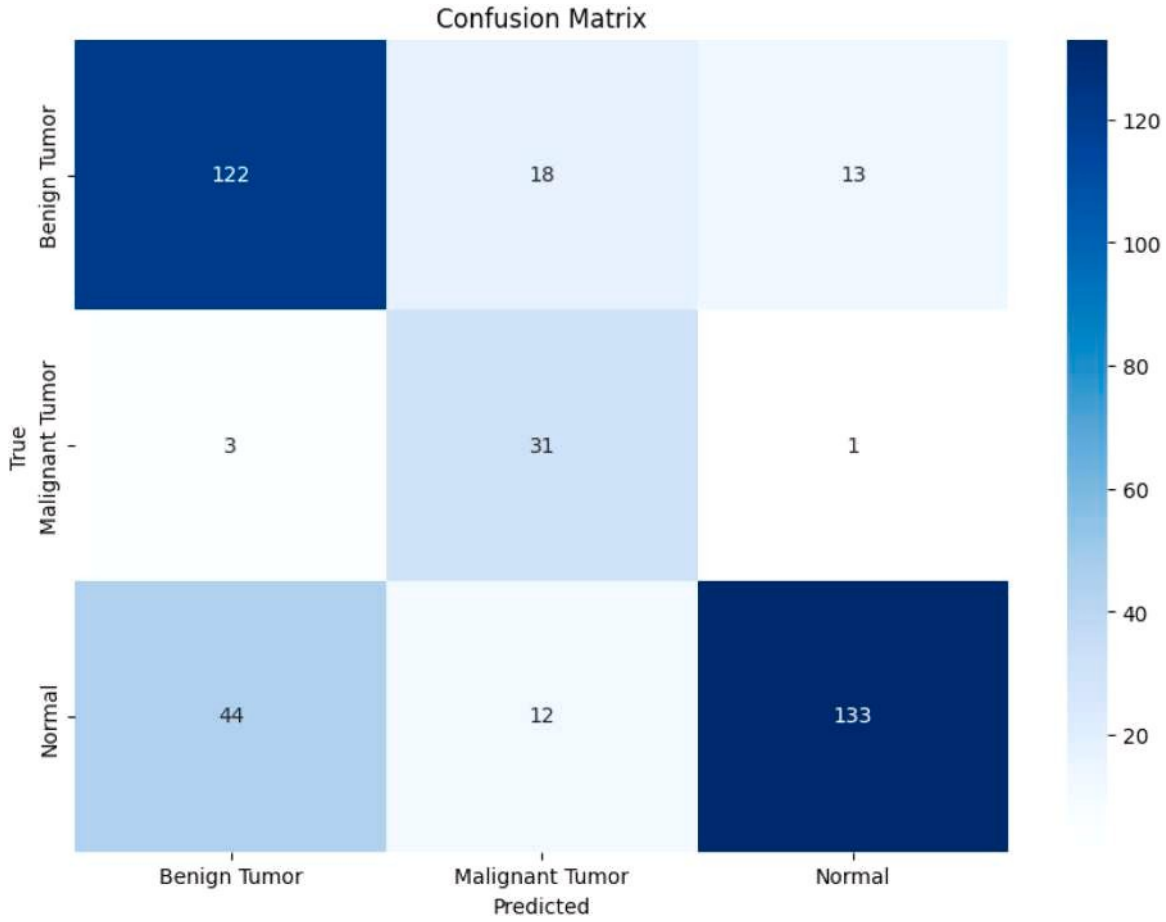

Fig. 20. Matriz de confusão para as faixas ABMLFE-Net e DenseNet-169.

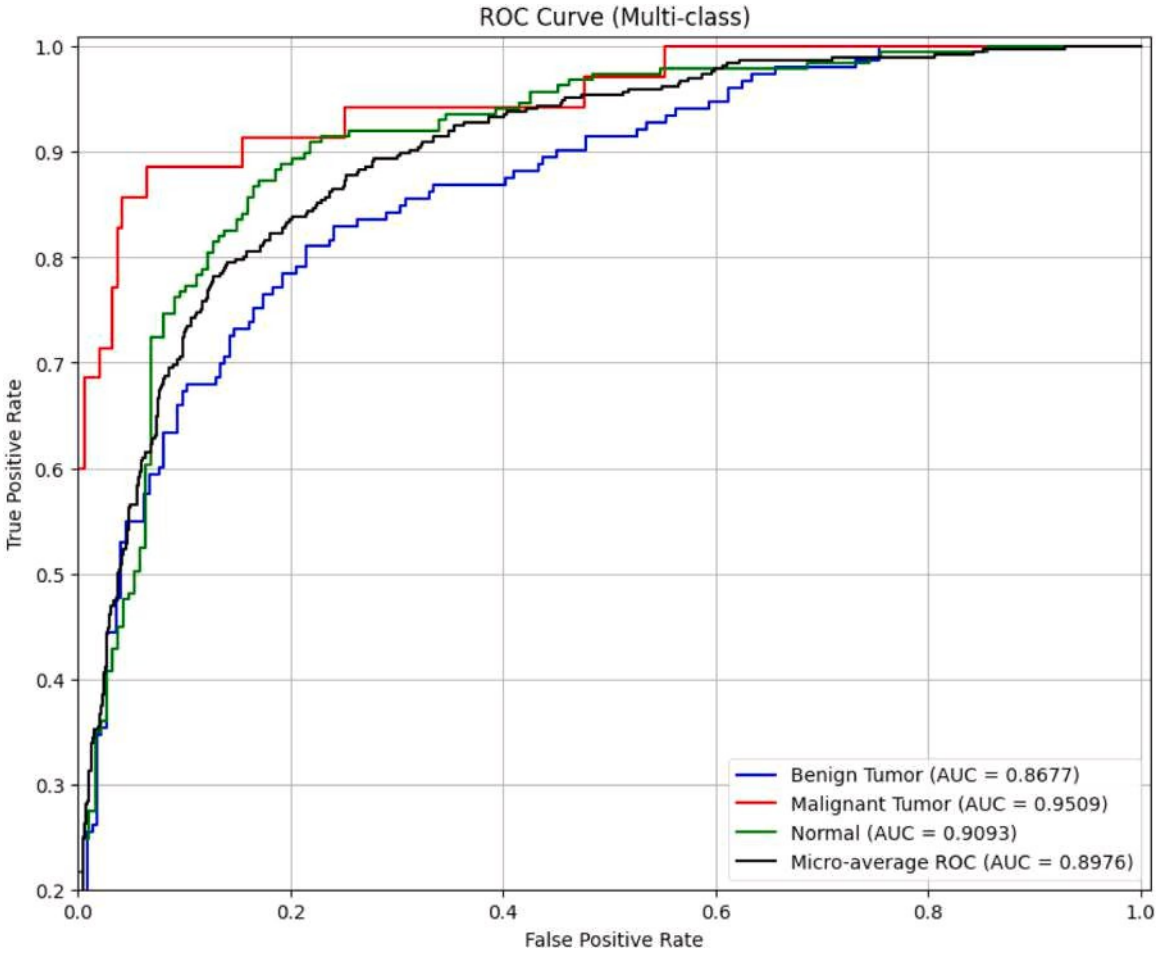

Fig. 21. Curva ROC para as faixas ABMLFE-Net e DenseNet-169.

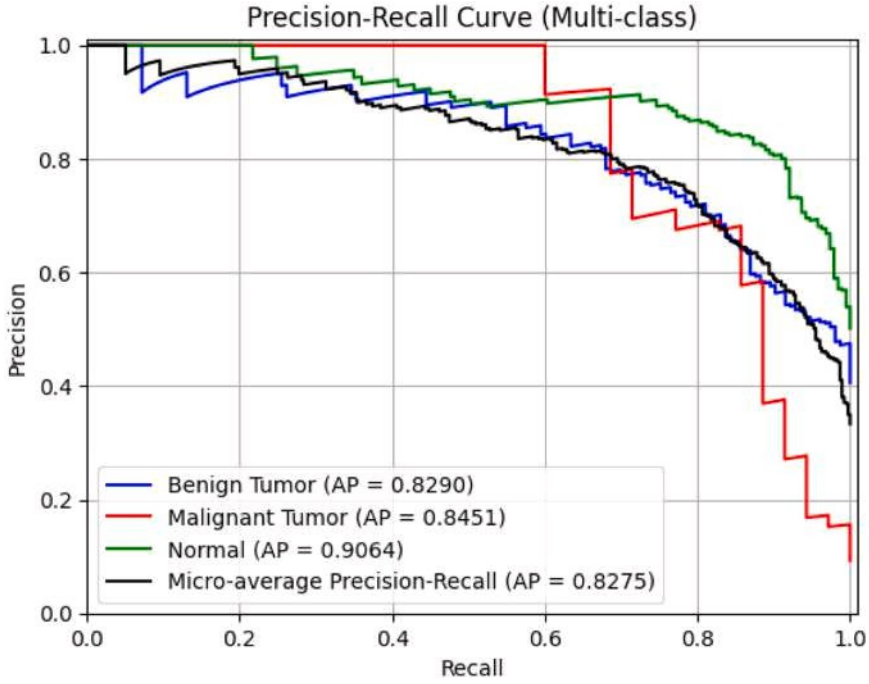

Fig. 22. Curva de precisão-recall para as faixas ABMLFE-Net e DenseNet-169.

Tabela 8
Métricas de desempenho por classe para as faixas CeiT e DenseNet-169.

Classe	Precisão (em %)	Precisão (em %)	Recuperação (em %)	F1-Score (em %)
Tumor benigno	67,32	82,40	67,32	74,10
Maligno Tumor	74,29	70,27	74,29	72,22
Normal	88,36	77,67	88,36	82,67
Total	**78,52**	**76,78**	**76,66**	**76,33**

Fig. 11–13. Além disso, as métricas por classe são apresentadas na Tabela 4.

4.3.3. *Avaliação da linha DenseNet*

Esta seção avalia o desempenho da linha DenseNet-169, que funciona como a terceira linha de extração de características na rede proposta, com foco na extração de características locais. O modelo DenseNet foi treinado por 100 épocas no conjunto de dados BTXRD utilizando o otimizador ADAM. Durante os testes, a rede atingiu uma precisão de 72,68 %, precisão de 66,97 %, recall de 72,08 % e F1-Score de 68,80. A Tabela 5 resume o desempenho por classe da trilha DenseNet-169 no conjunto de dados BTXRD. A matriz de confusão, a curva ROC e as curvas de precisão-recall são apresentadas nas Figuras 14–16.

4.3.4. *Avaliação das faixas ABMLFE-Net e CeiT*

Esta seção apresenta a avaliação das vias combinadas ABMLFE-Net e CeiT, responsáveis pela extração de características de nível médio e globais, respectivamente. As saídas de ambas as vias foram concatenadas para criar um mapa de características fusionado, aproveitando assim a natureza complementar das características globais e de nível médio para melhorar o desempenho da classificação. O modelo combinado de duas vias foi treinado por 100 épocas no conjunto de dados BTXRD usando o otimizador ADAM e, posteriormente, avaliado. Após o teste, a configuração de duas trilhas alcançou uma precisão de 71,88 %, com uma precisão de 67,57 %, recall de 73,59 % e um F1-Score de 69,77 %. Esses resultados indicam que a integração do CeiT e do ABMLFE-Net melhora a representação de características em comparação com o desempenho de cada um isoladamente. As métricas de desempenho por classe para essa combinação de duas redes estão resumidas na Tabela 6. Além disso, a matriz de confusão, a curva ROC e as curvas de precisão-recall correspondentes a essa avaliação são apresentadas nas Figuras 17–19.

4.3.5. *Avaliação das faixas ABMLFE-Net e DenseNet-169*

Esta seção avalia o desempenho combinado das faixas ABMLFE-Net e DenseNet-169, responsáveis pela extração de características de nível médio e local, respectivamente. As saídas de ambas as faixas foram concatenadas para formar um mapa de características rico que aprimora a capacidade discriminatória do modelo. A configuração combinada das faixas foi treinada no conjunto de dados BTXRD por 100 épocas utilizando o otimizador ADAM e, posteriormente, testada. Os resultados da avaliação demonstram que a combinação de duas trilhas alcançou uma precisão de 75,86%, com uma precisão de 71,16%, recall de 79,56% e um F1-Score de 73,18%. Esses resultados destacam a eficácia da combinação de representações de características de nível médio e local para melhorar a precisão da classificação. As métricas de desempenho por classe são apresentadas na Tabela 7, enquanto a matriz de confusão, a curva ROC e as curvas de precisão-recall são ilustradas nas Figs. 20–22.

4.3.6. *Avaliação das faixas CeiT e DenseNet-169*

Esta subseção apresenta o desempenho da configuração que combina CeiT e DenseNet-169, que, em conjunto, se concentram na captura de representações de características globais e locais de tumores ósseos

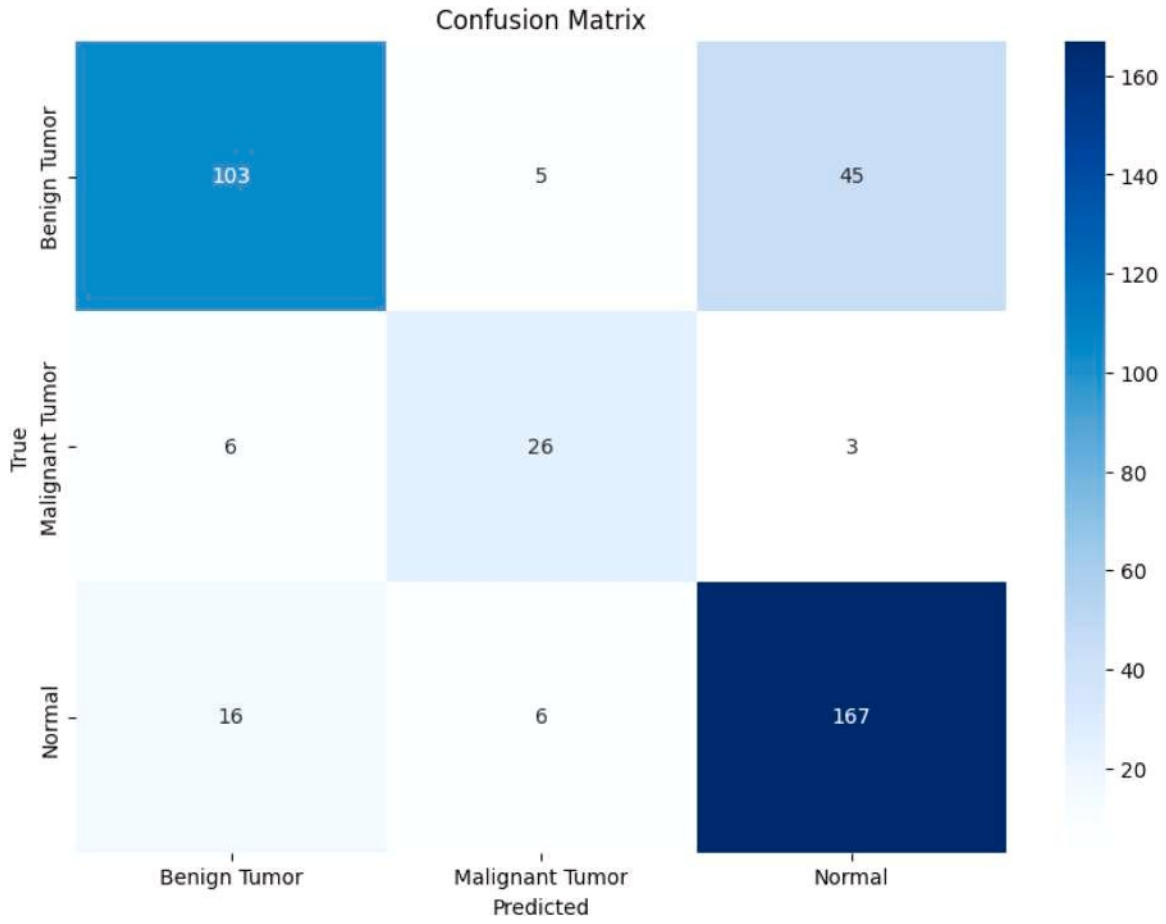

Fig. 23. Matriz de confusão para as faixas CeiT e DenseNet-169.

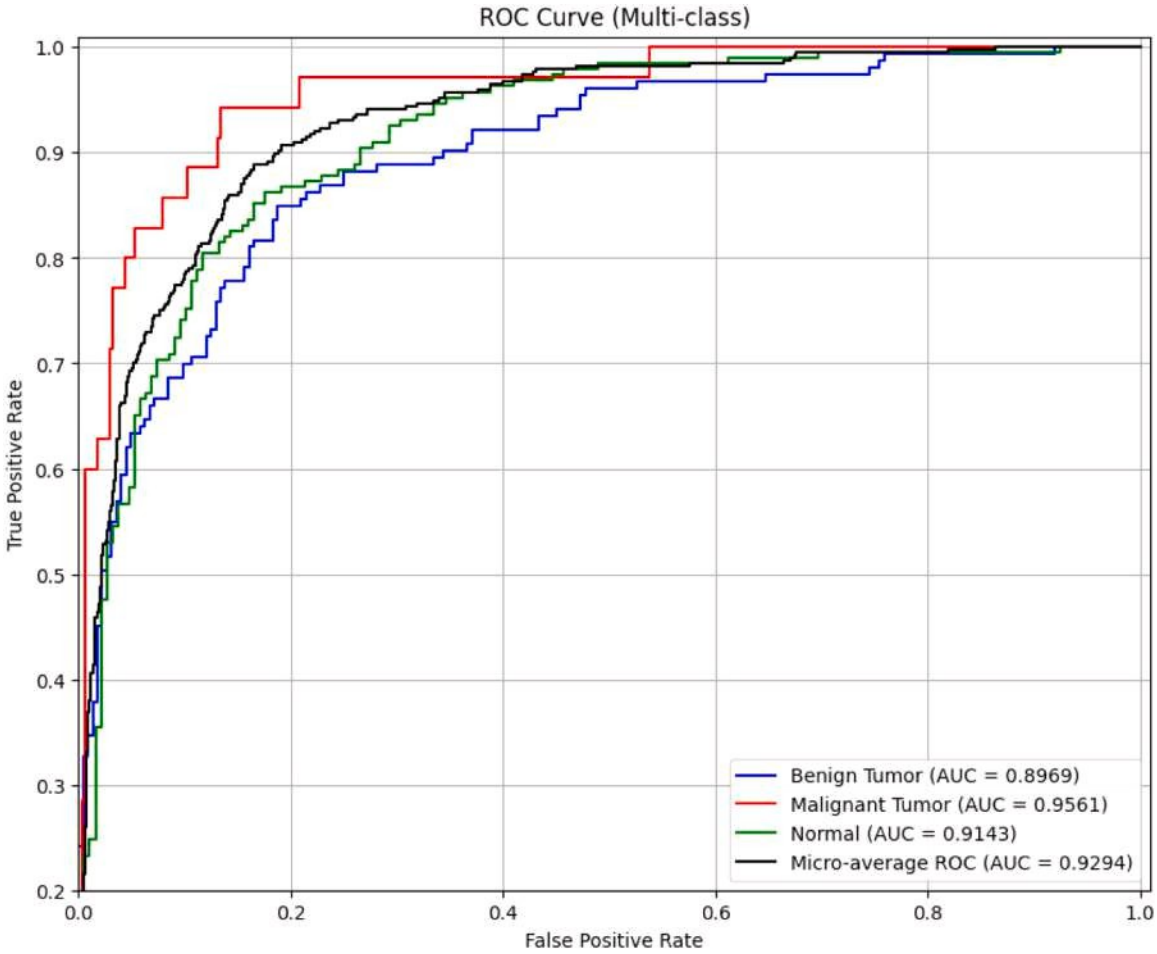

Fig. 24. Curva ROC para as faixas CeiT e DenseNet-169.

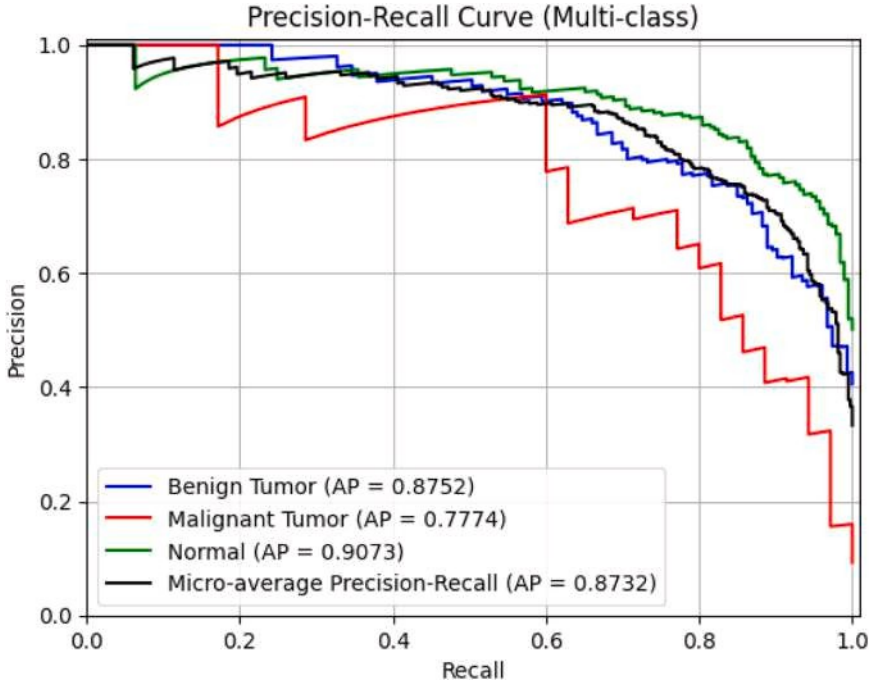

Fig. 25. Curva de precisão-recall para as faixas CeiT e DenseNet-169.

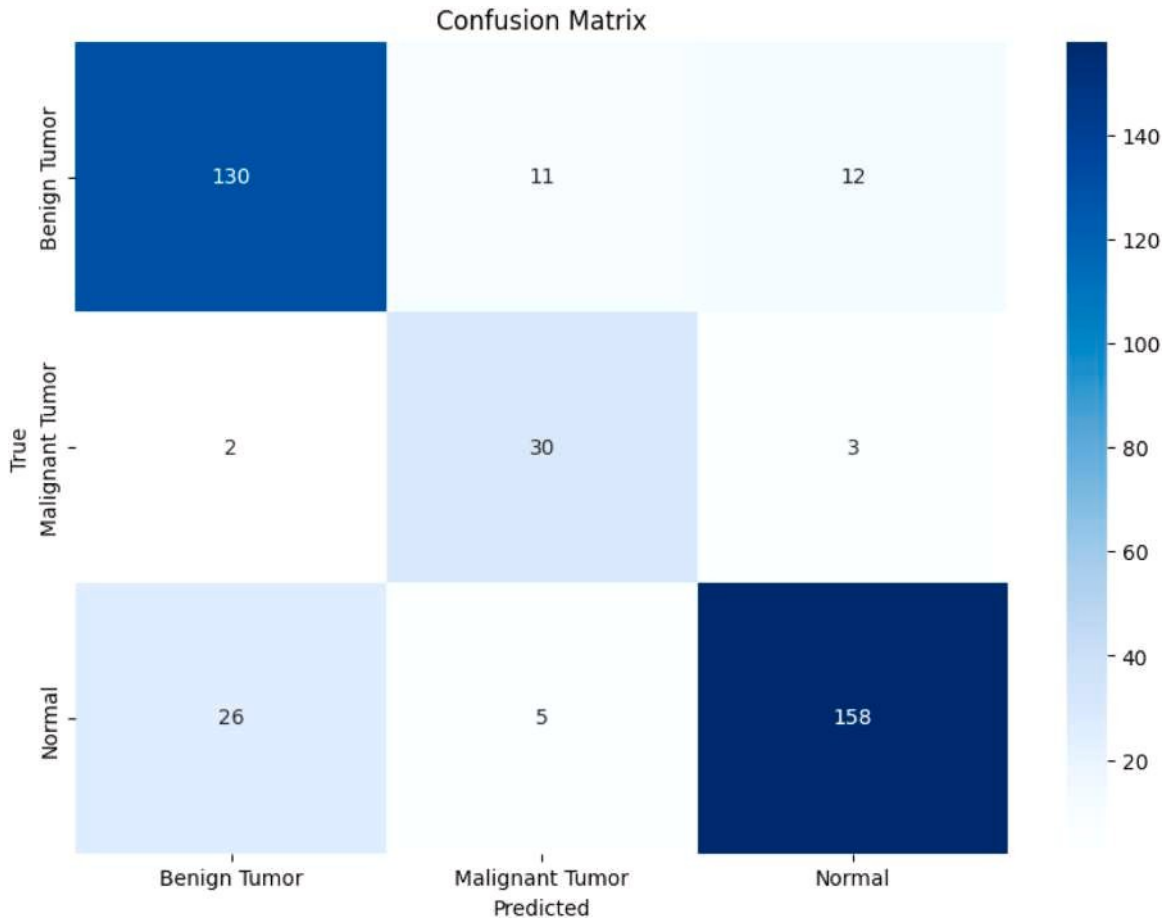

Fig. 26. Matriz de confusão para o BoneVisionNet.

radiografias. Enquanto o CeiT se especializa na extração de características contextuais de alto nível em toda a imagem, o DenseNet-169 enfatiza detalhes espaciais minuciosos, garantindo uma representação abrangente. Para este experimento, os mapas de características gerados por ambas as vias foram combinados para criar uma representação unificada das informações globais e locais. O modelo foi treinado no conjunto de dados BTXRD por 100 épocas usando o otimizador ADAM. Durante os testes, essa configuração de duas trilhas alcançou uma precisão de 78,52%, juntamente com uma precisão de 76,78%, recall de 76,66% e um F1-Score de 76,33%. Os resultados demonstram que a integração de características globais e locais melhora a capacidade de classificação em comparação com as faixas individuais. As métricas de desempenho por classe para essa combinação são apresentadas na Tabela 8, enquanto a matriz de confusão, a curva ROC e os gráficos de precisão-recall são ilustrados nas Figuras 23–25.

4.3.7. *Avaliação da rede proposta*

Esta seção examina os resultados obtidos pelo modelo Bone-VisionNet proposto para a classificação de radiografias de tumores ósseos. O conjunto de dados BTXRD foi utilizado para treinar o modelo proposto com o otimizador ADAM, tendo os hiperparâmetros sido ajustados para obter o máximo desempenho. O modelo passou por um treinamento de 100 épocas e, posteriormente, foi testado quanto ao desempenho de classificação. Quando testado no conjunto de dados BTXRD, o modelo atingiu 84,35% de acurácia, 79,61% de precisão, 84,76% de recall e um F1-score de 81,66%. A fim de realizar uma análise completa do desempenho do modelo, foram plotadas a matriz de confusão, a curva ROC e a curva de precisão-recall, conforme mostrado nas Figs. 26, 27 e 28. Esses resultados destacam a eficácia da rede proposta na classificação de imagens de tumores ósseos. As métricas por classe para a BoneVisionNet proposta são apresentadas na Tabela 9. Um resumo dos estudos de ablação é fornecido na Tabela 10. Para validar ainda mais a confiabilidade da BoneVisionNet proposta, Grad-CAM e LIME foram utilizados para visualizar o processo de tomada de decisão do modelo. Os resultados são apresentados na Tabela 11, que mostra a imagem original, uma imagem clinicamente anotada e as visualizações correspondentes do Grad-CAM e do LIME. Além disso, o SHAP foi utilizado para uma análise detalhada de atribuição da importância das características, ao nível do pixel, com os resultados apresentados na Tabela 12.

4.4. *Avaliação em uma configuração de classificação binária*

Nesta seção, o BoneVisionNet proposto foi avaliado em uma configuração de classificação binária para se adequar a um cenário clinicamente mais relevante. Para este experimento, foram consideradas apenas as classes de tumor benigno e tumor maligno do conjunto de dados BTXRD, excluindo a classe normal. Essa configuração reflete os fluxos de trabalho diagnósticos do mundo real, nos quais o principal objetivo clínico é determinar se o tumor é benigno ou maligno. Quando avaliado nessa tarefa de classificação binária, o BoneVisionNet alcançou uma precisão de 93,62%, com uma precisão de 88,89%, recall de 90,57% e um F1-Score de 89,69%, demonstrando sua forte capacidade em diferenciar tumores ósseos benignos e malignos. As precisões por classe para essa configuração de classificação binária são apresentadas na Tabela 13.

4.5. *Avaliação em conjuntos de dados externos*

Nesta seção, o modelo proposto é avaliado em diversos conjuntos de dados médicos, a fim de verificar a generalização e a robustez do modelo em vários cenários clínicos.

4.5.1. *Validação em conjunto de dados para detecção de tuberculose usando radiografias*

Para avaliar a robustez do modelo proposto, ele foi testado no conjunto de dados Sakha-TB, disponível publicamente, que compreende imagens anotadas

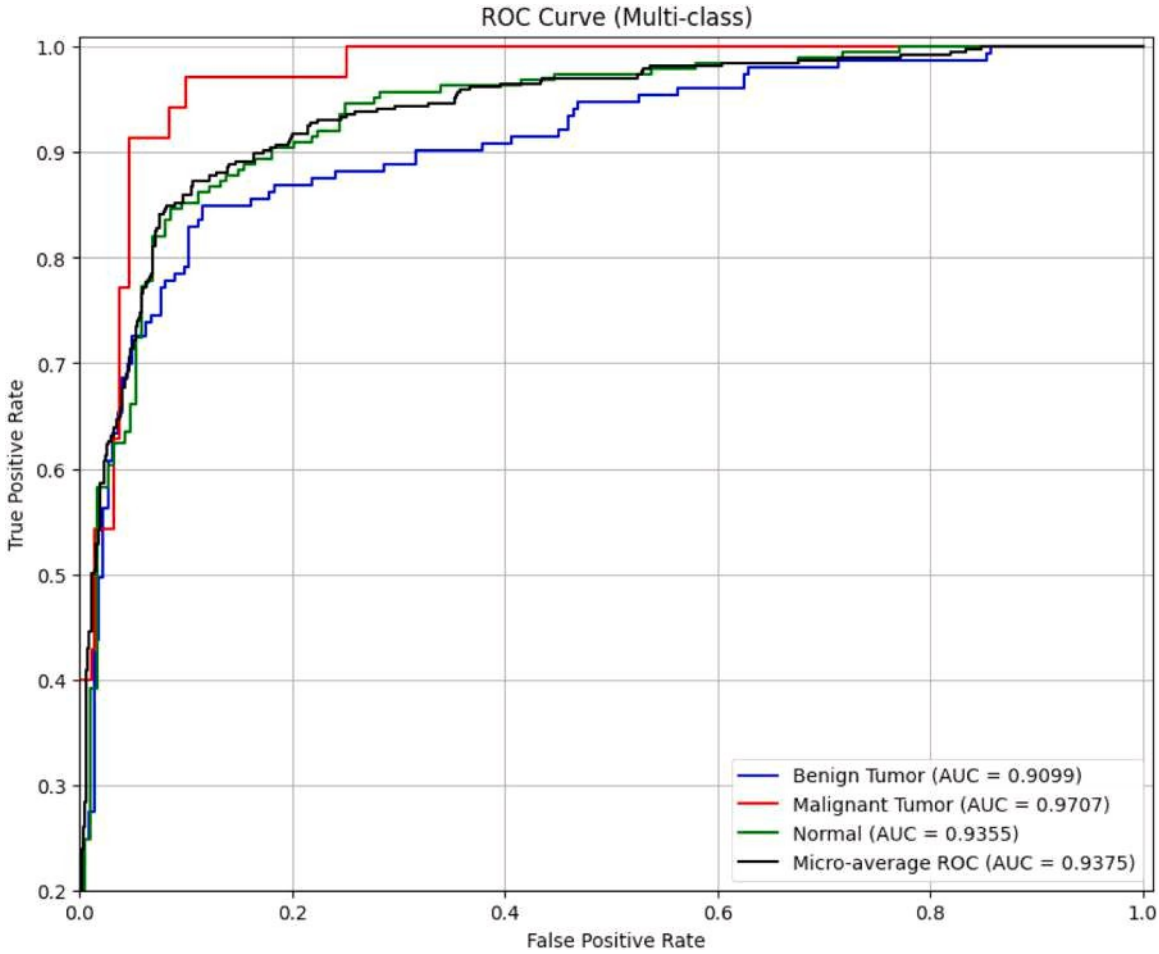

Fig. 27. Curva ROC para o sistema proposto.

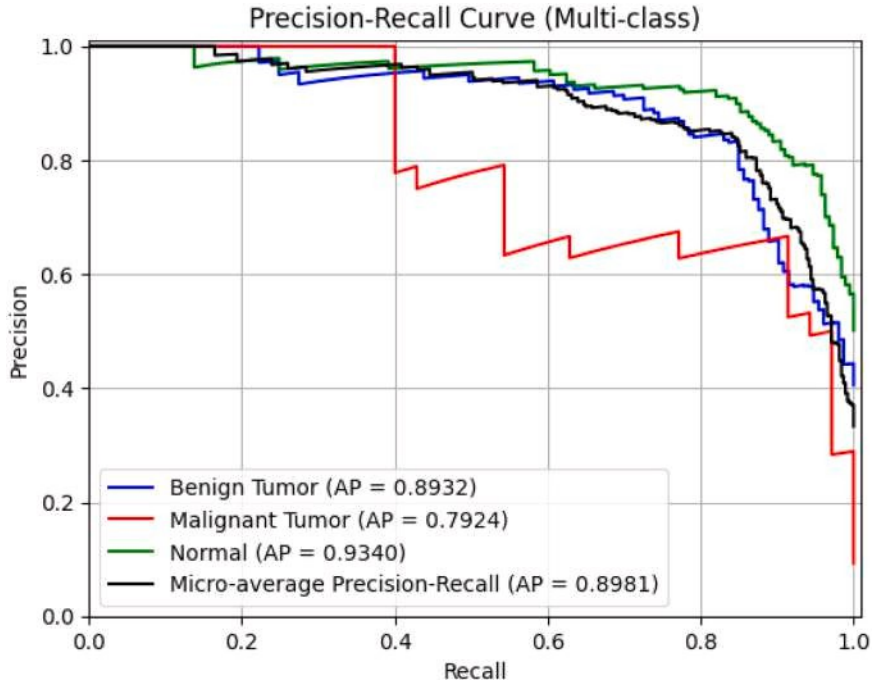

Fig. 28. Curva de precisão-recall para o modelo proposto.

Tabela 9
Métricas de desempenho por classe para o BoneVisionNet.

Classe	Precisão (em %)	Precisão (em %)	Recuperação (em %)	F1-Score (em %)
Tumor benigno	84,97	82,28	84,97	83,60
Maligno Tumor	85,71	65,22	85,75	74,07
Normal	83,60	91,33	83,60	87,30
Total	**84,35**	**79,61**	**84,76**	**81,66**

imagens de radiografia de tórax divididas igualmente entre indivíduos saudáveis e pacientes com tuberculose (Pchelintsev et al., 2022). O conjunto de dados foi organizado para garantir equilíbrio em termos de gênero, distribuição etária e categorias diagnósticas, com cada imagem representando um paciente único. O diagnóstico foi confirmado por meio de leituras duplas independentes, validadas por dados clínicos, laboratoriais e microbiológicos. Quando testado neste conjunto de dados, o modelo alcançou uma precisão de 85,04%, com precisão, recall e F1-score atingindo 85,25%, 85,00% e 84,97%, respectivamente.

4.5.2. Validação em conjunto de dados para detecção de fraturas ósseas por meio de radiografias. A fim de verificar a eficácia e a generalizabilidade do Bone-VisionNet, ele foi testado em um conjunto de dados FracAtlas disponível publicamente (Abedeen et al., 2023). O conjunto de dados contém 4.083 imagens de raios-X, cada uma delas rotulada manualmente em uma de duas classes: fraturada e não fraturada. A anotação foi realizada na plataforma de rotulagem de código aberto makesense.ai, que foi posteriormente validada por dois radiologistas experientes e um ortopedista. O conjunto de dados contém imagens de diferentes partes da anatomia, incluindo mão, perna, quadril e ombro, que foram obtidas de três hospitais e centros de diagnóstico diferentes. Quando testado no conjunto de dados FracAtlas, o modelo atingiu 90,34% de precisão, com precisão, recall e F1-score atingindo 89,86%, 90,34% e 89,66 %, respectivamente.

4.5.3. Validação em conjunto de dados para classificação de tumores de mama utilizando radiografias

Para avaliar melhor a eficácia do modelo proposto, ele foi testado no conjunto de dados Mammogram Mastery, disponível publicamente, que consiste em imagens de mamografia coletadas em quatro unidades de saúde (Aqdar et al., 2024). O conjunto de dados inclui imagens capturadas com equipamentos dedicados de mamografia, cada uma representando uma paciente única com idade entre 34 e 88 anos. O conjunto de dados é categorizado em classes benignas e malignas. Radiologistas e médicos especialistas anotaram e validaram o conjunto de dados para garantir a precisão do diagnóstico. O modelo alcançou alto desempenho neste conjunto de dados, com uma precisão de 97,33%, precisão de 98,44%, recall de 92,31% e um F1-score de 95,04%.

5. Discussão

Nesta seção, é apresentada uma visão geral dos diversos estudos realizados para avaliar o desempenho do modelo. A primeira seção inclui uma discussão sobre a visualização XAI para interpretar as decisões tomadas pelo modelo e aumentar a transparência na classificação. A seção seguinte contém uma comparação detalhada do Bone-VisionNet proposto com as arquiteturas de aprendizagem profunda (DL) de última geração. Por fim, o modelo é validado em vários conjuntos de dados médicos para verificar sua generalização e robustez em diversos cenários médicos.

5.1. Visualizações XAI

A aplicação de técnicas de XAI forneceu informações valiosas sobre o processo de tomada de decisão do BoneVisionNet e confirmou sua confiabilidade clínica. As visualizações do Grad-CAM revelaram que o modelo prestava atenção de forma consistente a regiões específicas do tumor nas imagens de raios-X, o que se alinha fortemente com as anotações de um especialista experiente em tumores ósseos. Esse alinhamento sugere que o modelo está aproveitando padrões clinicamente relevantes, em vez de se basear em correlações espúrias. Uma análise complementar utilizando o LIME reforçou essas descobertas ao destacar regiões localizadas e detalhes no nível de pixels, demonstrando que a sensibilidade do modelo se estende a características específicas do tumor. Além disso, o SHAP adicionou uma camada de interpretabilidade mais profunda ao atribuir quantitativamente as contribuições de pixels individuais às previsões do modelo. O contraste entre contribuições positivas e negativas nos mapas de calor do SHAP proporciona uma compreensão matizada da importância das características, reforçando que as previsões são impulsionadas por características discriminatórias relacionadas ao tumor. Juntas, essas avaliações de XAI confirmam que as previsões do BoneVisionNet não são apenas precisas, mas também explicáveis, um fator essencial para a adoção clínica. A integração de Grad-CAM, LIME e SHAP garante transparência tanto em nível global quanto em detalhes, o que aumenta a confiabilidade e apoia seu uso em fluxos de trabalho de diagnóstico no mundo real.

5.2. Análise dos exemplos classificados incorretamente

Embora o modelo proposto demonstre alta precisão na classificação de tumores por meio de radiografias, certos casos foram classificados incorretamente, destacando a necessidade de análises adicionais. As visualizações do Grad-CAM, conforme apresentadas na Tabela 14, fornecem insights sobre esses casos, revelando que a atenção do modelo foi, por vezes, direcionada para regiões irrelevantes ou ambíguas das radiografias. Fatores potenciais que contribuem para as classificações incorretas incluem limites indistintos dos tumores e tumores muito pequenos. Ao utilizar técnicas de XAI, como o Grad-CAM, torna-se possível validar o processo de classificação, identificar possíveis causas de erros e melhorar a confiabilidade. Essas visualizações permitem que os médicos avaliem o foco do modelo e garantam que as previsões sejam baseadas em características clinicamente relevantes. Isso reduz o risco de diagnósticos incorretos e aumenta a confiança nos sistemas automatizados para classificação de tumores.

5.3. Comparação com arquiteturas de última geração

Esta subseção compara o desempenho da BoneVisionNet com o de CNNs e Transformers de última geração. Como o conjunto de dados foi lançado recentemente, não há estudos existentes para comparação no conjunto de dados BTXRD. Portanto, para a comparação de desempenho, foram analisadas 15 redes, consistindo em 8 CNNs e 7 Transformers. Todos os modelos foram treinados utilizando o conjunto de dados BTXRD, para garantir uma avaliação comparativa justa. Entre as redes treinadas, a DenseNet emergiu como a CNN mais precisa, com 72,68% de precisão. Isso é indicativo da eficiência da DenseNet na extração de características locais. No mesmo contexto, a CeiT foi a rede transformadora mais precisa, com 69,23% de precisão, o que demonstra sua eficiência na extração de características globais. A proposta

Tabela 10
Resumo dos estudos de ablação no conjunto de dados BTXRD.

Modelo	Parâmetros	Tempo de inferência (em ms)	Precisão (em %)	Precisão (em %)	Recall (em %)	Pontuação F1 (em %)
Pista CeiT	6164.483	0,63	69,23	61,98	66,27	63,08
ABMLFE-Net	4.013.019	0,70	70,82	63,41	65,50	64,26
Trilha DenseNet-169	12.489.475	0,92	72,68	66,97	72,08	68,80
ABMLFE-Net + CeiT	10.178.083	0,79	71,88	67,57	73,59	69,77
ABMLFE-Net + DenseNet	16.499.163	1,16	75,86	71,16	79,56	73,18
CeiT + DenseNet	18.651.206	1,34	78,52	76,78	76,66	76,33
Modelo proposto	**22.723.825**	**1,61**	**84,35**	**79,61**	**84,76**	**81,66**

Tabela 11
Visualizações XAI de tumores a partir do conjunto de dados BTXRD.

	Tumor benigno	Tumor maligno	Tumor benigno
Imagem de entrada			
Imagem anotada	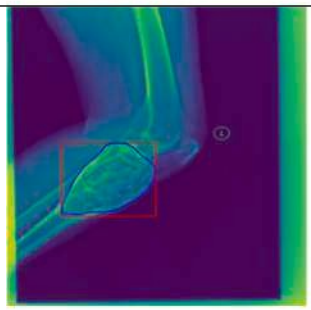	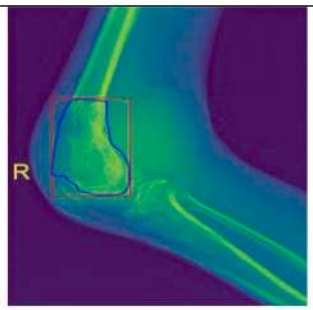	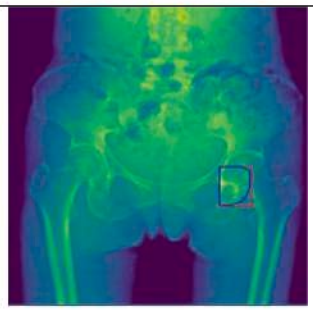
Grad-CAM	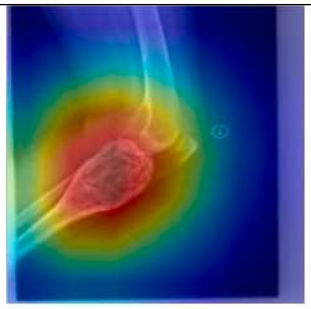	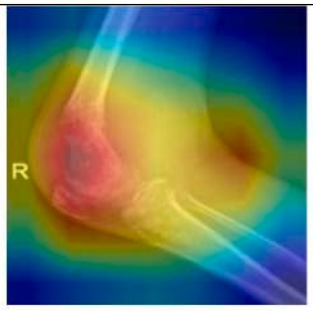	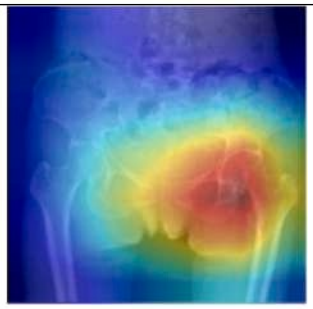
LIME			

O BoneVisionNet superou todos os modelos de última geração com uma pontuação de precisão de 84,35 %. Esses resultados demonstram o desempenho aprimorado do BoneVisionNet, comprovando sua eficácia na detecção de tumores ósseos em imagens de raios-X. Todos os indicadores de desempenho dos modelos foram resumidos na Tabela 15.

5.4. *Avaliação da generalização em conjuntos de dados adicionais*

A robustez e a generalizabilidade do BoneVisionNet proposto foram avaliadas mais detalhadamente por meio de testes em vários conjuntos de dados externos que abrangem um uma variedade de tarefas além da análise de tumores ósseos. Essas avaliações tiveram como objetivo garantir a adaptabilidade do modelo em diversos cenários clínicos. Os resultados, resumidos na Tabela 16, demonstram claramente que o modelo mantém um desempenho consistente em diferentes modalidades de imagem e regiões anatômicas, indicando seu potencial como uma ferramenta diagnóstica versátil. Notavelmente, o modelo alcançou bom desempenho nas tarefas de detecção de tuberculose e classificação de fraturas ósseas, ao mesmo tempo em que se destacou na classificação de tumores de mama. Esses resultados confirmam que o BoneVisionNet não se limita a uma patologia ou configuração de imagem específica, destacando sua capacidade de generalização eficaz para diversos dados médicos.

Tabela 12
Exemplos de visualização XAI usando SHAP.

Classe	Visualização SHAP
Tumor benigno	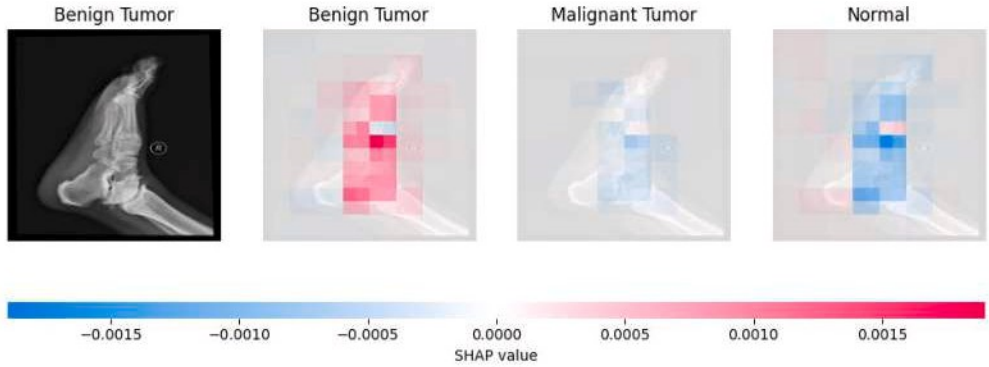
Tumor maligno	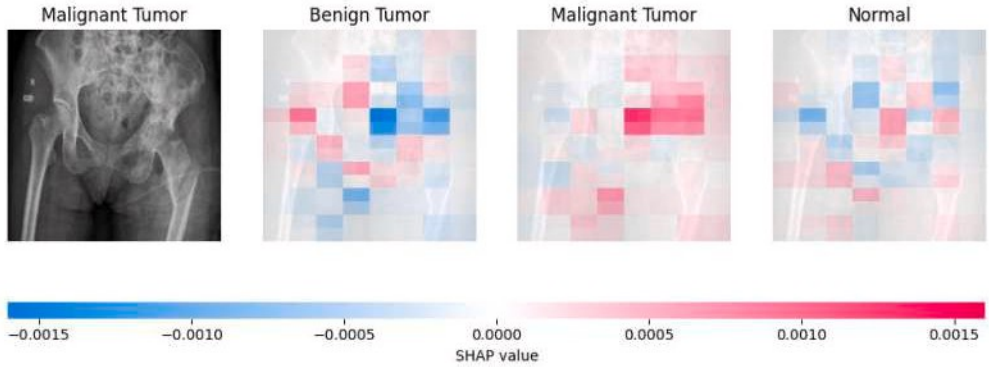
Normal	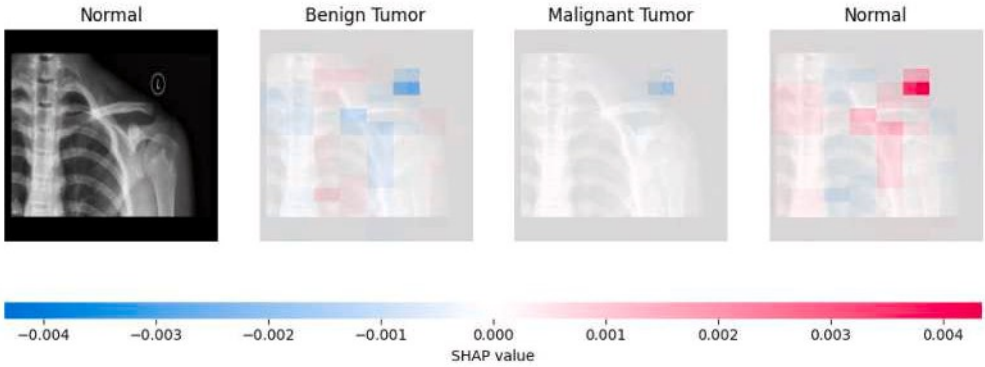

Tabela 13
Métricas de desempenho por classe para classificação binária.

Classe	Precisão (em %)	Precisão (em %)	Recuperação (em %)	F1-Score (em %)
Tumor benigno	95,43	96,68	95,43	96,05
Maligno Tumor	85,72	81,08	85,71	83,33
Total	**93,62**	**88,89**	**90,57**	**89,69**

6. Conclusão

O diagnóstico de tumores ósseos é um problema desafiador na medicina, pois apresenta uma ampla variedade de características visuais e quadros clínicos entre os pacientes. Uma intervenção precisa e oportuna é crucial para o diagnóstico de tumores ósseos e a melhoria dos resultados clínicos. As técnicas existentes para o diagnóstico de tumores ósseos dependem da análise manual de radiografias por pessoal treinado, o que é demorado e propenso a erros humanos. Essas questões destacam a necessidade urgente de soluções automatizadas que possam auxiliar os profissionais de saúde na tomada de decisões precisas e rápidas. O estudo proposto visa resolver essas questões ao propor um novo projeto de três vias para a classificação de radiografias de tumores ósseos. O Bone-VisionNet proposto utiliza três trilhas especializadas para a extração eficaz de características em múltiplas escalas. A trilha CeiT captura características globais, que são então passadas para o GCB para refinamento por meio de modelagem de características de longo alcance, a fim de melhorar a extração de características globais. As características de nível médio são capturadas pela rede personalizada ABMLFE-Net, enquanto o DenseNet-169 é utilizado para a extração de características locais.

Posteriormente, os mapas de características de saída do ABMLFE-Net e do DenseNet-169 são combinados e, em seguida, refinados utilizando o mecanismo ECA

Tabela 14
Exemplos de visualização Grad-CAM de tumores classificados incorretamente.

	Tumor maligno (osteossarcoma)	Tumor benigno (osteocondroma)	Tumor benigno (osteocondroma)
Imagem de entrada			
Imagem anotada	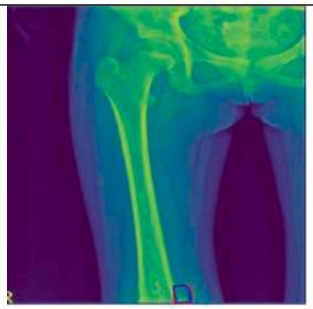	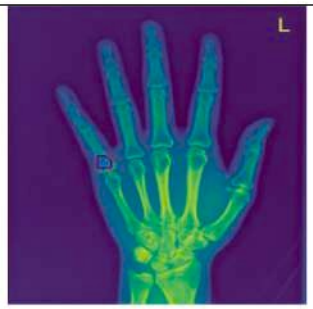	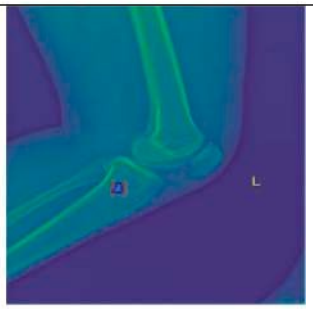
Grad-CAM	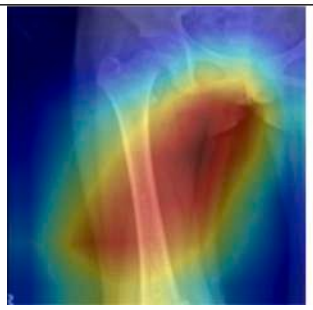		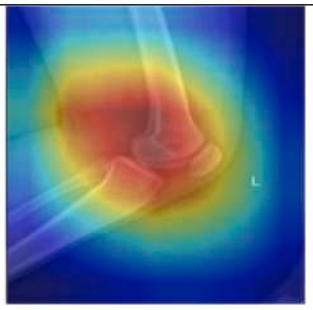

o que melhora a seleção de características sem aumentar a sobrecarga computacional. Esses mapas de características refinados da camada ECA são concatenados com características globais da GCB para produzir um mapa de características multiescala rico, visando melhorar a classificação de radiografias de tumores ósseos. O modelo foi testado no conjunto de dados BTXRD e atingiu uma precisão de 84,35% e um F1-Score de 79,61%, superando as CNNs e transformadores de última geração. Além disso, a visualização XAI usando Grad-CAM, LIME e SHAP ajuda a interpretar as classificações feitas pelo modelo com mais transparência. A arquitetura de trilha tripla proposta permite uma extração aprimorada de características globais, semilocais e locais a partir de imagens de raios-X, levando a uma maior precisão de classificação. O BoneVisionNet proposto classifica tumores ósseos com precisão e transparência, tornando-o uma ferramenta de diagnóstico clínico em potencial para a detecção eficaz de tumores ósseos.

Declaração de contribuição de autoria CRediT

Akshaj Singh Bisht: Redação – rascunho original, Software, Metodologia, Curadoria de dados, Conceitualização. **Pranav Uppuluri:** Redação – rascunho original, Metodologia, Curadoria de dados, Conceitualização. **Armaano Ajay:** Redação – rascunho original, Visualização, Validação, Software, Metodologia, Análise formal, Curadoria de dados, Conceitualização. **Karthik R:** Redação – revisão e edição, Visualização, Validação, Supervisão, Recursos, Administração do projeto, Metodologia, Investigação, Conceitualização.

Consentimento informado

Todos os autores revisaram e aprovaram o manuscrito e consentem com sua publicação.

Consentimento para participar

O estudo baseou-se exclusivamente em dados de imagens de acesso público; não foi necessário obter o consentimento dos participantes.

Aprovação ética

O estudo utilizou dados de imagens disponíveis publicamente; a aprovação ética não se aplica.

Tabela 15
Comparação de desempenho da rede BoneVisionNet proposta com arquiteturas de ponta.

Modelo	Precisão (em %)	Precisão (em %)	Recall (em %)	F1-Score (em %)
Atenção de classe em transformadores de imagem	54,11	50,12	55,75	49,31
Token-to-Token Transformador	55,97	50,82	56,29	50,74
Pyramid Vision Transformador	58,62	53,69	58,39	53,00
Swin Transformador	59,68	53,61	58,15	53,72
ShuffleNet	59,95	54,49	60,38	55,11
Imagem com eficiência de dados Transformador	61,01	55,68	61,44	55,55
EfficientNet	61,76	60,24	62,05	61,14
MobileNet	63,66	58,44	65,17	58,95
Transformer-in-Transformador	63,66	58,61	65,70	58,64
AlexNet	63,93	58,04	64,13	58,71
SqueezeNet	65,78	58,63	63,02	59,01
ResNet	66,05	59,34	64,64	60,38
XceptionNet	67,64	62,00	66,71	61,09
Transformador de Imagens com Reforço	69,23	61,98	66,27	63,08
Convolucional DenseNet	72,68	66,97	72,08	68,80
Modelo proposto	**84,35**	**79,61**	**84,76**	**81,66**

Tabela 16
Resumo do desempenho do BoneVisionNet em vários conjuntos de dados.

Conjunto de dados	Precisão (em %)	Precisão (em %)	Recall (em %)	Pontuação F1 (em %)
BTXRD (Yao et al., 2025)	84,35	79,61	84,76	81,66
Sakha-TB (Pchelintsev et al., 2022)	85,04	85,25	85,00	84,97
FracAtlas (Abedeen et al., 2023)	90,34	89,86	90,34	89,66
Domínio da Mamografia (Aqdar et al., 2024)	97,33	98,44	92,31	95,04

Financiamento

Esta pesquisa não recebeu qualquer financiamento.

Divulgação sobre IA

Ferramentas de inteligência artificial (IA), incluindo o ChatGPT da OpenAI, foram utilizadas para auxiliar na elaboração deste manuscrito. Essas ferramentas auxiliaram em tarefas como refinamento da linguagem, correção gramatical e estruturação do conteúdo. Todo o conteúdo intelectual, a interpretação dos dados e as decisões finais foram de responsabilidade exclusiva dos autores, que assumem total responsabilidade pela integridade e precisão do trabalho apresentado

Declaração de Conflito de Interesses

Os autores declaram que não possuem interesses financeiros concorrentes conhecidos ou relações pessoais que pudessem parecer influenciar o trabalho relatado neste artigo.

Disponibilidade de dados

Os dados serão disponibilizados mediante solicitação.

Referências

Abedeen, I., Rahman, Md.A., Prottyasha, F.Z., Ahmed, T., Chowdhury, T.M., Shatabda, S., 2023. FracAtlas: um conjunto de dados para classificação, localização e segmentação de radiografias musculoesqueléticas. Sci. Data 10. https://doi.org/10.1038/s41597-023-02432-4.

Ahmed, S.F., Alam, Md.S.B., Hassan, M., Rozbu, M.R., Ishtiak, T., Rafa, N., et al., 2023. Técnicas de modelagem de aprendizado profundo: progresso atual, aplicações, vantagens e desafios. Artif. Intell. Rev. 56, 13521–13617. https://doi.org/10.1007/s10462-023-10466-8.

Ahsan, M.M., Luna, S.A., Siddique, Z., 2022. Diagnóstico de doenças baseado em aprendizado de máquina: uma revisão abrangente. Healthcare 10, 541. https://doi.org/10.3390/healthcare10030541.

Aqdar, K.B., Mustafa, R.K., Abdulqadir, Z.H., Abdalla, P.A., Qadir, A.M., Shali, A.A., et al., 2024. Domínio da mamografia: um conjunto de dados robusto para a detecção do câncer de mama e a educação médica. Data Brief. 55, 110633. https://doi.org/10.1016/j.dib.2024.110633.

Sarcomas ósseos, 2014. Diretrizes de Prática Clínica da ESMO para diagnóstico, tratamento e acompanhamento. Ann. Oncol. 25, iii113–iii123. https://doi.org/10.1093/annonc/mdu256.

Breden, S., Hinterwimmer, F., Consalvo, S., Neumann, J., Knebel, C., von Eisenhart-Rothe, R., et al., 2023. Detecção baseada em aprendizado profundo de tumores ósseos ao redor do joelho em radiografias de crianças. JCM 12, 5960. https://doi.org/10.3390/jcm12185960.

Cao, Y., Xu, J., Lin, S., Wei, F., Hu, H., 2023. Redes de contexto global. IEEE Trans. Pattern Anal. Mach. Intell. 45, 6881–6895. https://doi.org/10.1109/ tpami.2020.3047209.

Chollet F. Xception: Deep Learning with Depthwise Separable Convolutions. Conferência IEEE sobre Visão Computacional e Reconhecimento de Padrões (CVPR) 2017:1800–7. https://doi.org/10.1109/cvpr.2017.195.

Dalai, S.S., Ranjan Sahu, B.J., Rautaray, J., Khan, M.I., Jabr, B.A., Ali, Y.A., 2024. Detecção automatizada de câncer ósseo utilizando aprendizado profundo em imagens de raios-X. Surg. Innov. https://doi.org/10.1177/15533506241299886.

Hakim, D.N., Pelly, T., Kulendran, M., Caris, J.A., 2015. Tumores benignos dos ossos: uma revisão. J. Bone Oncol. 4, 37–41. https://doi.org/10.1016/j.jbo.2015.02.001.

Han K., Wang Y., Tian Q., Guo J., Xu C., Xu C. GhostNet: Mais recursos a partir de operações baratas. Conferência IEEE/CVF 2020 sobre Visão Computacional e Reconhecimento de Padrões (CVPR) 2020. https://doi.org/10.1109/cvpr42600.2020.00165.

Hinterwimmer, F., Serena, R.S., Wilhelm, N., Breden, S., Consalvo, S., Seidl, F., et al., 2024. Classificação de tumores ósseos com base em sistemas de recomendação e radiografias — uma ligação com o passado. Eur. Radio. 34, 6629–6638. https://doi.org/10.1007/s00330-024-10672-0.

Hu J., Shen L., Sun G. Redes Squeeze-and-Excitation. Conferência IEEE/CVF 2018 sobre Visão Computacional e Reconhecimento de Padrões 2018. https://doi.org/10.1109/cvpr.2018.00745.

Huang G., Liu Z., Van Der Maaten L., Weinberger K.Q. Redes convolucionais densamente conectadas. Conferência IEEE de 2017 sobre Visão Computacional e Reconhecimento de Padrões (CVPR) 2017. https://doi.org/10.1109/cvpr.2017.243.

K, S.B., 2025. Revolucionando a detecção do câncer ósseo: análise de imagens médicas em tempo real utilizando o YOLOv8 para maior precisão e rapidez no diagnóstico. IJRASET 13, 854–857. https://doi.org/10.22214/ijraset.2025.66462.

Khalfaoui-Hassani, I., Pellegrini, T., Masquelier, T., 2021. Convolução dilatada com espaçamentos aprendíveis. arXiv. https://doi.org/10.48550/ARXIV.2112.03740.

Li, J., Li, S., Li, X., Miao, S., Dong, C., Gao, C., et al., 2022. Detecção e classificação de tumores ósseos primários em radiografias ósseas de campo total por meio do modelo de aprendizado profundo YOLO. Eur. Radio. 33, 4237–4248. https://doi.org/10.1007/s00330-022-09289-y

Lundberg, S., Lee, S.-I., 2017. Uma abordagem unificada para a interpretação de modelos de previsão. https://doi.org/10.48550/ARXIV.1705.07874.

Natha, S., Laila, U., Gashim, I.A., Mahboob, K., Saeed, M.N., Noaman, K.M., 2024. Identificação automatizada de tumores cerebrais em imagens de radiologia biomédica: uma abordagem de aprendizado profundo com conjunto de múltiplos modelos. Appl. Sci. 14, 2210. https://doi.org/10.3390/ app14052210.

Pan, C., Lian, L., Chen, J., Huang, R., 2023. FemurTumorNet: Classificação de tumores ósseos no fêmur proximal utilizando o modelo DenseNet com base em radiografias. J. Bone Oncol. 42, 100504. https://doi.org/10.1016/j.jbo.2023.100504.

Pchelintsev, Ya, Khvostikov, A., Buchatskaia, O., Nikiforova, N., Shepeleva, L., Prokopev, E., et al., 2022. Análise de robustez do diagnóstico computadorizado de tuberculose em radiografias de tórax. Comput. Math. Model 33, 472–486. https://doi.org/ 10.1007/s10598-023-09587-0.

Rayed, Md.E., Islam, S.M.S., Niha, S.I., Jim, J.R., Kabir, M.M., Mridha, M.F., 2024. Aprendizado profundo para segmentação de imagens médicas: avanços de ponta e desafios. Inform. Med. Unlocked 47, 101504. https://doi.org/10.1016/j. imu.2024.101504.

Ribeiro M.T., Singh S., Guestrin C. "Why Should I Trust You?" Anais da 22ª Conferência Internacional ACM SIGKDD sobre Descoberta de Conhecimento e Mineração de Dados 2016:1135–1144. https://doi.org/10.1145/2939672.2939778.

Selvaraju R.R., Cogswell M., Das A., Vedantam R., Parikh D., Batra D. Grad-CAM: Explicações visuais a partir de redes profundas por meio de localização baseada em gradiente. Conferência Internacional IEEE sobre Visão Computacional (ICCV) 2017. https://doi.org/10.1109/iccv.2017.74.

Singh, R., Srivastava, N., Kashyap, R., 2024. Detecção aprimorada de câncer ósseo usando classificação por aprendizado convolucional profundo a partir de imagens histopatológicas. Adv. Med. Technol. Clin. Pract. 219–236. https://doi.org/10.4018/979-8-3693-6308-9.ch010.

Song, L., Li, C., Tan, L., Wang, M., Chen, X., Ye, Q., et al., 2024. Um modelo de aprendizado profundo para aprimorar a classificação de tumores ósseos primários com base em imagens multimodais incompletas em raios-X, tomografia computadorizada e ressonância magnética. Cancer Imaging 24. https://doi.org/10.1186/s40644-024-00784-7.

Taye, M.M., 2023. Compreensão do aprendizado de máquina com aprendizado profundo: arquiteturas, fluxo de trabalho, aplicações e direções futuras. Computers 12, 91. https://doi.org/ 10.3390/computers12050091.

Vijayaraj, J., Abirami, B., Mohanty, S.N., Kavitha, V.P., 2023. Uma abordagem eficiente de gradientes orientados por histograma convolucional e aprendizado convolucional profundo para a classificação precisa

do câncer ósseo. Int J. Imaging Syst. Tech. 34. https://doi.org/10.1002/ ima.23000.
Wang Q., Wu B., Zhu P., Li P., Zuo W., Hu Q. ECA-Net: Atenção de canal eficiente para redes neurais convolucionais profundas. Conferência IEEE/CVF 2020 sobre Visão Computacional e Reconhecimento de Padrões (CVPR) 2020:11531–9. https://doi.org/10.1109/cvpr42600.2020.01155.
Xu, Y., Shi, F., Zhang, Y., Yin, M., Han, X., Feng, J., et al., 2023. Resultados de um estudo de 20 anos sobre prevalência, incidência, mortalidade e taxa de sobrevivência em pacientes com tumores ósseos malignos. Int. J. Cancer 154, 226–240. https://doi.org/10.1002/ijc.34694
Yao, S., Huang, Y., Wang, X., Zhang, Y., Paixão, I.C., Wang, Z., et al., 2025. Um conjunto de dados radiográficos para a classificação, localização e segmentação de tumores ósseos primários. Sci. Data 12. https://doi.org/10.1038/s41597-024-04311-y.
Yuan K., Guo S., Liu Z., Zhou A., Yu F., Wu W. Incorporação de arquiteturas convolucionais em transformadores visuais. Conferência Internacional IEEE/CVF sobre Visão Computacional (ICCV) 2021:559–68. https://doi.org/10.1109/iccv48922.2021.00062.
Zhang X., Zhou X., Lin M., Sun J. ShuffleNet: Uma rede neural convolucional extremamente eficiente para dispositivos móveis. Conferência IEEE/CVF sobre Visão Computacional e Reconhecimento de Padrões 2018. https://doi.org/10.1109/cvpr.2018.00716.