Assine o DeepL Pro para traduzir arquivos maiores.
Mais informações em www.DeepL.com/pro.

Pré-processamento e pós-processamento para detecção robusta de tumores ósseos: um pipeline de aumento ponderado guiado por Siamese

Ali Tamizifar
Departamento de Engenharia Elétrica e Computação, Universidade de Tecnologia de Isfahan Isfahan 84156-83111, Irã
a.tamizi@ec.iut.ac.ir

Shakiba Berenjkoub
Departamento de Engenharia Elétrica e Computação, Universidade de Tecnologia de Isfahan Isfahan 84156-83111, Irã
s.berenjkoub@ec.iut.ac.ir

Zahra SobhaniNia
Faculdade de Ciências, Universidade de Copenhague, Copenhague, Dinamarca
zahra.s@di.ku.dk

Nader Karimi
Departamento de Engenharia Elétrica e Computação, Universidade de Tecnologia de Isfahan Isfahan 84156-83111, Irã
nader.karimi@iut.ac.ir

Pejman Khadivi
Departamento de Ciência da Computação
Universidade de Seattle
Seattle, EUA
khadivip@seattleu.edu

Shadrokh Samavi
Departamento de Ciência da Computação, Universidade de Seattle,
Seattle, WA 98122, EUA
samavishadro@seattleu.edu

2025 IEEE World AI IoT Congress (AIIoT) | 979-8-3315-2508-8/25/$31,00 ©2025 IEEE | DOI: 10.1109/AIIoT65859.2025.11105226

***Resumo* — A detecção de tumores ósseos em imagens médicas representa um desafio significativo devido à variabilidade na aparência dos tumores e à necessidade de análises precisas e eficientes. A detecção precisa é crucial para o diagnóstico e tratamento oportunos; no entanto, os métodos tradicionais geralmente dependem de vários modelos para diferentes tarefas, resultando em maior complexidade e sobrecarga computacional. Neste artigo, propomos uma nova abordagem que aborda essas questões, integrando pré-processamento, uma estrutura multitarefa e pós-processamento orientado por Siamese em uma estrutura coesa para classificação, segmentação e localização. Nosso método utiliza o YOLOv11n para focar em regiões relevantes da imagem e o YOLOv11-seg para classificação, localização e segmentação simultâneas. Em seguida, usamos uma rede Siamese para refinar os resultados da segmentação. Esse design unificado reduz o número de parâmetros e melhora o desempenho, oferecendo uma solução promissora para a detecção eficiente e precisa de tumores ósseos.**

Palavras-chave — Análise de imagens médicas, Aprendizagem multitarefa, Aumento do tempo de teste (TTA), Tumor ósseo, BTXRD, Pós-processamento

I. Introdução

Os ossos fornecem suporte estrutural e permitem o movimento, trabalhando em conjunto com os ligamentos e a medula óssea para manter as funções corporais. O câncer ósseo surge quando células saudáveis proliferam descontroladamente, formando tumores que enfraquecem o tecido ósseo e podem metastatizar. O diagnóstico do câncer ósseo requer conhecimento especializado, sendo a radiografia uma ferramenta fundamental para detectar anormalidades estruturais. No entanto, as diversas aparências de tumores como o osteossarcoma e o condrossarcoma complicam o diagnóstico preciso [1]. A radiografia auxilia na avaliação do crescimento e da agressividade do tumor, orientando o diagnóstico. Tumores avançados podem destruir os ossos, causando dor, fraturas e redução da mobilidade. A detecção precoce e a classificação precisa são cruciais para um tratamento eficaz, especialmente em casos agressivos que requerem intervenção urgente. Embora o diagnóstico manual dos radiologistas continue sendo o padrão, os avanços em imagens e análises automatizadas estão aumentando a precisão e a eficiência da identificação de tumores ósseos [2].

Nos últimos anos, os algoritmos de aprendizado profundo transformaram a análise de imagens médicas [3]. As redes neurais convolucionais (CNNs) têm apresentado um desempenho excepcional em tarefas como classificação de imagens, detecção de objetos e segmentação. Esses métodos extraem automaticamente características de grandes conjuntos de dados, contornando a engenharia manual de características. Sua capacidade de aprender características hierárquicas os torna adequados para desafios complexos de imagens médicas, nos quais as abordagens tradicionais enfrentam dificuldades com a variabilidade e padrões sutis. Como resultado, o aprendizado profundo surgiu como uma ferramenta poderosa para analisar e segmentar tumores ósseos.

As CNNs são agora indispensáveis na análise de imagens médicas, destacando-se em tarefas de classificação, segmentação e localização de tumores. Ao processar imagens hierarquicamente, elas identificam padrões e características vitais para um diagnóstico preciso. Modelos amplamente utilizados na análise de tumores ósseos incluem U-Net, YOLO e ResNet. A arquitetura codificador-decodificador da U-Net se destaca na segmentação, delineando com precisão os limites do tumor [4]. O YOLO, otimizado para detecção de objetos em tempo real, facilita a localização precisa de tumores em exames médicos [5]. O ResNet, aproveitando o aprendizado residual profundo, aprimora a classificação ao resolver as dificuldades de treinamento em redes profundas [6].

Apesar de seu potencial, os modelos baseados em CNN enfrentam limitações. Modelos de segmentação, como o U-Net, podem ter dificuldade com a localização precisa, enquanto modelos de detecção, como o YOLO, muitas vezes carecem de recursos detalhados de segmentação. Modelos de classificação, como o ResNet, normalmente exigem conjuntos de dados rotulados extensos e podem ignorar detalhes espaciais. Desafios adicionais surgem no pré-processamento [7] (por exemplo, redução de ruído) e no pós-processamento [8] (por exemplo, redução de falsos positivos ou refinamento de limites). Uma abordagem multitarefa [9] — integrando classificação, segmentação e localização em um único modelo — pode mitigar essas questões compartilhando recursos entre as tarefas, aumentando assim a eficiência e a precisão [10]. Essa estratégia de aprendizagem conjunta otimiza o pipeline e permite que o modelo aprenda representações mais generalizáveis, especialmente em domínios com escassez de dados. Em imagens médicas, por exemplo, multitarefa

Uso autorizado e licenciado limitado a: UNIVERSIDADE FEDERAL DO PIAUI. Baixado em 26 de fevereiro de 2026 às 06:14:43 UTC do IEEE Xplore. Aplicam-se restrições.
979-8-3315-2508-8/25/$31.00 ©2025 IEEE

têm demonstrado um sucesso significativo no aumento da precisão do diagnóstico, reduzindo a dependência de anotações extensas, tornando-as altamente práticas para a implantação clínica no mundo real [11, 12].

Neste artigo, propomos uma estrutura inovadora para a detecção de tumores ósseos que unifica classificação, segmentação e localização em um único modelo eficiente. Nossa abordagem começa com um pipeline de pré-processamento robusto que remove regiões de imagem irrelevantes e melhora a qualidade normalizando variações de intensidade, garantindo que o foco permaneça nas regiões críticas do tumor. Utilizamos o YOLOv11-seg como base, aproveitando sua capacidade de realizar as três tarefas simultaneamente com alta precisão. Para elevar ainda mais o desempenho, introduzimos uma estratégia de pós-processamento baseada em Siamese que refina os resultados da segmentação, reduzindo falsos positivos e tornando os limites do tumor mais nítidos. Esse método integrado não apenas simplifica o processo de detecção, mas também alcança uma precisão diagnóstica superior, oferecendo uma solução confiável para aplicações clínicas.

O restante deste artigo está estruturado da seguinte forma: a Seção II revisa trabalhos relacionados, explorando os avanços recentes no aprendizado profundo para análise de imagens médicas, com ênfase na detecção de tumores ósseos. A Seção III descreve o método proposto, detalhando o pipeline de pré-processamento, a arquitetura multitarefa baseada em YOLOv11 e as estratégias de pós-processamento. A Seção IV apresenta os resultados experimentais, incluindo conjuntos de dados, parâmetros de treinamento e uma avaliação abrangente do desempenho. A Seção V conclui o artigo e descreve as direções futuras da pesquisa.

II. Trabalhos relacionados

Os recentes avanços no aprendizado profundo melhoraram significativamente a detecção e classificação de tumores ósseos primários em imagens radiográficas. Um estudo notável de von Schacky et al [13] desenvolveu um modelo de aprendizado profundo multitarefa baseado na arquitetura Mask R-CNN com um backbone ResNeXt-101, pré-treinado no conjunto de dados Microsoft Common Objects in Context (COCO) [14]. Esse modelo foi projetado para realizar simultaneamente o posicionamento de caixas delimitadoras, a segmentação e a classificação de tumores ósseos primários em radiografias. A arquitetura inclui três cabeças distintas: uma função de perda de regressão para o posicionamento preciso de caixas delimitadoras, funções de perda sigmoidal e binária por pixel para a segmentação precisa de tumores e perda de entropia cruzada categórica para classificar tumores como benignos ou malignos.

Li et al [15] desenvolveram um modelo de aprendizado profundo baseado em YOLO para a detecção e classificação automatizadas de lesões ósseas em radiografias de campo total. O modelo foi treinado em um conjunto de dados composto por 1085 radiografias de tumores ósseos e 345 radiografias normais coletadas em dois centros médicos. Ele foi projetado primeiro para localizar lesões ósseas e, posteriormente, classificá-las em quatro categorias: normal, benigna, intermediária ou maligna. O desempenho da detecção foi avaliado usando a interseção sobre a união (IoU), enquanto a precisão da classificação foi avaliada por meio de matrizes de confusão e pontuações kappa de Cohen. Uma análise comparativa com dois radiologistas em um conjunto de validação externo demonstrou a eficácia do modelo na caracterização de lesões e na consistência do diagnóstico.

Kim et al. [16] introduzem uma abordagem inovadora para o aumento do tempo de teste, selecionando dinamicamente transformações. adaptado a cada instância de entrada. Ao contrário dos métodos tradicionais que aplicam transformações uniformes durante os testes, esta técnica emprega uma rede auxiliar para prever a perda potencial associada a várias transformações de uma determinada entrada. Ao aplicar essas transformações previstas para produzir perdas menores e calcular a média das previsões dessas entradas aumentadas, o modelo demonstra maior robustez contra diversas corrupções de imagem, conforme evidenciado pelo desempenho aprimorado em vários benchmarks de classificação de imagens.

Em outro trabalho, Tomar et al. [17] apresentam o TeSLA, um novo método de adaptação em tempo de teste que supera as limitações das abordagens existentes, como o foco exclusivo em tarefas de classificação, a dependência de arquiteturas de rede especializadas e os desafios com a calibração do modelo. O TeSLA adapta um modelo de origem pré-treinado a dados de teste de streaming não rotulados, empregando uma nova função de perda em tempo de teste que aproveita a informação mútua e a destilação de conhecimento online. Além disso, incorpora um módulo de aumento adversário aprendível para aprimorar a destilação de conhecimento, gerando imagens aumentadas de alta entropia.

Alwzwazy et al [18] apresentam o FracNet, uma estrutura de aprendizado profundo de ponta a ponta projetada para a detecção precisa de fraturas ósseas. O FracNet integra mecanismos de atenção para aprimorar a extração de características, melhorando assim a interpretabilidade do modelo. A arquitetura emprega estratégias de fusão e seleção de características para reforçar a aprendizagem de representação e a robustez, garantindo uma generalização eficaz em diversos padrões de fraturas. Além disso, o FracNet incorpora módulos de explicabilidade que fornecem previsões claras e interpretáveis, auxiliando na tomada de decisões clínicas. Projetada para ser adaptável, a estrutura requer um retreinamento mínimo para acomodar novos conjuntos de dados, mantendo um alto desempenho. Sua arquitetura escalável permite a extensão para várias aplicações de imagens médicas, posicionando o FracNet como uma ferramenta versátil para a automação do diagnóstico.

III. Método proposto

Nesta seção, apresentamos nosso método proposto para a detecção de tumores ósseos, uma abordagem abrangente que integra perfeitamente classificação, segmentação e localização em uma estrutura multitarefa unificada. A arquitetura do nosso método é mostrada na Fig. 1. Nosso método aumenta a precisão e a eficiência do diagnóstico por meio de um pipeline cuidadosamente projetado que começa com o pré-processamento para refinar as imagens de entrada, seguido por uma estrutura multitarefa robusta que executa todas as três tarefas simultaneamente e conclui com uma estratégia inovadora de pós-processamento que otimiza os resultados da segmentação para uma inferência e interpretação superiores durante o teste. Ao combinar a extração de características compartilhadas entre as tarefas com um processo de refinamento orientado pela qualidade, nossa abordagem supera as limitações dos modelos autônomos, oferecendo desempenho confiável em imagens radiológicas, como raios-X de tumores ósseos e fraturas. Essa etapa de pós-processamento melhora as máscaras de segmentação e fornece insights mais profundos sobre os resultados do modelo, facilitando melhores conclusões sobre sua eficácia e confiabilidade durante a avaliação.

A. Pré-processamento

O pré-processamento é fundamental na preparação de imagens de raios X para análise, concentrando o modelo em regiões clinicamente relevantes e minimizando a complexidade computacional. Para isso,

Uso autorizado e licenciado limitado a: UNIVERSIDADE FEDERAL DO PIAUI. Baixado em 26 de fevereiro de 2026 às 06:14:43 UTC do IEEE Xplore. Aplicam-se restrições.

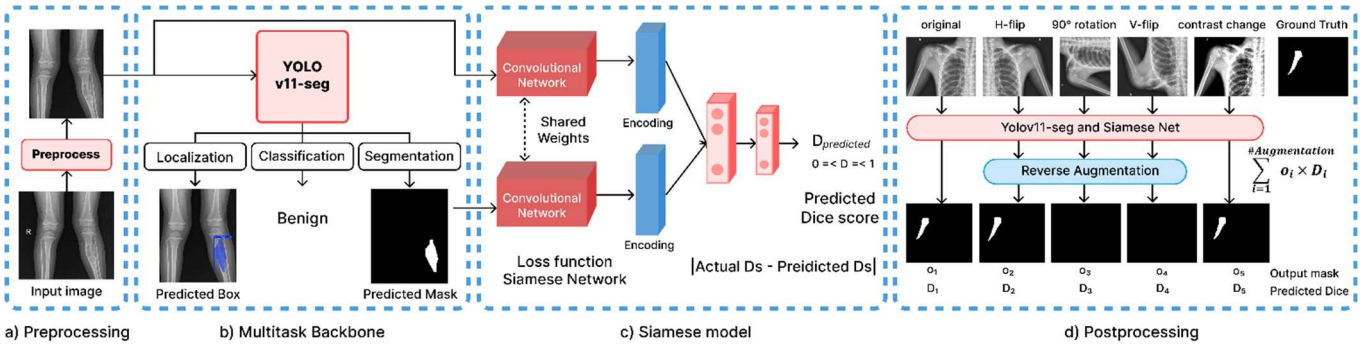

Fig. 1. Visão geral da arquitetura do sistema: (a) Pré-processamento, remove partes extras das imagens de entrada e realiza o aumento e a normalização da imagem. (b) Backbone multitarefa (YOLOv11-seg) para localização, classificação e segmentação. (c) O modelo siamês estima a pontuação de Dice entre máscaras previstas e verdades fundamentais não vistas usando imagens originais e máscaras previstas. (d) O pós-processamento aplica aumentos inversos às máscaras previstas e as combina por meio de uma média ponderada com base nas saídas do modelo siamês.

Empregamos o modelo YOLOv11n, uma estrutura leve e eficiente de detecção de objetos, para localizar regiões que contêm tecido ósseo e adiposo com base nos valores de intensidade da imagem, removendo subsequentemente áreas estranhas, como fundo ou tecidos não essenciais (Fig. 2). Para essa tarefa, rotulamos 20% do conjunto de dados BTXRD [19] — composto por raios-X de tumores ósseos — como nosso conjunto de treinamento, usando essas anotações para treinar o YOLOv11n a detectar regiões anatômicas críticas. Em seguida, avaliamos seu desempenho nos 5% restantes do BTXRD, garantindo o recorte preciso de partes irrelevantes. Para avaliar a generalização, aplicamos esse modelo YOLOv11n pré-treinado a dois conjuntos de dados adicionais, Fracatlas [20] e Wrist Fracture [21], ambos focados em fraturas ósseas, sem retreinamento adicional. Nos três conjuntos de dados, essa etapa de pré-processamento removeu consistentemente aproximadamente 30% dos pixels da imagem, aumentando a eficiência computacional e preservando detalhes estruturais essenciais.

Para garantir a robustez, projetamos o pré-processamento para levar em conta a variabilidade nos resultados da detecção. Se o YOLOv11n identificar várias caixas delimitadoras dentro de uma imagem, indicando regiões de interesse potencialmente desconexas, calculamos sua união para formar uma única região coesa, evitando a exclusão de quaisquer áreas relevantes. Por outro lado, se nenhuma caixa delimitadora for detectada, mantemos a imagem inteira para exame posterior, garantindo que nenhuma

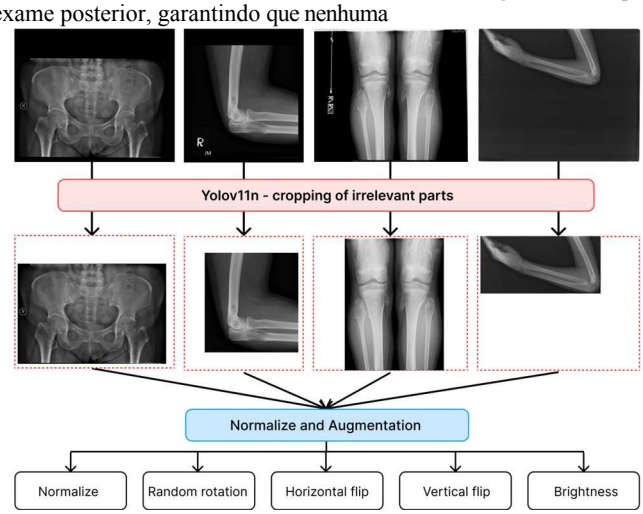

Fig. 2. Pipeline de pré-processamento: o YOLOv11n é usado para recortar regiões irrelevantes das imagens de raios X, seguido pela normalização e aumento de dados.

informações críticas são perdidas. Após o recorte, normalizamos as intensidades dos pixels das regiões retidas para um intervalo de [0, 1]. Essa etapa padroniza a escala de entrada em diversas imagens de raios X, melhorando a estabilidade e a convergência do modelo durante o treinamento. Ao contrário das técnicas convencionais de pré-processamento que priorizam a redução de ruído, nosso método se baseia apenas no recorte e na normalização, confiando na resiliência do modelo downstream para lidar com artefatos de imagem. A generalização demonstrada em BTXRD, Fracatlas e fratura de punho ressalta a adaptabilidade dessa abordagem a vários contextos radiológicos, tornando-a uma base versátil para análises subsequentes.

Além das etapas de pré-processamento, aplicamos um pipeline de aumento para melhorar a robustez do modelo. Isso incluiu rotações aleatórias, inversões horizontais e verticais e ajustes de brilho e contraste.

B. *Backbone multitarefa*

O YOLOv11-seg é um modelo multitarefa de ponta projetado para desempenho em tempo real em classificação, localização e segmentação, que está no centro do nosso método. Essa estrutura processa as imagens pré-processadas em uma única passagem direta, extraindo características hierárquicas compartilhadas entre três cabeças específicas para cada tarefa. A cabeça de classificação determina a presença e a categoria dos tumores ósseos (por exemplo, benignos ou malignos), gerando probabilidades de classe. O cabeçalho de localização gera caixas delimitadoras para identificar as posições dos tumores, enquanto o cabeçalho de segmentação produz máscaras em nível de pixel que delineiam os limites dos tumores com granularidade fina. Essas tarefas são otimizadas em conjunto usando uma função de perda composta que equilibra a entropia cruzada para classificação, a perda de interseção sobre união (IoU) para localização e a perda de Dice para segmentação, garantindo um desempenho harmonioso em todas as saídas (Fig. 1.b).

C. *Modelo siamês*

$$MAE = \frac{1}{N}\sum_{i=1}^{N}\left|D^{(i)}_{\text{previsão}} - D^{(i)}_{\text{verdade fundamental}}\right| \quad (1)$$

Uma inovação fundamental em nossa abordagem é a integração de uma rede siamesa treinada juntamente com o YOLOv11-seg para aprimorar os recursos da espinha dorsal. A Fig. 1(c) mostra um modelo siamês auxiliar que prevê a qualidade das máscaras de segmentação, que

Uso autorizado e licenciado limitado a: UNIVERSIDADE FEDERAL DO PIAUI. Baixado em 26 de fevereiro de 2026 às 06:14:43 UTC do IEEE Xplore. Aplicam-se restrições.

pode ser incorporado em qualquer estágio do treinamento, no início para orientar o aprendizado de recursos ou mais tarde para refinar resultados maduros. Durante o treinamento, a rede siamesa recebe como entradas a imagem pré-processada original e uma máscara prevista do YOLOv11-seg, produzindo um valor escalar que representa a pontuação Dice prevista. A pontuação Dice real, calculada usando máscaras de verdade fundamental, serve como alvo, e o modelo Siamese é otimizado usando o erro absoluto médio (MAE) entre esses valores, conforme mostrado na Equação (1). Para evitar viés em direção a previsões triviais (por exemplo, zero para máscaras vazias), excluímos pares com a verdade fundamental ou máscara prevista sem conteúdo tumoral. Esse treinamento conjunto influencia dinamicamente o YOLOv11-seg, pois as melhorias na qualidade da segmentação são retroalimentadas nas previsões siamesas, promovendo uma relação simbiótica que eleva a precisão da espinha dorsal. Ao incorporar essa avaliação de qualidade ao processo de treinamento, permitimos que o modelo refine suas saídas de forma adaptativa, aprimorando sua capacidade de lidar com a complexa variabilidade das aparências dos tumores ósseos.

D_{previsto}representa a pontuação Dice prevista pela rede siamesa, enquanto$D_{\text{verdade fundamental}}$é a pontuação Dice real calculada usando a máscara da verdade fundamental.

D. *Pós-processamento*

Embora a estrutura multitarefa ofereça resultados iniciais sólidos, nossa estratégia de pós-processamento aproveita a rede Siamese para obter um refinamento excepcional durante os testes, sem afetar a fase de treinamento. Essa abordagem transcende as limitações de depender exclusivamente de resultados brutos do modelo ou conjuntos básicos de aumento, oferecendo um mecanismo sofisticado para otimizar máscaras de segmentação e tirar conclusões informadas sobre o desempenho do modelo. A rede siamesa, pré-treinada junto com o YOLOv11-seg, desempenha um papel central nessa melhoria no tempo de teste, fornecendo previsões de qualidade que orientam a integração de várias saídas de segmentação.

Durante a inferência, empregamos o aumento no tempo de teste (TTA) para gerar um conjunto de máscaras de segmentação para cada imagem de entrada, aplicando transformações como rotações, inversões e dimensionamento. A rede siamesa avalia cada máscara aumentada emparelhada com sua imagem original, que prevê uma pontuação Dice variando de 0 a 1. Essas pontuações servem como pesos em um cálculo de média ponderada, em que máscaras com pontuações acima de um limite mínimo (por exemplo, 0,1) contribuem proporcionalmente para o resultado final (Fig. 1.d). Máscaras com pontuações excessivamente baixas são excluídas, garantindo que apenas previsões de alta qualidade moldem o resultado. Esse processo aprimora os limites do tumor, reduz falsos positivos e aumenta a robustez geral, priorizando resultados confiáveis em vez de outliers.

Além do TTA, nossa estrutura de pós-processamento oferece uma vantagem adicional: a seleção de modelos. Em cenários em que vários modelos de segmentação estão disponíveis, cada um produzindo máscaras distintas para a mesma imagem, a rede siamesa atua como um avaliador auxiliar. Ao colocar esse modelo de previsão de qualidade ao lado de todos os modelos de segmentação, avaliamos seus resultados individualmente, prevendo pontuações Dice para cada um. Isso nos permite identificar qual modelo tem o melhor desempenho para uma determinada imagem, fornecendo uma base orientada por dados para selecionar o resultado de segmentação ideal. Esse pós-processamento de dupla finalidade não apenas refina os resultados individuais do modelo, mas também possibilita a análise comparativa, tornando-o uma ferramenta versátil para melhorar a inferência e apoiar a tomada de decisões diagnósticas.

Nosso método é um pipeline integrado que harmoniza o pré-processamento, a análise multitarefa e o pós-processamento avançado. As imagens de raios X passam por um pré-processamento, no qual o YOLOv11n recorta regiões irrelevantes e os valores dos pixels são normalizados para [0, 1]. Essas entradas refinadas são então processadas pelo YOLOv11-seg, que gera pontuações de classificação, caixas delimitadoras e máscaras de segmentação em uma única passagem, com a rede Siamese aprimorando o treinamento por meio de feedback de qualidade. No momento do teste, as máscaras de segmentação são refinadas por meio de TTA e média ponderada Siamese, enquanto o modelo Siamese também facilita a seleção do modelo quando várias opções de segmentação estão disponíveis. Os resultados finais — probabilidades de classificação, caixas delimitadoras localizadas e máscaras otimizadas — são preservados para avaliação independente. Esse pipeline aproveita a eficiência do aprendizado multitarefa, a precisão do pós-processamento orientado pela qualidade e a adaptabilidade de uma etapa de pré-processamento generalizável, oferecendo uma solução abrangente para a detecção de tumores ósseos.

IV. Resultados experimentais

Esta seção avalia nosso método proposto para detecção de tumores ósseos, com foco na eficiência do pré-processamento e no desempenho da estrutura multitarefa com pós-processamento orientado por Siamese. Descrevemos os conjuntos de dados, detalhamos a implementação e relatamos os resultados das tarefas de pré-processamento e multitarefa.

A. *Conjuntos de dados*

Utilizamos três conjuntos de dados radiológicos — BTXRD, Fracatlas e Wrist Fracture — para avaliar nosso modelo de pré-processamento (YOLOv11n). No entanto, como este artigo se concentra na detecção de tumores ósseos, a estrutura YOLOv11-seg e a avaliação final foram realizadas exclusivamente no BTXRD. O conjunto de dados BTXRD compreende 3.746 imagens de raios-X: 2.995 para treinamento e 751 para teste, com 1.879 imagens de indivíduos saudáveis, 1.525 imagens de tumores benignos e 342 imagens de tumores malignos. Para o pré-processamento, selecionamos aleatoriamente 20% do BTXRD (700 imagens) para treinar o YOLOv11n e 5% (175 imagens) para avaliação. Para o treinamento do YOLOv11-seg, usamos 80% do BTXRD (2.995 imagens) como conjunto de treinamento e 20% (751 imagens) para teste. Fracatlas é uma coleção de radiografias musculoesqueléticas anotadas projetadas para detecção de fraturas, e Wrist-Fracture é um conjunto de dados sobre fraturas de punho em imagens de raios-X. Usamos esses dois conjuntos de dados para avaliar a generalização do modelo de pré-processamento e não desempenharam nenhum outro papel neste estudo.

B. *Detalhes da implementação*

Os experimentos foram conduzidos em uma GPU NVIDIA RTX 4080 Super com 16 GB de memória usando PyTorch 2.6.0.

1) YOLOv11-seg Backbone: O modelo multitarefa foi inicializado com as configurações padrão do YOLOv11-seg e treinado no conjunto de treinamento BTXRD, produzindo resultados de classificação, localização e segmentação.

2) Rede Siamese: A rede Siamese apresentava dois ramos, cada um com quatro camadas convolucionais*:* 32, 64, 128 *e* 256 *filtros, cada um com* kernels 3×3. Cada camada *é* seguida por *um* max-pooling (2 × 2), reduzindo as dimensões de entrada de 256×256 para 16×16. O pooling médio global e o achatamento são

Uso autorizado e licenciado limitado a: UNIVERSIDADE FEDERAL DO PIAUI. Baixado em 26 de fevereiro de 2026 às 06:14:43 UTC do IEEE Xplore. Aplicam-se restrições.

seguidos por um bloco Multilayer Perceptron (256*2 para 128, 128 para 64, 64 para 1) com ativações ReLU, dropout (0,5) e uma saída sigmoidal para prever a pontuação Dice.

3) Pós-processamento: O aumento no tempo de teste (TTA) incluiu quatro transformações, incluindo inversão horizontal, rotação de 90°, inversão vertical e alteração aleatória de contraste. Essas imagens transformadas geraram cinco máscaras por imagem. A rede siamesa ponderou essas máscaras e combinamos as saídas do YOLOv11-seg e do U-Net usando pontuações siamesas para uma soma ponderada final.

C. Resultados

Avaliamos o desempenho do pré-processamento separadamente, seguido pelos resultados do modelo multitarefa com impacto do pós-processamento Siamese, usando dados de teste BTXRD para o último.

1) Desempenho do pré-processamento: O YOLOv11n reduziu efetivamente a sobrecarga de imagens em todos os conjuntos de dados, conforme mostrado na Tabela 1. Para fraturas de punho, ele preservou todas as regiões de fratura, removendo 33,7% dos pixels em média. Para o Fracatlas, 0,5% das imagens foram rotuladas incorretamente, resultando na remoção de 40,1% dos pixels. Para o BTXRD, 23% dos pixels foram removidos e todas as imagens foram rotuladas com precisão, sem perda das regiões tumorais. Essa redução simplificou a detecção de padrões tumorais/fraturas, alinhando áreas críticas e melhorando a retenção de detalhes durante o redimensionamento para um tamanho de entrada fixo (por exemplo, 256×256) para modelos a jusante
.

2) Multitarefa e resultados siameses: nossa abordagem utiliza um único modelo YOLOv11-seg para realizar classificação, localização e segmentação simultaneamente, reduzindo significativamente a contagem de parâmetros e o número de modelos em comparação com os métodos tradicionais, que geralmente implantam modelos separados por tarefa (por exemplo, um para classificação, um para detecção, um para segmentação). Esse design unificado minimiza a complexidade computacional, mantendo um desempenho competitivo em todas as tarefas. A rede siamesa, treinada juntamente com o YOLOv11-seg, refina os resultados da segmentação, e o pós-processamento aprimora ainda mais os resultados, integrando os resultados do TTA e do U-Net, otimizando a precisão dos limites e reduzindo os falsos positivos.

A Tabela 2 compara nosso método com as linhas de base no BTXRD. Para classificação, avaliamos precisão, recall e exatidão

TABELA 1. RESULTADOS DO PRÉ-PROCESSAMENTO COM YOLOV11N

Conjunto de dados	*Redução de pixels*	*Precisão da rotulagem*
Fratura do punho [21]	33,7	100
Fracatlas [20]	40,1	99,5 %
BTXRD [19]	23,0	100

em comparação com YOLOv8-cls, ResNet18 e ResNet50, demonstrando a eficiência do nosso modelo com menos parâmetros. Para a localização, comparamos a precisão, a recuperação e a taxa de cobertura (mAP@0.5) com o YOLOv8-s, testando com e sem pré-processamento para destacar seu impacto. Para a segmentação, avaliamos as pontuações Dice em relação ao U-Net e ao YOLOv8s-seg em quatro condições: YOLOv11-seg sozinho, com pré-processamento, com pré-processamento e pós-processamento TTA e com pré-processamento e TTA. Essas comparações ilustram o papel do pré-processamento no aprimoramento da localização e segmentação e do pós-processamento na melhoria adicional da qualidade da segmentação.

Nossa abordagem de modelo único reduz a complexidade (por exemplo, 8,5 milhões de parâmetros contra 25,6 milhões para ResNet50), enquanto o pré-processamento e o pós-processamento melhoram o desempenho em todas as tarefas, especialmente na segmentação.

V. CONCLUSÃO

Neste artigo, apresentamos um método inovador para a detecção de tumores ósseos que integra pré-processamento, uma estrutura multitarefa e pós-processamento baseado em Siamese para obter um desempenho superior na análise de imagens médicas. Nossa abordagem utiliza o YOLOv11n para um pré-processamento eficiente, reduzindo a sobrecarga da imagem e preservando regiões críticas, e emprega o YOLOv11-seg como um modelo unificado para classificação, localização e segmentação, reduzindo significativamente a contagem de parâmetros em comparação com as configurações tradicionais de múltiplos modelos. A rede Siamese melhora a qualidade da segmentação durante o treinamento e permite um pós-processamento sofisticado por meio do aumento do tempo de teste e da integração do modelo. Os resultados experimentais no conjunto de dados BTXRD demonstram que nosso método não apenas otimiza as demandas computacionais, mas também melhora a precisão em todas as tarefas, particularmente na segmentação. Trabalhos futuros explorarão a extensão dessa estrutura para outras imagens médicas.

TABELA 2. COMPARAÇÃO DE MODELOS NO CONJUNTO DE TESTES BTXRD

Método	**Classificação**			**Localização**			**Segmentação**			**Parâmetros (M)**
	Precisão	***Recuperação***	***Precisão***	***Precisão***	***Recall***	***mAP@0.5***	***Precisão***	***Recall***	***Dice***	
YOLOv8 (pequeno) [19]	0,84	0,87	0,92	0,76	0,64	0,70	0,77	0,63	0,42	11,2 M 6,4 milhões (cls) 11,8 M (seg)
ResNet18 [6]	0,79	0,82	0,86	-	-	-	-	-	-	11,6 M
ResNet50 [6]	0,81	0,83	0,87	-	-	-	-	-	-	25,5 M
U-Net [4]	-	-	-	-	-	-	0,62	0,37	0,39	23 M
YOLOv11-seg (nosso)	0,85	0,85	0,92	0,78	0,65	0,71	0,74	0,68	0,52	22,4 M
Nosso (pré-processamento)	0,86	0,88	0,93	0,69	0,70	0,72	0,71	0,70	0,54	22,4 M
Nosso (Pré-processamento + TTA)	**0,90**	**0,88**	**0,94**	**0,80**	**0,71**	**0,74**	**0,75**	**0,74**	**0,58**	22,4 + 0,5 M

Uso autorizado e licenciado limitado a: UNIVERSIDADE FEDERAL DO PIAUI. Baixado em 26 de fevereiro de 2026 às 06:14:43 UTC do IEEE Xplore. Aplicam-se restrições.

domínios, como detecção de fraturas, e refinando o modelo siamês para obter ainda mais precisão.

REFERÊNCIAS

[1] J.S.Wu, M.G. Hochman, Tumores ósseos: um guia prático para imagens, Springer Science & Business Media, 2012.

[2] K. Sampath, S. Rajagopal, A. Chintanpalli, "Uma análise comparativa de arquiteturas de aprendizado profundo baseadas em CNN para o diagnóstico precoce do câncer ósseo usando imagens de TC", *Scientific Reports,* vol. 14, n. Nature Publishing Group UK London, p. 2144-2024.

[3] G. Litjens, et.al. "Uma pesquisa sobre aprendizado profundo na análise de imagens médicas", *Medical image analysis,* vol. 42, n.º Elsevier, pp. 60--88, 2017.

[4] O. Ronneberger, P. Fischer e T. Brox, "U-net: redes convolucionais para segmentação de imagens biomédicas", na *18ª Conferência Internacional sobre Computação de Imagens Médicas e Intervenção Assistida por Computador (MICCAI),* Munique, Alemanha, 5 a 9 de outubro de 2015, pp. 234-241.

[5] R. Khanam, M. Hussain, "Yolov11: Uma visão geral das principais melhorias arquitetônicas", *pré-impressão arXiv arXiv:2410.17725,* 2024.

[6] K. He, et al., "Aprendizado residual profundo para reconhecimento de imagens", em *Anais da conferência IEEE sobre visão computacional e reconhecimento de padrões*, 2016, pp. 770-778.

[7] A. Tamizifar et al. "Segmentação aprimorada de núcleos em imagens histopatológicas usando um novo pipeline de pré-processamento e aprendizado profundo", em *2024 IEEE World AI IoT Congress (AIIoT)*, IEEE, 2024, pp. 259-264.

[8] P. Liu, et al. "Aprendizado profundo para segmentar ossos pélvicos: conjuntos de dados de TC em grande escala e modelos de linha de base", *International Journal of Computer Assisted Radiology and Surgery,* vol. 16, n.º Springer, pp. 749-756, 2021.

[9] Y. Zhao, et al. "Aprendizado profundo multitarefa para computação e análise de imagens médicas: uma revisão", *Computadores em Biologia e Medicina,* vol. 153, n.º Elsevier, p. 106496, 2023.

[10] J. Kamiri, G.M. Wambugu, A.M. Oirere, Aprendizado profundo multitarefa no processamento de imagens médicas: uma revisão sistemática, Revista Internacional de Pesquisa em Ciências da Computação, 2025.

[11] Y. Zhao, et al. "Aprendizado profundo multitarefa para computação e análise de imagens médicas: uma revisão", *Computers in Biology and Medicine,* vol. 153, n.º Elsevier, p. 106496, 2023.

[12] Z. Sobhaninia, et al. "Segmentação de tumores cerebrais por estrutura de aprendizado multitarefa multiescala em cascata baseada na agregação de características", *Processamento e Controle de Sinais Biomédicos,* vol. 85, p. 104834, 2023.

[13] C.E. von Schacky, et al. "Aprendizado profundo multitarefa para segmentação e classificação de tumores ósseos primários em radiografias", *Radiology,* vol. 301, pp. 398-406, 2021.

[14] T.Y. Lin, et al. "Microsoft coco: objetos comuns em contexto", em *Visão computacional-ECCV: 13ª conferência europeia, Zurique, Suíça, 6 a 12 de setembro de 2014, atas, parte V 13*, Springer, 2014, pp. 740-755.

[15] J. Li, et al. "Detecção e classificação de tumores ósseos primários em radiografias ósseas de campo total por meio do modelo de aprendizado profundo YOLO", *European Radiology,* vol. 33, pp. 4237-4248, 2023.

[16] I. Kim, et al. "Perda de aprendizagem para aumento no tempo de teste", *Advances in neural information processing systems,* vol. 33, pp. 4163-4174, 2020.

[17] D. Tomar, et al. "Tesla: autoaprendizagem em tempo de teste com aumento adversário automático", em *Anais da conferência IEEE/CVF sobre visão computacional e reconhecimento de padrões*, 2023, pp. 20341-20350.

[18] H.A. Alwzwazy, L. Alzubaidi, Z. Zhao, Y. Gu, "FracNet: uma estrutura de aprendizado profundo de ponta a ponta para detecção de fraturas ósseas", *Pattern Recognition Letters,* 2025.

[19] S. Yao, et al. "Um conjunto de dados radiográficos para a classificação, localização e segmentação de tumores ósseos primários", *Scientific Data,* vol. 12, n.º Nature Publishing Group UK London, p. 12, 2025.

[20] I. Abedeen, et al. "Fracatlas: um conjunto de dados para classificação, localização e segmentação de fraturas em radiografias musculoesqueléticas", *Scientific data,* vol. 10, p. 521, 2023.

[21] H. Malik, J. Jabbar e H. Mehmood, "Fratura do punho — raios X", *Mendeley Data,* 2020.

Uso autorizado e licenciado limitado a: UNIVERSIDADE FEDERAL DO PIAUI. Baixado em 26 de fevereiro de 2026 às 06:14:43 UTC do IEEE Xplore. Aplicam-se restrições.